

ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ Η/Υ ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

Διπλωματική Εργασία

Εντοπισμός μεθόδων κακόβουλου χειρισμού επιστημονικών μετρικών με χρήση μηχανικής μάθησης και γράφων

Αριστέα Τεμπελοπούλου
ΑΜ: 1084514

Επιβλέπων Καθηγητής:
Κοσμόπουλος Δημήτριος

Πάτρα, Ιούλιος 2026



ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

Εντοπισμός μεθόδων κακόβουλου χειρισμού επιστημονικών μετρικών με χρήση μηχανικής μάθησης και γράφων

Τριμελής επιτροπή:
Κοσμόπουλος Δημήτριος, Ψαράκης Εμμανουήλ, Κοσμαδάκης Σταύρος

Περίληψη

Η παρούσα διπλωματική εργασία επικεντρώνεται στην ανάπτυξη και αξιολόγηση ενός συστήματος για τον εντοπισμό κακόβουλου χειρισμού επιστημονικών μετρικών, μέσω της πρόβλεψης ανάκλησης επιστημονικών άρθρων που σχετίζονται με ”εργοστάσια παραγωγής επιστημονικών δημοσιεύσεων” (paper mills), χρησιμοποιώντας τεχνικές Μηχανικής Μάθησης σε ετερογενείς γράφους. Αναγνωρίζοντας την απουσία ενός δημόσια διαθέσιμου συνόλου δεδομένων, κατασκευάστηκε ένα νέο, ισορροπημένο σύνολο δεδομένων 6.190 άρθρων, με πηγές τις βάσεις Retraction Watch και OpenAlex. Η εργασία αξιοποιεί την τοπολογία των δικτύων αναφορών (citation networks), τα σημασιολογικά χαρακτηριστικά και τα βιβλιομετρικά στατιστικά των άρθρων μέσω του αρχιτεκτονικού μοντέλου Hetero-GraphSAGE το οποίο επιτρέπει την επαγωγική γενίκευση σε άρθρα άγνωστα κατά την εκπαίδευση, προσομοιώνοντας ρεαλιστικές συνθήκες ελέγχου. Μέσα από την κατασκευή ενός σύνθετου ετερογενούς γράφου, ο οποίος ενσωματώνει σχέσεις αναφορών, συγγραφής, βιβλιογραφικής σύζευξης και συνεργασιών μεταξύ ερευνητών, το μοντέλο επιτυγχάνει να αναδείξει στρατηγικά μοτίβα παραποίησης άρθρων που δεν είναι ανιχνεύσιμα από παραδοσιακές μεθόδους ανάλυσης κειμένου, φτάνοντας Accuracy 90.79% και F1-score 90.95% στον βασικό κώδικα. Η πειραματική διαδικασία περιέλαβε την εκπαίδευση του μοντέλου Hetero-GraphSAGE για τον ακριβή εντοπισμό ανακληθέντων επιστημονικών άρθρων, η οποία συμπληρώθηκε από πειράματα εμπλουτισμού του γράφου και επαγωγική μάθηση, αφού πρώτα διενεργήθηκε συστηματική επιλογή υπερπαραμέτρων, διασφαλίζοντας την αποφυγή διαρροής δεδομένων και ενισχύοντας την στατιστική αξιοπιστία των αποτελεσμάτων. Τα ευρήματα της έρευνας υπογραμμίζουν τη σημασία της δομικής ανάλυσης στη διαφοροποίηση μεταξύ έγκυρων άρθρων και συστηματικά παραποιημένων εργασιών, προσφέροντας ένα εργαλείο ενίσχυσης διαφάνειας στις επιστημονικές μετρικές.

Ευχαριστίες

Θα ήθελα να ευχαριστήσω τον επιβλέποντα καθηγητή κ.Κοσμόπουλο για τη βοήθεια και τη καθοδήγηση σε όλη τη διάρκεια εκπόνησης της εργασίας. Επιπλέον, θα ήθελα να ευχαριστήσω την οικογένειά μου και τις φίλες μου για την στήριξή τους σε κάθε στάδιο της φοιτητικής μου πορείας. Τέλος, θα ήθελα να ευχαριστήσω τους καθηγητές του τμήματος για τις γνώσεις που προσέφεραν σε μία διαδικασία ακαδημαϊκής ανέλιξης.

Περιεχόμενα

1 Εισαγωγή **6**

1.1 Περιγραφή του προβλήματος 6
1.2 Η εξέλιξη της επιστημονικής αξιολόγησης και η άνοδος των μετρικών 6
1.3 Από τα ακούσια σφάλματα στη σκόπιμη χειραγώγηση 7
1.4 Η επιβίωση των ανακληθέντων άρθρων στα δίκτυα αναφορών 7
1.5 Βιομηχανοποιημένη απάτη και σύγχρονες τακτικές εξαπάτησης 8
1.6 Από τη γλωσσική επεξεργασία στη δομική ανάλυση: η ανάγκη για προσεγγίσεις βασισμένες σε γράφους 9
1.7 Συνεισφορά της εργασίας 9
1.8 Μέθοδοι με βάση τα γραφήματα 10
1.9 Βασικά ευρήματα και συμπεράσματα 10
1.10 Σημασία και αντίκτυπος στην ερευνητική κοινότητα 11

2 Τεχνολογίες και προσεγγίσεις στην ανίχνευση επιστημονικής απάτης **12**

2.1 Αμιγώς κειμενικές προσεγγίσεις (text-based) 12
2.2 Προσεγγίσεις βασισμένες σε Μεγάλα Γλωσσικά Μοντέλα - LLMs 13
2.3 Προσεγγίσεις βασισμένες σε γράφους 14
2.4 Το ερευνητικό κενό, οι προκλήσεις και η συνεισφορά της εργασίας 15

3 Νευρωνικά Δίκτυα Γράφων **16**

3.1 Γράφοι 16
3.2 Η ανάγκη για δικτυακή μοντελοποίηση 16
3.3 Το πλαίσιο των Νευρωνικών Δικτύων Γράφων (GNNs) 17
3.4 Η καινοτομία των GNNs: Σχεσιακή επαγωγική προκατάληψη (relational inductive bias) 17
3.5 Ο μηχανισμός της νευρωνικής μεταβίβασης μηνυμάτων (neural message passing) . 18
3.6 Θεμελιώδεις ιδιότητες και περιορισμοί 19
3.6.1 Μετρικές Αξιολόγησης Μοντέλων Ταξινόμησης 20
3.7 Βασικές αρχιτεκτονικές GNN 23
3.7.1 Graph Convolutional Networks (GCN) 23
3.7.2 GraphSAGE (Graph Sample and Aggregate) 23
3.7.3 Graph Attention Networks (GAT) 24

3.8 Οι ετερογενείς γράφοι . . . 25
3.8.1 Ορισμός . . . 25
3.8.2 Ετερογενής Συνέλιξη: Γενίκευση της Νευρωνικής Μεταβίβασης Μηνυμάτων 26
3.8.3 Ανεξαρτησία Τύπων Χαρακτηριστικών . . . 27
3.9 Ο χώρος σχεδιασμού των GNNs . . . 28
3.10 Εφαρμογές GNNs σε επιστημονικά γραφήματα . . . 29
3.11 Το ερευνητικό κενό και η συμβολή της διπλωματικής εργασίας . . . 29

4 Δημιουργία κατάλληλου dataset 30
4.1 Επισκόπηση και αξιολόγηση υπαρχόντων συνόλων δεδομένων . . . 30
4.1.1 Βάσεις δεδομένων ανακλήσεων άρθρων . . . 30
4.1.2 Datasets πρόβλεψης ανακλήσεων . . . 31
4.1.3 Σύνολα δεδομένων για αποσύρσεις και χειραγώγηση εικόνων . . . 31
4.1.4 Λοιπά σύνολα δεδομένων . . . 32
4.2 Η ανάγκη δημιουργίας νέου συνόλου δεδομένων . . . 32
4.3 Αρχική προσέγγιση συλλογής δεδομένων: δομικοί περιορισμοί και αναθεώρηση . 33
4.4 Εξόρυξη δικτυακής τοπολογίας . . . 33
4.5 Ανάκτηση και ανακατασκευή περιλήψεων (abstracts) . . . 33
4.6 Δομή και χαρακτηριστικά τελικής έκδοσης dataset . . . 34
4.7 Από το αρχείο dataset.csv σε ετερογενή γράφο . . . 35
4.7.1 Κόμβοι γράφου . . . 35
4.7.2 Ακμές γράφου . . . 36
4.7.3 Χαρακτηριστικά κόμβων-άρθρων . . . 37

5 Προτεινόμενη αρχιτεκτονική μοντέλου Hetero-GraphSAGE 39
5.1 Ο μηχανισμός to_hetero . . . 39
5.2 RetractionDetectorSAGE: Αρχιτεκτονική δύο επιπέδων . . . 41
5.3 Κανονικοποίηση: διαφοροποίηση στον εικονικό κόμβο . . . 42
5.4 Μηχανισμοί σταθεροποίησης της εκπαίδευσης . . . 42
5.5 Δύο είδη εκπαίδευσης: Transductive έναντι Inductive . . . 43
5.6 Υπολογιστικός γράφος . . . 45

6 Πειραματική αξιολόγηση και ανάλυση αποτελεσμάτων 46
6.1 Σκοπός και οργάνωση πειραματικής διαδικασίας . . . 46
6.2 Πειραματικό περιβάλλον και προετοιμασία δεδομένων . . . 47
6.2.1 Υπολογιστικοί Πόροι και Περιβάλλον Εκτέλεσης . . . 47
6.2.2 Εξαγωγή σημασιολογικών χαρακτηριστικών κειμένου . . . 47
6.2.3 Προετοιμασία και φόρτωση του ετερογενούς γράφου . . . 48
6.3 Βασική αρχιτεκτονική και στρατηγική εκπαίδευσης . . . 49
6.3.1 Αρχιτεκτονική μοντέλου Hetero-GraphSAGE . . . 49
6.3.2 Στρατηγική εκπαίδευσης . . . 50

6.3.3 Σταθερότητα/seeds 51
6.4 Μελέτη ευαισθησίας και επιλογή υπερπαραμέτρων 52
6.4.1 Συγκριτικά αποτελέσματα δοκιμών για τις υπερπαραμέτρους 52
6.4.2 Ανάλυση αποτελεσμάτων επιλογής υπερπαραμέτρων και βέλτιστου μοντέλου 53
6.5 Απόδοση του μοντέλου σε επίπεδο βασικής τοπολογίας 55
6.6 Πειραματική αξιολόγηση εμπλουτισμού γράφου 60
6.6.1 Πείραμα 1: Ενσωμάτωση σημασιολογικών ακμών (cosine similarity) 60
6.6.2 Πείραμα 2: Ενσωμάτωση κόμβων-πανεπιστημίου 62
6.6.3 Πείραμα 3: Ενσωμάτωση κόμβων-χώρας 64
6.6.4 Πείραμα 4: Ενσωμάτωση κόμβων-επιστημονικών περιοδικών 66
6.6.5 Πείραμα 5: Ενσωμάτωση εικονικού κόμβου 71
6.7 Αξιολόγηση της γενικευτικής ικανότητας του μοντέλου 74
6.8 Συνολική σύγκριση αποδόσεων 77

7 Συμπεράσματα **78**
7.1 Η τοπολογία ως αυτόνομος δείκτης αξιοπιστίας (βασικό μοντέλο) 78
7.2 Η σημασία της πρόσθετης σημασιολογικής ομοιότητας (πείραμα 1) 79
7.3 Η συνεισφορά των θεσμικών μεταδεδομένων (πειράματα 2, 3) 79
7.4 Το εκδοτικό περιβάλλον ως ισχυρός δείκτης απάτης (πείραμα 4) 79
7.5 Η τοπικότητα των κακόβουλων μοτίβων (πείραμα 5) 80
7.6 Δυνατότητα γενίκευσης σε πραγματικές συνθήκες (πείραμα 6) 80
7.7 Περιορισμοί της μελέτης 80
7.8 Γενικό συμπέρασμα 81

8 Μελλοντική εργασία **82**
8.1 Κλιμάκωση και εμπλουτισμός του συνόλου δεδομένων 82
8.2 Εμπλουτισμός τοπολογίας και ετερογένειας 82
8.3 Εξέλιξη της αρχιτεκτονικής GNN 82
8.4 Επεξηγηματικότητα και διαφάνεια 83
8.5 Μοντελοποίηση δυναμικών γράφων (TGNs) 83

Βιβλιογραφία **84**

Κεφάλαιο 1

Εισαγωγή

1.1 Περιγραφή του προβλήματος

Η αξιοπιστία της επιστημονικής έρευνας κλονίζεται από την αυξανόμενη εξάπλωση πρακτικών που υπονομεύουν τη διαφάνεια και την εγκυρότητα της έρευνας, καθώς η φύση της ερευνητικής παράβασης έχει μεταβληθεί ριζικά. Ενώ στο παρελθόν τα επιστημονικά σφάλματα ήταν κυρίως μεμονωμένα και ακούσια, σήμερα παρατηρείται μια στροφή προς τη συστηματική και σκόπιμη ερευνητική απάτη. Το φαινόμενο ξεκίνησε με πρακτικές όπως τα «καρτέλ αναφορών» (citation cartels) [1], όπου ομάδες ερευνητών αντάλλασσαν αμοιβαία αναφορές για να διογκώσουν τους βιβλιομετρικούς δείκτες τους, και τις «εξαναγκαστικές» παραπομπές (coercive citations) [2], όπου επιβλέποντες ή επιμελητές περιοδικών, εκμεταλλευόμενοι την ιεραρχική τους θέση, επέβαλλαν την προσθήκη άσχετων παραπομπών ως προϋπόθεση για τη δημοσίευση. Στη σύγχρονη εποχή, το πρόβλημα έχει λάβει διαστάσεις «βιομηχανοποιημένης εξαπάτησης». Τα εργοστάσια παραγωγής άρθρων (paper mills) κατασκευάζουν και πωλούν συγγραφική ιδιότητα σε δημοσιεύσεις βασισμένες σε παραποιημένα δεδομένα, μία τάση που επιταχύνεται δραματικά με την ευρεία διάθεση των Μεγάλων Γλωσσικών Μοντέλων (LLMs), τα οποία παράγουν μαζικά αληθοφανή επιστημονικά κείμενα.

1.2 Η εξέλιξη της επιστημονικής αξιολόγησης και η άνοδος των μετρικών

Η ρίζα αυτής της παθογένειας εντοπίζεται στη μεταβολή του τρόπου με τον οποίο αποτιμάται το ερευνητικό έργο. Ιστορικά, ο θεσμός της ομότιμης κρίσης (peer review) αποτελούσε το κύριο φίλτρο διασφάλισης της αξιοπιστίας, εστιάζοντας στην ποιοτική αποτίμηση της έρευνας. Ωστόσο, η εκρηκτική αύξηση της παγκόσμιας ακαδημαϊκής παραγωγής τις τελευταίες δεκαετίες κατέστησε το σύστημα αυτό ανεπαρκές για να διαχειριστεί τον όγκο των νέων δημοσιεύσεων. Υπό την πίεση του δόγματος ”publish or perish”, η ακαδημαϊκή κοινότητα στράφηκε στην καθιέρωση ποσοτικών βιβλιομετρικών δεικτών, όπως ο δείκτης απήχησης (impact factor,1960), που αντιπροσωπεύει τον μέσο όρο των αναφορών που λαμβάνουν ένα άρθρο και ο δείκτης h-

index (2005),που μετρά την παραγωγικότητα και τον αντίκτυπο του ερευνητικού έργου ενός επιστήμονα, ο οποίος έχει δείκτη h όταν έχει δημοσιεύσει h εργασίες, καθεμία από τις οποίες έχει δεχτεί τουλάχιστον h ετεροαναφορές (citations). Αν και οι δείκτες αυτοί σχεδιάστηκαν για να προσφέρουν μια ταχεία αποτίμηση του ερευνητικού αντίκτυπου, η άμεση σύνδεσή τους με την ακαδημαϊκή ανέλιξη και το κύρος των ερευνητών δημιούργησε ισχυρά κίνητρα για την τεχνητή διόγκωσή τους, μετατρέποντας τις μετρικές από εργαλεία αποτίμησης σε στόχους προς χειραγώγηση.

1.3 Από τα ακούσια σφάλματα στη σκόπιμη χειραγώγηση

Η μετάβαση από τα μεμονωμένα και ακούσια επιστημονικά σφάλματα στη συστηματική ερευνητική απάτη υπήρξε σταδιακή αλλά σαφής. Η τάση αυτή αποτυπώνεται στη δραματική αύξηση ανακλήσεων (retractions) των επιστημονικών άρθρων παγκοσμίως, με τον ρυθμό εμφάνισης των ανακληθέντων χειρογράφων να αυξάνεται με συντελεστή 19.06 μέσα σε μία μόνο δεκαετία [3]. Ενώ ιστορικά τα ειλικρινή σφάλματα, οι παρανοήσεις και η αδυναμία αναπαραγωγής των πειραματικών αποτελεσμάτων (40%) [4] υπερτερούσαν της απάτης (28%) [4], η σύγχρονη βιβλιογραφία δείχνει ότι η εσκεμμένη ανάρμοστη συμπεριφορά (misconduct), η οποία περιλαμβάνει κατασκευή δεδομένων, παραποίηση και λογοκλοπή ευθύνεται πλέον για το 60% των ανακλήσεων. Αντίθετα, τα ειλικρινή ανθρώπινα λάθη περιορίζονται στο 17% ενώ τα εκδοτικά ζητήματα καταλαμβάνουν το 9% [5]. Η κατάσταση περιπλέκεται καθώς πολλά επιστημονικά περιοδικά δεν διατυπώνουν σωστά τους λόγους ανάκλησης, γεγονός που συχνά συγκαλύπτει την απάτη ως ”σφάλμα” ή αντίθετα στιγματίζει άδικα ερευνητές που προβαίνουν σε ανάκληση των άρθρων τους, στο 63% των περιπτώσεων.

1.4 Η επιβίωση των ανακληθέντων άρθρων στα δίκτυα αναφορών

Μια κρίσιμη πτυχή του προβλήματος είναι η ”επιβίωση” των ανακληθέντων άρθρων στα δίκτυα αναφορών. Παρά την επίσημη απόσυρσή τους, τα άρθρα αυτά συνεχίζουν να συγκεντρώνουν ετεροαναφορές, λειτουργώντας ως φορείς διαιώνισης σφαλμάτων μέσα στα δίκτυα αναφοράς [6]. Έρευνες δείχνουν ότι το 83% των μετα-ανακλητικών αναφορών είναι θετικές, αντιμετωπίζοντας τις μελέτες ως έγκυρες [7], συχνά λόγω άγνοιας των ερευνητών για την κατάσταση της πηγής τους. Η αποτυχία αυτή της επιστημονικής κοινότητας να αυτοδιορθωθεί αποτελεσματικά δημιουργεί σαθρά θεμέλια στη δομή της επιστημονικής γνώσης. Μόλις το 5.4% των μετα-ανακλητικών αναφορών αναγνωρίζει ρητά ότι το άρθρο έχει αποσυρθεί [8]. Η συμπεριφορά αυτή διαφοροποιείται μόνο σε ευρέως γνωστές υποθέσεις μαζική απάτης [9] όπου οι μετα-ανακλητικές αναφορές αποκτούν κριτικό και αρνητικό χαρακτήρα, με την επίγνωση της ανάκλησης να φτάνει στο 61%, με χαρακτηριστικό παράδειγμα την ανακληθείσα μελέτη του Wakefield (1998) για τα εμβόλια, η οποία πλέον παρατίθεται ευρέως ως αρνητικό πρότυπο για κατάδειξη των συνεπειών της ακαδημαϊκής απάτης. Γενικότερα, όμως τα ανακληθέντα άρθρα συνεχίζουν να μολύνουν το

δίκτυο των επιστημονικών παραθέσεων [10]. Η διαπίστωση αυτή ενισχύεται από πρόσφατη μελέτη [11], η οποία ανέλυσε το δίκτυο αναφορών και παραθέσεων μεταξύ ανακληθέντων άρθρων προερχόμενων από paper mills, εντοπίζοντας συστάδες (clusters) 53, 48 και 44 αλληλοσυνδεδεμένων άρθρων που παραπέμπουν συστηματικά το ένα στο άλλο. Το εύρημα αυτό υποδεικνύει ότι η ίδια η ύπαρξη τέτοιων πυκνών, αλληλοσυνδεδεμένων υποδικτύων μπορεί να λειτουργήσει ως έμμεσος δείκτης πιθανής αιτίας -μια παρατήρηση που στηρίζει άμεσα την ενσωμάτωση ακμών βιβλιογραφικής σύζευξης. Εφόσον τα ανακληθέντα άρθρα παραμένουν ενεργά στο δίκτυο, και συνεχίζουν να διαδίδονται και να παραποιούν τη βάση της επιστημονικής γνώσης, η ανάγκη για προγνωστικά μοντέλα καθίσταται επιτακτική. Ένα τέτοιο μοντέλο δεν υπηρετεί απλώς την ανάγκη για αναδρομική ταυτοποίηση, αλλά λειτουργεί ως μηχανισμός έγκαιρης ανίχνευσης· επιτρέπει τον εντοπισμό άρθρων που παρουσιάζουν το ίδιο δομικό "αποτύπωμα" απάτης με ήδη ανακληθείσες μελέτες, αποτρέποντας έτσι τη συνέχιση της διάδοσης συμπερασμάτων πριν αυτά παγιωθούν στη βιβλιογραφία.

1.5 Βιομηχανοποιημένη απάτη και σύγχρονες τακτικές εξαπάτησης

Η ανάγκη για τεχνητή διόγκωση των δεικτών οδήγησε στην εμφάνιση οργανωμένων δικτύων χειραγώγησης. Αρχικά, αυτό εκδηλώθηκε με τα "καρτέλ αναφορών" (citation cartels) και τις "εξαναγκαστικές παραθέσεις" (coercive citations), καθώς και με την "τιμητική πατρότητα" (honorary authorship) [2] — μιας ανήθικης πρακτικής όπου προστίθενται ως συγγραφείς άτομα που δεν είχαν καμία ουσιαστική συνεισφορά στην έρευνα, συνήθως για να προσδώσουν κύρος στο άρθρο ή να ευνοήσουν ακαδημαϊκές ανταλλαγές. Σήμερα, το πρόβλημα έχει εξελιχθεί σε αυτό που ορίζεται ως "βιομηχανοποιημένη εξαπάτηση". Τα εργοστάσια παραγωγής άρθρων (paper mills) αποτελούν πλέον οργανωμένες επιχειρήσεις που κατασκευάζουν και πωλούν θέσεις συγγραφέων σε άρθρα βασισμένα σε παραποιημένα ή κλεμμένα δεδομένα [12]. Αυτοί οι οργανισμοί δεν παράγουν απλώς περιεχόμενο, αλλά κατασκευάζουν ολόκληρα πλασματικά δίκτυα συνεργασίας και αναφορών που αφήνουν μετρήσιμα στατιστικά αποτυπώματα. Εκτιμάται μάλιστα ότι το 2% των συνολικών ακαδημαϊκών υποβολών προέρχεται από paper mills, πλήττοντας σφοδρά πεδία όπως η έρευνα ανθρώπινων γονιδίων, προκαλώντας σπατάλη ερευνητικών πόρων και επικίνδυνη αλλοίωση κλινικών οδηγιών [13] [14].

Οι πλέον σύγχρονες μέθοδοι εξαπάτησης περιλαμβάνουν μεταξύ άλλων χειραγώγηση μέσω Google Scholar [15], μία πλατφόρμα ευάλωτη σε "υπηρεσίες" βελτιστοποίησης όπου ερευνητές μπορούν να αγοράσουν αναφορές που προέρχονται από κείμενα παραγόμενα μέσω Τεχνητής Νοημοσύνης και αναρτημένα σε διακομιστές προδημοσιεύσεων (citation mills). Η χρήση παρεισφρέουσων αναφορών (sneaked references) [16] αποτελεί μία ακόμη μέθοδο απάτης, με ψευδείς αναφορές να εισάγονται στα μεταδεδομένα (Crossref/DOI) χωρίς να υπάρχουν στο πραγματικό κείμενο του άρθρου, εκμεταλλευόμενη την τυφλή εμπιστοσύνη στα αυτοματοποιημένα συστήματα. Επιπλέον, η χρήση Μεγάλων Γλωσσικών Μοντέλων (LLMs) και η Generative AI επιτρέπουν τη μαζική παραγωγή αληθοφανών αλλά ψευδών ερευνών, καθιστώντας την υπεράσπιση της

ακεραιότητας της επιστημονικής βιβλιογραφίας πρόκληση αντίστοιχη με αυτή της κλιματικής αλλαγής [17]. Για την αποφυγή ανιχνευτών λογοκλοπής χρησιμοποιούνται οι λεγόμενες tortured phrases (π.χ. "δίκτυο pin" αντί για "νευρωνικό δίκτυο") [14] , οι οποίες μολύνουν την επιστημονική ορολογία. Επιπροσθέτως, νεότερες μελέτες αποδεικνύουν ότι η αγορά AI αναφορών μέσω citation mills αφήνει μόνιμα ίχνη στο Google Scholar ακόμα και μετά την διαγραφή των πλαστών άρθρων [18]. Αυτό το διευρυνόμενο πλέγμα αθέμιτων τακτικών καθιστά επιτακτική την άμεση εγρήγορση των εκδοτών και τη θεσμοθέτηση αυτοματοποιημένων ελέγχων στα μετα-δεδομένα για τη διαφύλαξη της ακαδημαϊκής ακεραιότητας [19].

1.6 Από τη γλωσσική επεξεργασία στη δομική ανάλυση: η ανάγκη για προσεγγίσεις βασισμένες σε γράφους

Καθώς οι μέθοδοι ακαδημαϊκής απάτης μεταλλάσσονται, οι παραδοσιακές προσεγγίσεις που βασίζονται στην ανάλυση κειμένου (text mining - η διαδικασία εξαγωγής δεδομένων από μη δομημένα κείμενα) και στη Φυσική Επεξεργασία Γλώσσας (Natural Language Processing (NLP) -το πεδίο της τεχνητής νοημοσύνης που επιτρέπει στους υπολογιστές να "κατανοούν" και να χειρίζονται την ανθρώπινη γλώσσα) καθίστανται ανεπαρκείς. Τεχνικές όπως το text spinning (αυτοματοποιημένη αντικατάσταση λέξεων με συνώνυμες για αποφυγή ανιχνευτών λογοκλοπής) και η αλγοριθμική αλλοίωση κειμένων από LLMs (μοντέλα βαθιάς μάθησης που εκπαιδεύονται σε τεράστιο όγκο δεδομένων για να παράγουν αληθοφανή κείμενα) μπορούν πλέον να ξεφύγουν από τους απλούς κειμενικούς ελέγχους. Περνώντας όμως από την ανάλυση περιεχομένου στην ανάλυση δομής, αποδεικνύεται ότι αυτές οι επιχειρήσεις κατασκευάζουν ολόκληρα πλασματικά δίκτυα συνεργασίας που αφήνουν ένα μετρήσιμο στατιστικό αποτύπωμα. Αυτή η προσέγγιση αναγνωρίζει συγκεκριμένες δομικές ανωμαλίες, όπως μικρό ιστορικό δημοσιεύσεων των συγγραφέων και ασυνήθιστα χαμηλό συντελεστή ομαδοποίησης (clustering coefficient-ένα μέτρο που δείχνει πόσο στενά συνδέονται μεταξύ τους οι συνεργάτες ενός ερευνητή) στα δίκτυά του, υποδηλώνοντας καθαρά συναλλακτικές σχέσεις [20]. Το ερευνητικό κενό εντοπίζεται στην ανάγκη για συστήματα που δεν εξετάζουν το άρθρο ως μεμονωμένη οντότητα, αλλά αναλύουν την πολύπλοκη τοπολογία των ακαδημαϊκών δικτύων. Η επιστημονική απάτη αφήνει δομικά αποτυπώματα που απαιτούν προηγμένες μεθόδους, όπως τα Νευρωνικά Δίκτυα Γράφων (GNNs), για να εντοπιστούν. Η παρούσα εργασία φιλοδοξεί να καλύψει αυτό το κενό, μετατρέποντας τον έλεγχο της ακαδημαϊκής εγκυρότητας από μία διορθωτική διαδικασία σε έναν προληπτικό μηχανισμό μέσω της ανάλυσης της δομής του δικτύου.

1.7 Συνεισφορά της εργασίας

Η παρούσα διπλωματική εργασία προτείνει μία μεθοδολογία βασισμένη σε Νευρωνικά Δίκτυα Γράφων (Graph Neural Networks - GNNs) για τον εντοπισμό κακόβουλου χειρισμού επιστημονικών μετρικών. Δημιουργείται ένα νέο ισορροπημένο σύνολο δεδομένων 6.190 επιστημονικών άρθρων (ανακληθέντων και μη), με άντληση δεδομένων από τις βάσεις Retraction Watch και

OpenAlex. Χρησιμοποιούνται τεχνικές επεξεργασίας φυσικής γλώσσας (SPECTER 2 embeddings) για την αποτύπωση της επιστημονικής συγγένειας των περιλήψεων. Η πληροφορία του συνόλου δεδομένων μοντελοποιείται ως ένας ετερογενής γράφος πολλαπλών επιπέδων, ενσωματώνοντας όχι μόνο τα άρθρα και τους συγγραφείς, αλλά και τα πανεπιστήμια, τις χώρες και τα περιοδικά δημοσίευσης. Τέλος, εφαρμόζεται η αρχιτεκτονική GraphSAGE, η οποία επιτρέπει στο μοντέλο να αξιολογεί νέα, άγνωστα άρθρα χωρίς να απαιτείται επανεκπαίδευση του συστήματος, προσομοιώνοντας ρεαλιστικές συνθήκες ελέγχου προ-δημοσίευσης.

1.8 Μέθοδοι με βάση τα γραφήματα

Η μεθοδολογία βασίστηκε στην παραδοχή ότι η απάτη δεν αποτελεί ιδιότητα ενός μεμονωμένου άρθρου, αλλά ένα παρεκκλίνον μοτίβο εντός του δικτύου. Για την εξαγωγή αυτών των μοτίβων, κατασκευάζεται ένας ετερογενής γράφος όπου η πληροφορία μεταδίδεται μέσω διαφορετικών ακμών, όπως η συγγραφή (ακμές writes/written by), οι ετεροαναφορές (ακμές cites/cited by), η συν-συγγραφή (ακμές collaborates) και η βιβλιογραφική σύζευξη (ακμές bibliographic coupling).

Στον πυρήνα της υλοποίησης βρίσκεται ο αλγόριθμος GraphSAGE (Graph Sample and Aggregate). Σε αντίθεση με τα παραδοσιακά συνελικτικά δίκτυα γράφων, το GraphSAGE μαθαίνει μία γενικεύσιμη συνάρτηση συσσώρευσης (aggregation) της πληροφορίας από την τοπική γειτονιά κάθε κόμβου. Μέσω του μηχανισμού νευρωνικής μεταβίβασης μηνυμάτων (message passing), το μοντέλο λαμβάνει υπόψη τόσο τα σημασιολογικά χαρακτηριστικά ενός άρθρου όσο και τα χαρακτηριστικά των συνδεδεμένων οντοτήτων (π.χ την ύπαρξη έγκυρου orcid των συγγραφέων του).

1.9 Βασικά ευρήματα και συμπεράσματα

Από την συνολική ανάλυση των ευρημάτων προκύπτει ότι ο χειρισμός των βιβλιομετρικών δεικτών αφήνει ένα σαφές, ανιχνεύσιμο δομικό αποτύπωμα στα ακαδημαϊκά δίκτυα. Αρχικά, η εκπαίδευση του βασικού μεταβατικού μοντέλου πέτυχε ακρίβεια (Accuracy) 90.79% και F1-score 90.95%, επιβεβαιώνοντας ότι οι σχέσεις αναφορών και συν-συγγραφής αρκούν για τον εντοπισμό μεθοδευμένων αλλοιώσεων. Η ενσωμάτωση κόμβων επιστημονικών περιοδικών απέφερε την μέγιστη συνολική επίδοση (F1-score 95.63%), αποδεικνύοντας πως η βιομηχανοποιημένη απάτη των paper mills στοχεύει συστηματικά συγκεκριμένα ακαδημαϊκά περιοδικά. Παράλληλα, η προσθήκη ακαδημαϊκών ιδρυμάτων και γεωγραφικών δεδομένων βοήθησε το μοντέλο να είναι πιο σίγουρο για προειδοποίηση ανακληθέντων άρθρων και να διακρίνει με μεγαλύτερη σαφήνεια τις πραγματικές περιπτώσεις απάτης, αφού αυξήθηκαν οι μετρικές Precision (για Uni nodes) και Recall (για country nodes) αντίστοιχα. Οι ακμές σημασιολογικής ομοιότητας περιλήψεων κράτησαν την ισορροπία του μοντέλου, αντιμετωπίζοντας πρακτικές τεχνητής χειραγώγησης κειμένων. Η εισαγωγή εικονικού κόμβου βελτίωσε ελάχιστα όλες τις μετρικές, αφού αύξησε την διασυνδεσιμότητα του γράφου. Τέλος, η μετάβαση σε επαγωγικό περιβάλλον (inductive learning) με ακρίβεια 89.82%, πιστοποιεί ότι το μοντέλο GraphSAGE δεν απομνημόνευσε την τοπολογία, αλλά έμαθε την γενική συνάρτηση μεταβίβασης μηνυμάτων.

1.10 Σημασία και αντίκτυπος στην ερευνητική κοινότητα

Η παρούσα έρευνα αποδεικνύει πως η κακόβουλη ερευνητική συμπεριφορά δεν συνιστά μόνο ένα μεμονωμένο κειμενικό σφάλμα, αλλά αποτελεί ένα δομικό αποτύπωμα στο επιστημονικό δίκτυο. Η διαπίστωση αυτή καθιστά σαφές ότι τα παραδοσιακά συστήματα λογοκλοπής είναι πλέον ανεπαρκή απέναντι στις σύγχρονες τακτικές των paper mills. Η κύρια συνεισφορά της μελέτης έγκειται στην ικανότητα του μοντέλου να λειτουργεί αποτελεσματικά σε συνθήκες επαγωγικής μάθησης (inductive learning). Ουσιαστικά, η αξιολόγηση της επιστημονικής εγκυρότητας μετασχηματίζεται από μία διορθωτική διαδικασία που έπεται της ανάκλησης σε έναν προληπτικό μηχανισμό.

Κεφάλαιο 2

Τεχνολογίες και προσεγγίσεις στην ανίχνευση επιστημονικής απάτης

2.1 Αμιγώς κειμενικές προσεγγίσεις (text-based)

Οι αμιγώς κειμενικές προσεγγίσεις στην ανίχνευση επιστημονικής απάτης βασίζονται στην υπόθεση ότι οι προβληματικές δημοσιεύσεις, όπως εκείνες που προέρχονται από "εργοστάσια παραγωγής εργασιών" (paper mills), εμφανίζουν διακριτά γλωσσολογικά και υφολογικά χαρακτηριστικά που μπορούν να απομονωθούν μέσω της επεξεργασίας φυσικής γλώσσας (NLP).Ο μηχανισμός λειτουργίας τους ξεκινά με την μετατροπή του κειμένου (τίτλοι, περιλήψεις, πλήρη κείμενα) σε διανυσματικές αναπαραστάσεις (embeddings) μέσω αρχιτεκτονικών όπως οι Transformers (π.χ BERT, SciBERT). Ο βασικός μηχανισμός ελέγχου εστιάζει σε τρεις άξονες: πρώτον, στην ανίχνευση υφολογικών παρεκκλίσεων (stylometry), όπου το μοντέλο εντοπίζει τεχνικές (όπως τεχνητές επαναλήψεις) που χαρακτηρίζουν τα paper mills. Δεύτερον, στον εντοπισμό σημασιολογικής ασυνέπειας, όπου ελέγχεται αν η περίληψη παρουσιάζει λογικά κενά ή ασύνδετα συμπεράσματα σε σχέση με τον τίτλο. Τρίτον, στην εφαρμογή προτύπων κατηγοριοποίησης, όπου εξειδικευμένοι ταξινομητές εκπαιδεύονται σε μεγάλα σύνολα δεδομένων για να αναγνωρίζουν στοιχεία απάτης, όπως η χρήση συγκεκριμένων δομών πρότασης που παρατηρούνται συχνά σε χειραγωγημένες δημοσιεύσεις. Στο πλαίσιο αυτό, πρόσφατες έρευνες έχουν αξιοποιήσει προηγμένα μοντέλα βαθιάς μάθησης για τον αυτόματο εντοπισμό τέτοιων μοτίβων: το σύστημα Scancar (2026) [21] εφαρμόζει εξειδικευμένους ταξινομητές για τον εντοπισμό προβληματικών άρθρων στην ογκολογική έρευνα με υψηλή ακρίβεια, ενώ οι Transformer-based ταξινομητές, όπως εκείνοι που παρουσιάστηκαν στο συνέδριο Workshop on Scholarly Document Processing το 2025 [22], εκμεταλλεύονται την τεράστια υπολογιστική γνώση των προ-εκπαιδευμένων μοντέλων για να αναγνωρίσουν συντακτικές ιδιομορφίες σε εκατοντάδες χιλιάδες περιλήψεις. Αντίστοιχα, μοντέλα όπως το BERTRetrax [23] αποτελούν χαρακτηριστικό παράδειγμα προσπάθειας ανίχνευσης ανακλήσεων μέσω της σημασιολογικής ανάλυσης του περιεχομένου, επιτυγχάνοντας επιδόσεις που πλησιάζουν το 0.93 σε όρους F1-score σε μεγάλα ακαδημαϊκά σύνολα δεδομένων, αποδεικνύοντας ότι το κείμενο από μόνο του φέρει κρίσιμες πληροφορίες για την αξιοπιστία ενός έργου.

Οι αμιγώς κειμενικές μέθοδοι, αν και αποτελεσματικές στη φάση της προ-διαλογής (pre-

screening), παρουσιάζουν δομική ανεπάρκεια απέναντι στη σύγχρονη ακαδημαϊκή χειραγώγηση, καθώς εστιάζουν αποκλειστικά στη σημασιολογία των λέξεων αγνοώντας τοπολογικές ανωμαλίες στο δίκτυο αναφορών. Οι βιβλιομετρικοί δείκτες είναι ευάλωτοι σε τεχνητή βελτιστοποίηση [24], καθιστώντας τα γλωσσικά μοντέλα ανεπαρκή για τον εντοπισμό τακτικών που ξεπερνούν το επίπεδο του κειμένου. Η αδυναμία αυτή αναδεικνύεται εμφατικά στην έρευνα των Ibrahim et al. [15] σχετικά με τη χειραγώγηση του Google Scholar, όπου αποδείχθηκε πειραματικά ότι οι υπηρεσίες αγοράς αναφορών (citation purchasing) επιτρέπουν στους ερευνητές να διογκώσουν τεχνητά την απήχησή τους. Μέσω αυτών των υπηρεσιών, τοποθετούνται αναφορές προς το έργο τους εντός κειμένων που παράγονται από Τεχνητή Νοημοσύνη και αναρτώνται σε διακομιστές προδημοσιεύσεων, δημιουργώντας ένα δίκτυο ψευδούς επιρροής. Η ανάλυση 1,6 εκατομμυρίων προφίλ αποκάλυψε ότι ακόμα και όταν το ίδιο το κείμενο φαίνεται αληθοφανές, η στατιστική δυσαναλογία στις αναφορές και η ενσωμάτωση πλαστών παραπομπών καθιστούν τους κειμενικούς ανιχνευτές ανεπαρκείς, καθώς οι τελευταίοι δεν συσχετίζουν τη δομική ανωμαλία του δικτύου με την υφολογική αρτιότητα του περιεχομένου.

2.2 Προσεγγίσεις βασισμένες σε Μεγάλα Γλωσσικά Μοντέλα - LLMs

Οι προσεγγίσεις που βασίζονται σε Μεγάλα Γλωσσικά Μοντέλα (LLMs) αποτελούν την πιο πρόσφατη εξέλιξη στην ανίχνευση επιστημονικής παραπληροφόρησης, περνώντας από την στατιστική ανάλυση λέξεων στη σημασιολογική κατανόηση και στο συλλογιστικό πλαίσιο. Το σύστημα Pub-Guard-LLM [25] πρωτοπορεί σε αυτόν τον τομέα, εισάγοντας ένα πολυεπίπεδο πλαίσιο ανίχνευσης ανακλήσεων που λειτουργεί μέσω τριών διακριτών μηχανισμών: τον ”standard”, όπου το μοντέλο αξιολογεί άμεσα την εγκυρότητα ενός άρθρου, τον ”RAG” (Retrieval-Augmented Generation),ο οποίος ανακτά εξωτερικές έγκυρες πηγές για να διασταυρώσει τα ευρήματα της δημοσίευσης και τον ”Multi-Agent Debate”, όπου πολλαπλοί αυτόνομοι agents συνεργάζονται υπό συνθήκες κριτικής αντιπαράθεσης για την πιθανότητα απόσυρσης ενός έργου. Ο μηχανισμός λειτουργίας τους βασίζεται στην ικανότητα των LLMs να εντοπίζουν ”λογικές αντιφάσεις” ή επιστημονικά ανακριβείς ισχυρισμούς σε κείμενα που, σε επιφανειακό επίπεδο, φαίνονται συντακτικά άρτια. Έτσι, τα συστήματα αυτά επιτυγχάνουν να διαβάσουν την επιστημονική επιχειρηματολογία και να εντοπίσουν τι απόκλιση έχουν από τα καθιερωμένα πρότυπα έγκυρης έρευνας, λειτουργώντας ως ένας ψηφιακός κριτής αξιοπιστίας.

Παρά την ικανότητα των Μεγάλων Γλωσσικών Μοντέλων (LLMs) στον σημασιολογικό συλλογισμό, η χρήση τους ως αυτόνομων ανιχνευτών ακαδημαϊκής απάτης κρίνεται ανεπαρκής λόγω δομικών περιορισμών και υπολογιστικής δυσχέρειας. Τα LLMs αποτελούν ”δίκοπο μαχαίρι” καθώς η ικανότητά τους να παράγουν πειστικά, αληθοφανή επιστημονικά κείμενα επιτρέπει τη δημιουργία και ευρετηρίαση ψευδών άρθρων που παρακάμπτουν επιτυχώς τους παραδοσιακούς ανιχνευτές κειμένου [15]. Επιπλέον, η ποσοτική ανάλυση [26] υπογραμμίζει ότι ακόμη και εξελιγμένα μοντέλα αδυνατούν να διακρίνουν κακόβουλες από νόμιμες αναφορές, καθώς στερούνται πρόσβασης στη δομική πληροφορία του επιστημονικού δικτύου. Η τοπολογική ανεπάρκεια των

LLMs, σε συνδυασμό με το υπολογιστικό κόστος, δείχνει πως η ανάλυση του "τι" λέγεται σε ένα κείμενο δεν αρκεί, αφού ο εντοπισμός της ακαδημαϊκής απάτης απαιτεί πλέον μια ολοκληρωμένη δομική ανάλυση των άρθρων.

2.3 Προσεγγίσεις βασισμένες σε γράφους

Οι προσεγγίσεις που βασίζονται στην ανάλυση επιστημονικών γράφων αντιπροσωπεύουν το πλέον εξελιγμένο στάδιο στην ανίχνευση ακαδημαϊκής απάτης, καθώς αντί για αποσπασματική ανάλυση κειμένων λειτουργούν με αξιολόγηση της δομής του επιστημονικού οικοσυστήματος. Στην κατηγορία αυτή, το μοντέλο PDCN [12] αποτελεί μια ισχυρή προσέγγιση που συνδυάζει BERT embeddings για το κειμενικό περιεχόμενο με Heterogeneous Graph Attention Networks (HAN) και ταξινομητές LGBM, επιτρέποντας την ανίχνευση paper mills σε δίκτυα εκατομμυρίων κόμβων μέσω της ανάδειξης κρίσιμων τοπολογικών συσχετίσεων. Με τα HAN εκτελείται μια διαδικασία ιεραρχικής ομαδοποίησης, όπου το δίκτυο λειτουργεί ως ένας "χάρτης σχέσεων" και ο μηχανισμός attention επιτρέπει στο μοντέλο να αποδίδει δυναμικά μεγαλύτερη "βαρύτητα" σε συγκεκριμένες ύποπτες συνδέσεις (ακμές), απομονώνοντας συστηματικές προσπάθειες τεχνητής ενίσχυσης κύρους. Αντίστοιχα, τα Self-Learning Graph Masked Autoencoders (GMAE) [27] εφαρμόζουν μια διαδικασία "δικτυακής μάθησης μέσω αποκατάστασης" όπου το μοντέλο κρύβει (masks) τμήματα του γράφου και επιχειρεί να τα ανακατασκευάσει, επιτυγχάνοντας μόνο αν κατανοήσει τα αυθεντικά πρότυπα διάχυσης της γνώσης-αν το δίκτυο είναι χειραγωγημένο, η αποτυχία ανακατασκευής αποκαλύπτει την παρατυπία. Τέλος, το CIDRE [28] εστιάζει στην ανίχνευση "πυκνών ομάδων" (anomalous clusters) μέσω της ανάλυσης της τοπολογικής πυκνότητας, απομονώνοντας τεχνητά απομονωμένες κοινότητες συγγραφέων που αναφέρονται συνεχώς ο ένας στον άλλο. Παρόμοια φιλοσοφία ακολουθεί και το μοντέλο GLAD (Graph Learning for Anomaly Detection) [29], το οποίο ενσωματώνει σημασιολογικά χαρακτηριστικά κειμένουν (node attributes) με χαρακτηριστικά ακμών (link attributes) μέσω GNNs, προτείνοντας παράλληλα τον αλγόριθμο CPU (Citation PUrpose) για την ανακάλυψη του σκοπού μιας αναφοράς (κριτική, σύγκριση, βάση κ.α.) μέσω ανάλυσης του citation context. Σε αντίθεση όμως με την παρούσα εργασία, το GLAD στοχεύει στον εντοπισμό μεμονωμένων ιδιόμορφων αναφορών (citation-level anomaly) και όχι στην πρόβλεψη ανάκλησης σε επίπεδο άρθρου, ενώ δεν αξιολογήθηκε σε πραγματικό σύνολο δεδομένων ανακλήσεων αλλά σε ένα τεχνητά κατασκευασμένο.

Η σημασία της δομικής ανάλυσης επιβεβαιώνεται και από πρόσφατη μελέτη [15], στην οποία, παρά το γεγονός ότι δεν πρότειναν αρχιτεκτονική νευρωνικών δικτύων γράφων (GNN), απέδειξαν μέσω ανάλυσης δικτύων συν-αναφορών (co-citation networks) ότι η απάτη αφήνει αναπόφευκτα ένα διακριτό δομικό αποτύπωμα, καθιστώντας την ανάλυση της δομής πιο αποτελεσματική από την κειμενική ανάλυση. Στο πλαίσιο αυτό, το έργο [28] αποτελεί την πλησιέστερη βιβλιογραφική προσέγγιση για την ανίχνευση "citation cartels" μέσω δικτυακών μεθόδων, αν και ο τομέας εφαρμογής του περιορίζεται σε ομάδες αμοιβαίων αναφορών και όχι στην πρόβλεψη ανακλήσεων (retraction prediction).

2.4 Το ερευνητικό κενό, οι προκλήσεις και η συνεισφορά της εργασίας

Καθώς οι μέθοδοι ακαδημαϊκής εξαπάτησης μεταλλάσσονται και γίνονται όλο και πιο περίπλοκες, η ανακάλυψη της απάτης παραμένει μια εξαιρετικά δύσκολη διαδικασία. Η παραδοσιακή προσέγγιση βασιζόταν κυρίως στην ανάλυση κειμένου (text mining και NLP) για τον εντοπισμό λογοκλοπής. Ωστόσο, οι σύγχρονες κακόβουλες μέθοδοι, όπως το "text spinning" (χρήση συνωνύμων ή "tortured phrases") και η εισαγωγή «παρεισφρεουσών» αναφορών (sneaked references) κρυφά στα μεταδεδομένα, καθιστούν τις αμιγώς κειμενικές αναλύσεις ανεπαρκείς. Το εύρημα των Ibrahim et al. ([15]) ότι σε εξετασθέντα χειρόγραφα το 90% των αναφορών ήταν παρεισφρέουσες αναφορές – δηλαδή δεν εμφανίζονταν στο κύριο κείμενο – αποτελεί εμπειρική απόδειξη ότι η απάτη έχει μετατοπιστεί μαζικά από το κείμενο στη δομή των δικτύων αναφορών.

Η σύγχρονη βιβλιογραφία υποδεικνύει ότι τα paper mills δεν δημιουργούν απλώς κείμενα, αλλά κατασκευάζουν ολόκληρα πλασματικά δίκτυα συνεργασίας και αναφορών, για τεχνητή διόγκωση των μετρικών. Αν και έχουν υπάρξει μελέτες που προσεγγίζουν την ακαδημαϊκή απάτη ως πρόβλημα δικτύου (όπως για την ανίχνευση citation cartels), η πλειονότητα των ερευνών για την πρόβλεψη ανακλήσεων (retractions) περιορίζεται σε παραδοσιακούς ταξινομητές μηχανικής μάθησης που αγνοούν τη δομή του δικτύου. Ακόμα και όταν χρησιμοποιούνται μέθοδοι βαθιάς μάθησης σε γράφους, αυτές συνήθως είτε εστιάζουν μόνο στην ανίχνευση paper mills και όχι στην πρόβλεψη ανάκλησης, είτε είναι transductive, όπως το μοντέλο PDCN [12] που εντοπίζει paper mills με 81.85% accuracy (80.49% F1) αλλά απαιτεί η επανεκπαίδευση να συμπεριλάβει κάθε νέο άρθρο, είτε βασίζονται αποκλειστικά σε LLMs χωρίς ανάλυση τοπολογίας δικτύου, όπως το Pub-Guard-LLM [25]. Καμία από αυτές τις εργασίες δεν συνδυάζει σημασιολογικά embeddings με ετερογενή τοπολογία γράφου για την πρόβλεψη ανάκλησης σε ένα σχήμα ικανό να γενικεύσει σε αόρατα δεδομένα. Συνεπώς, υπάρχει ένα σημαντικό κενό στην ανάπτυξη συστημάτων που συνδυάζουν αποτελεσματικά το σημασιολογικό περιεχόμενο με την τοπολογία των ακαδημαϊκών δικτύων για την έγκαιρη ανίχνευση υποψήφιων ανακλήσεων.

Η παρούσα διπλωματική εργασία καλύπτει αυτό το κενό εισάγοντας ένα σύστημα που αξιοποιεί την επαγωγική μάθηση (inductive learning) μέσω του αλγορίθμου GraphSAGE πάνω σε ένα ετερογενές γράφημα άρθρων, συγγραφέων, επιστημονικών περιοδικών, χωρών και ιδρυμάτων. Σε αντίθεση με τις transductive μεθόδους που απαιτούν συνεχή επανεκπαίδευση και αδυνατούν να προβλέψουν για νέους κόμβους, το προτεινόμενο μοντέλο επιτρέπει την αξιολόγηση άρθρων που δεν έχουν συμπεριληφθεί στην εκπαίδευση. Η σημασιολογική πληροφορία ενσωματώνεται μέσω SPECTER 2 embeddings, ενώ η δομή του γράφου αποτυπώνει σύνθετες σχέσεις αναφορών, συγγραφής, συνεργασίας συγγραφέων και βιβλιογραφικής σύζευξης. Το μοντέλο επιτυγχάνει έως 95.63% F1-score όταν αξιοποιούνται οι κόμβοι περιοδικών, ενώ το πλήρως επαγωγικό μοντέλο διατηρεί 89.89% F1-score. Συνολικά, η συνεισφορά της εργασίας έγκειται στην ανάπτυξη μιας κλιμακώσιμης, δυναμικής λύσης που μετατρέπει την ανίχνευση απάτης από μια στατική ανάλυση σε μια διαδικασία έγκαιρης προειδοποίησης, ικανή να λειτουργήσει αποτελεσματικά σε ένα συνεχώς εξελισσόμενο ακαδημαϊκό δίκτυο.

Κεφάλαιο 3

Νευρωνικά Δίκτυα Γράφων

3.1 Γράφοι

Οι γράφοι αποτελούν μια πανταχού παρούσα δομή δεδομένων και μία καθολική γλώσσα για την περιγραφή πολύπλοκων συστημάτων. Ορίζονται ως μια συλλογή αντικειμένων, που ονομάζονται κόμβοι (nodes), μαζί με ένα σύνολο αλληλεπιδράσεων μεταξύ ζευγών αυτών των αντικειμένων, που ονομάζονται ακμές (edges). Μαθηματικά, ένας γράφος συμβολίζεται ως $G = (V, E)$ και συχνά αναπαρίσταται μέσω ενός πίνακα γειτνίασης (adjacency matrix) A, ο οποίος κωδικοποιεί την παρουσία συνδέσεων μεταξύ των κόμβων, όπου $A_{u,v} = 1$ εάν υπάρχει ακμή και 0 διαφορετικά. Η δύναμη της γραφικής αναπαράστασης έγκειται στην εστίασή της στις σχέσεις μεταξύ των σημείων και όχι μόνο στις ιδιότητες των μεμονωμένων σημείων, προσφέροντας ένα μαθηματικό θεμέλιο για την εκμάθηση από πραγματικά πολύπλοκα συστήματα.

3.2 Η ανάγκη για δικτυακή μοντελοποίηση

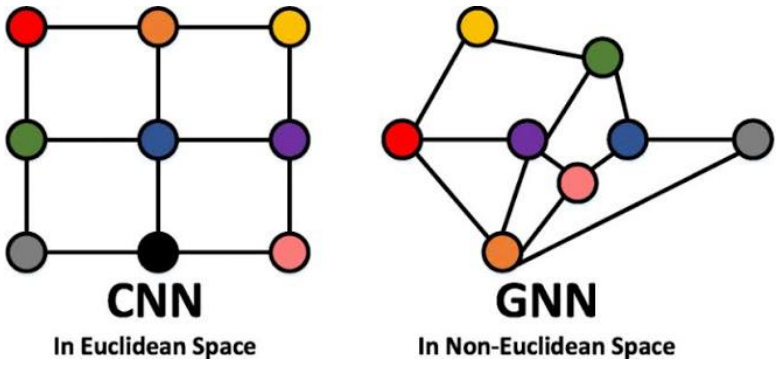
Η ανάγκη για τη χρήση γράφων απορρέει από το γεγονός ότι τα δεδομένα του πραγματικού κόσμου είναι εγγενώς διασυνδεδεμένα, καθιστώντας μη εφαρμόσιμη την παραδοσιακή υπόθεση της ανεξάρτητης και πανομοιότυπα κατανεμημένης (i.i.d.) στατιστικής της κλασσικής μηχανικής μάθησης. Ενώ τα παραδοσιακά μοντέλα βαθιάς μάθησης, όπως τα CNNs και τα RNNs, περιορίζονται σε δεδομένα όπως πλέγματα εικόνων ή ακολουθίες κειμένου, οι γράφοι προσφέρουν ένα ευέλικτο πλαίσιο για την μοντελοποίηση συστημάτων με αυθαίρετη τοπολογία και μέγεθος. Η χρήση των γράφων επιτρέπει στα μοντέλα να αξιοποιούν ρητά τις συνδέσεις μεταξύ των κόμβων, εκμεταλλευόμενα έννοιες όπως η ομοφιλία (homophily) -την τάση των κόμβων να μοιράζονται παρόμοια χαρακτηριστικά με τους γείτονές τους- για την εξαγωγή πληροφοριών που τα ανεξάρτητα σημεία δεδομένων θα αγνοούσαν.

3.3 Το πλαίσιο των Νευρωνικών Δικτύων Γράφων (GNNs)

Τα Νευρωνικά Δίκτυα Γράφων (GNNs) αντιπροσωπεύουν ένα κυρίαρχο και ταχέως αναπτυσσόμενο παράδειγμα βαθιάς μάθησης για δεδομένα με δομή γράφου. Πρόκειται για ένα γενικό πλαίσιο ορισμού βαθιών νευρωνικών δικτύων, ο κύριος στόχος των οποίων είναι η δημιουργία αναπαραστάσεων (embeddings) για τους κόμβους, οι οποίες εξαρτώνται άμεσα τόσο από την τοπολογία του δικτύου όσο και από τις διαθέσιμες πληροφορίες χαρακτηριστικών. Η ανάπτυξη των GNNs προέκυψε από την ανάγκη επέκτασης της βαθιάς μάθησης πέρα από τα παραδοσιακά εργαλεία τα οποία περιορίζονται στην δομή. Μέσω αυτού του πλαισίου, καθίστανται δυνατή η μάθηση και η εξαγωγή συμπερασμάτων από πολύπλοκα συστήματα, επιτρέποντας την αποτελεσματική μοντελοποίηση και κατανόηση δεδομένων σε ένα ευρύ φάσμα επιστημονικών πεδίων, από την κοινωνική δικτύωση έως τη βιολογία και τη χημεία.

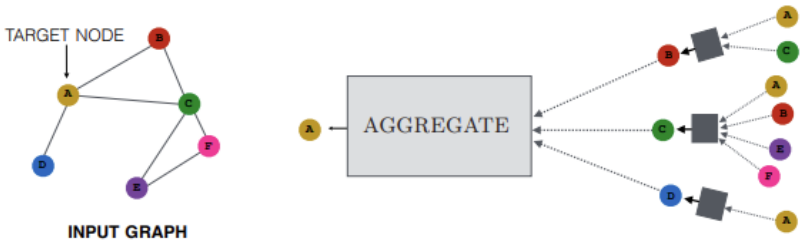
3.4 Η καινοτομία των GNNs: Σχεσιακή επαγωγική προκατάληψη (relational inductive bias)

Η θεμελιώδης πρόκληση κατά την εφαρμογή της βαθιάς μάθησης σε δίκτυα είναι ότι οι παραδοσιακές αρχιτεκτονικές, όπως τα Συνελικτικά Νευρωνικά Δίκτυα (CNNs) και οι Αναδρομικές Δομές (RNNs), είναι σχεδιασμένες για δεδομένα με αυστηρή Ευκλείδεια γεωμετρία, δηλαδή δεδομένα σε μορφή σταθερού πλέγματος (εικόνες) ή γραμμικής ακολουθίας (κείμενο). Οι γράφοι, αντίθετα, αποτελούν μη-Ευκλείδειες δομές με αυθαίρετο μέγεθος, μεταβλητή τοπολογία και έλλειψη φυσικής διάταξης, γεγονός που καθιστά αδύνατη την εφαρμογή τυπικών φίλτρων συνέλιξης. Η καινοτομία των GNNs έγκειται στην ενσωμάτωση της σχεσιακής επαγωγικής προκατάληψης (relational inductive bias). Κάθε αρχιτεκτονική μηχανικής μάθησης βασίζεται σε ένα inductive bias [30] -δηλαδή σε ένα σύνολο υποθέσεων που επιβάλλει το μοντέλο για να προβλέψει εξόδους για δεδομένα που δεν έχει ξαναδεί. Στα GNNs, η προκατάληψη αυτή υπαγορεύει ότι οι οντότητες (κόμβοι) αλληλεπιδρούν και επηρεάζονται άμεσα από την δομή των σχέσεων (ακμές) που τις περιβάλλουν. Το μοντέλο, επομένως, αναγκάζεται να αναζητήσει λύσεις που σέβονται την τοπολογία του δικτύου, θεωρώντας ότι η πληροφορία κατανέμεται και μεταδίδεται μέσω των τοπικών συνδέσεων, γεγονός που του επιτρέπει να γενικεύει αποτελεσματικά σε περίπλοκα γραφήματα. Αξίζει να σημειωθεί η διαφορά των GNNs από τις σύγχρονες αρχιτεκτονικές Transformers, οι οποίες χρησιμοποιούνται ευρέως για την εξαγωγή χαρακτηριστικών κειμένου (όπως το μοντέλο SPECTER): ενώ τα Transformers λειτουργούν ουσιαστικά ως πλήρως συνδεδεμένοι γράφοι μέσω του μηχανισμού πλήρους προσοχής (dense self-attention) εξετάζοντας κάθε στοιχείο σε σχέση με όλα τα υπόλοιπα, τα GNNs ενσωματώνουν την επαγωγική προκατάληψη (inductive bias) της τοπικότητας. Εκμεταλλεύονται την αραιή δομή του γράφου, καθιστώντας τα υπολογιστικά αποδοτικότερα και ικανότερα να μοντελοποιήσουν ρητές σχέσεις, όπως οι αναφορές μεταξύ επιστημονικών άρθρων.



Σχήμα 3.1: Τα Συνελικτικά Νευρωνικά Δίκτυα (CNNs) και οι Αναδρομικές Δομές (RNNs) σχεδιασμένες για δεδομένα με αυστηρή Ευκλείδεια γεωμετρία ενώ οι γράφοι αποτελούν μη-Ευκλείδειες δομές με αυθαίρετο μέγεθος.

3.5 Ο μηχανισμός της νευρωνικής μεταβίβασης μηνυμάτων (neural message passing)



Σχήμα 3.2: Ο μηχανισμός Neural Message Passing: Ο κόμβος-στόχος (A) συγκεντρώνει πληροφορίες από τους γείτονές του (B, C, D) μέσω της συνάρτησης AGGREGATE.

Ο πυρήνας της λειτουργίας των σύγχρονων GNNs βασίζεται στο πλαίσιο της Νευρωνικής Μεταβίβασης Μηνυμάτων, το οποίο επιτρέπει στους κόμβους να ανταλλάσσουν πληροφορίες με τους γείτονές τους. Μαθηματικά, σε κάθε επίπεδο l του δικτύου, η διαδικασία για έναν κόμβο v περιγράφεται από δύο θεμελιώδεις εξισώσεις. Αρχικά, ο κόμβος συλλέγει τα ”μηνύματα” από τους άμεσους γείτονές του μέσω μίας συνάρτησης συνάθροισης:

$$m_v^{(l+1)} = \sum_{u \in N(v)} \phi^{(l)}(h_v^{(l)}, h_u^{(l)}) \tag{3.1}$$

Όπου $N(v)$ είναι το σύνολο των γειτόνων του κόμβου v, $h_u^{(l)}$ η κρυφή αναπαράσταση (embedding) του γείτονα v στο επίπεδο l, και ϕ μία διαφορίσιμη συνάρτηση μηνύματος. Στη συνέχεια, η συσσωρευμένη πληροφορία $m_v^{(l+1)}$ συνδυάζεται με την προηγούμενη κατάσταση του ίδιου του κόμβου για να προκύψει η ενημερωμένη αναπαράστασή του, μέσω μιας συνάρτησης ενημέρωσης ψ:

$$h_v^{(l+1)} = \psi^{(l)}(h_v^{(l)}, m_v^{(l+1)}) \tag{3.2}$$

Ο μηχανισμός αυτός διέπεται από τρεις κρίσιμες μαθηματικές ιδιότητες:

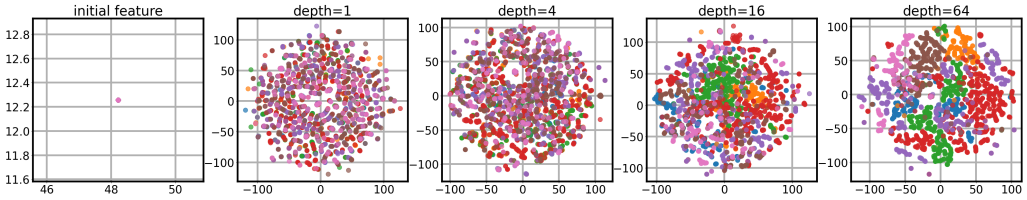
1. Ανεξαρτησία από τη σειρά των γειτόνων (permutation invariance): Η συνάρτηση AGGREGATE πρέπει να παράγει το ίδιο αποτέλεσμα ανεξάρτητα από τη σειρά με την οποία επεξεργάζεται τους γειτονικούς κόμβους, καθώς στους γράφους δεν υφίσταται προκαθορισμένη διάταξη.

2. Τοπικότητα (locality): Η ενημέρωση ενός κόμβου βασίζεται αυστηρά στην τοπική του γειτονιά. Μετά από l επίπεδα (layers), η αναπαράσταση του κόμβου έχει ενσωματώσει πληροφορίες από μια περιοχή εύρους l βημάτων (l-hop neighborhood).

3. Διαμοιρασμός παραμέτρων (parameter sharing): Οι συναρτήσεις ϕ και ψ (που υλοποιούνται συνήθως μέσω κοινών γραμμικών επιπέδων και βαρών W) είναι ίδιες για όλους τους κόμβους του γράφου, μειώνοντας δραστικά τον αριθμό των παραμέτρων και αποτρέποντας την υπερεκπαίδευση.

3.6 Θεμελιώδεις ιδιότητες και περιορισμοί

Τα GNNs παρουσιάζουν συγκεκριμένους περιορισμούς που πρέπει να λαμβάνονται υπόψη κατά τον σχεδιασμό τους. Ο σημαντικότερος περιορισμός είναι το φαινόμενο της υπερ-εξομάλυνσης (over-smoothing). Καθώς αυξάνεται ο αριθμός των επιπέδων (layers) του δικτύου, οι κόμβοι συλλέγουν μηνύματα από ολοένα και μεγαλύτερα τμήματα του γράφου. Αν το δίκτυο γίνει πολύ βαθύ, οι αναπαραστάσεις όλων των κόμβων τείνουν να συγκλίνουν σε πανομοιότυπες μαθηματικές τιμές, με αποτέλεσμα το μοντέλο να χάνει την ικανότητα να διακρίνει τις τοπικές ιδιότητες. Το πρόβλημα αυτό είναι κρίσιμο στην ανίχνευση απάτης, καθώς τα paper mills και τα καρτέλ αναφορών σχηματίζουν πυκνές αλλά τοπικά απομονωμένες κοινότητες, οι οποίες κινδυνεύουν να ”εξαφανιστούν” αν οι αναπαραστάσεις εξομαλυνθούν υπερβολικά.



Σχήμα 3.3: Μεταβολή των node embeddings σε διαφορετικά επίπεδα (layers) ενός GCN. Η απεικόνιση δείχνει την εξέλιξη των αναπαραστάσεων όταν τα χαρακτηριστικά των κόμβων αρχικοποιούνται στην ίδια τιμή. Το αποτέλεσμα υποδηλώνει ότι μια αρχιτεκτονική GCN διαθέτει την ικανότητα να «ανακάμπτει» από την κατάσταση της υπερ-εξομάλυνσης (oversmoothing) καθώς το βάθος του δικτύου αυξάνεται, αποκαθιστώντας τη διακριτική ικανότητα των embeddings.

Ένα επιπλέον ζήτημα αφορά την εκφραστική ικανότητα (expressiveness) των GNNs, η οποία σχετίζεται άμεσα με το ανώτατο θεωρητικό όριο ικανότητάς τους να ξεχωρίζουν διαφορετικές δομές γράφων. Όπως αποδεικνύεται στη σύγχρονη βιβλιογραφία, η εκφραστική ισχύς των τυπικών GNNs που βασίζονται στη μεταβίβαση μηνυμάτων περιορίζεται από το τεστ ισομορφισμού γράφων Weisfeiler-Lehman (1-WL test). Αυτό σημαίνει ότι αν δύο διαφορετικές τοπολογίες γράφων παράγουν την ίδια κατανομή χρωμάτων/μηνυμάτων κατά το WL test, ένα τυπικό GNN αδυνατεί να τις διαχωρίσει, γεγονός που επιβάλλει την προσεκτική επιλογή των αρχιτεκτονικών συνάθροισης.

3.6.1 Μετρικές Αξιολόγησης Μοντέλων Ταξινόμησης

Στα προβλήματα επιβλεπόμενης μάθησης (supervised learning - ένα παράδειγμα μηχανικής μάθησης όπου ένας αλγόριθμος εκπαιδεύεται σε δεδομένα με ετικέτα), και ειδικότερα στη δυαδική ταξινόμηση (binary classification), η αξιολόγηση της απόδοσης ενός μοντέλου δεν μπορεί να βασιστεί αποκλειστικά σε μία μετρική. Η θεμελιώδης δομή για την εξαγωγή των μετρικών αξιολόγησης είναι ο **Πίνακας Σύγχυσης (Confusion Matrix)**, ο οποίος αποτυπώνει πλήρως τη σχέση μεταξύ των πραγματικών ετικετών των δεδομένων και των προβλέψεων του μοντέλου.

Στο πλαίσιο ενός προβλήματος εντοπισμού ανωμαλιών (όπως η ανίχνευση ανακληθέντων άρθρων), ορίζουμε το προς εντοπισμό γεγονός ως τη ”Θετική” (Positive) κλάση και την κανονικότητα ως την ”Αρνητική” (Negative) κλάση. Ο πίνακας σύγχυσης παράγει τέσσερις θεμελιώδεις ποσότητες:

- **Αληθώς Θετικά (True Positives - TP):** Τα άρθρα που ήταν πράγματι ανακληθέντα και το μοντέλο τα ταξινόμησε σωστά ως ανακληθέντα.
- **Αληθώς Αρνητικά (True Negatives - TN):** Τα άρθρα που ήταν έγκυρα (κανονικά) και το μοντέλο τα ταξινόμησε σωστά ως έγκυρα.
- **Ψευδώς Θετικά (False Positives - FP):** Τα άρθρα που ήταν έγκυρα, αλλά το μοντέλο τα χαρακτήρισε λανθασμένα ως ανακληθέντα (Σφάλμα Τύπου I).
- **Ψευδώς Αρνητικά (False Negatives - FN):** Τα άρθρα που ήταν ανακληθέντα, αλλά το μοντέλο απέτυχε να τα εντοπίσει και τα χαρακτήρισε ως έγκυρα (Σφάλμα Τύπου II).

Με βάση αυτές τις τέσσερις ποσότητες, ορίζονται οι κύριες μαθηματικές μετρικές αξιολόγησης:

1. Ορθότητα (Accuracy)

Η Ορθότητα εκφράζει το ποσοστό των συνολικά σωστών προβλέψεων (τόσο για τη θετική όσο και για την αρνητική κλάση) επί του συνόλου των δεδομένων. Υπολογίζεται ως εξής:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \tag{3.3}$$

Αν και διαισθητικά αποτελεί την πιο κατανοητή μετρική, η Ορθότητα θεωρείται εξαιρετικά παραπλανητική σε μη-ισορροπημένα σύνολα δεδομένων (imbalanced datasets). Εάν, για παράδειγμα, το 99% των άρθρων ενός δικτύου είναι έγκυρα και το 1% ανακληθέντα, ένα «τυφλό» μοντέλο που προβλέπει πάντα την έγκυρη κλάση θα επιτύχει Ορθότητα 99%, έχοντας ωστόσο αποτύχει πλήρως στον πραγματικό του σκοπό.

2. Ακρίβεια (Precision)

Η Ακρίβεια ποσοτικοποιεί την ικανότητα του μοντέλου να μην παράγει Ψευδώς Θετικά (FP). Εκφράζει την αναλογία των πραγματικά θετικών δειγμάτων ως προς το σύνολο των δειγμάτων που το μοντέλο *προέβλεψε* ως θετικά:

$$\text{Precision} = \frac{TP}{TP + FP} \tag{3.4}$$

Σε ένα σύστημα ανίχνευσης απάτης, υψηλό Precision σημαίνει ότι όταν το μοντέλο προειδοποιήσει για ένα άρθρο, υπάρχει μεγάλη βεβαιότητα ότι είναι πράγματι προβληματικό, αποφεύγοντας την άδικη σπίλωση έγκυρων ερευνών.

3. Ανάκληση / Ευαισθησία (Recall / Sensitivity)

Η Ανάκληση μετράει την ικανότητα του μοντέλου να εντοπίζει όλα τα πραγματικά θετικά δείγματα, ελαχιστοποιώντας τα Ψευδώς Αρνητικά (FN). Αποτελεί την αναλογία των σωστά εντοπισμένων θετικών δειγμάτων ως προς το *σύνολο των πραγματικά* θετικών δειγμάτων:

$$\text{Recall} = \frac{TP}{TP + FN} \tag{3.5}$$

Το Recall είναι ίσως η πιο κρίσιμη μετρική σε προβλήματα όπου το κόστος της ”διαφυγής” ενός παραβάτη (False Negative) είναι υψηλό. Ένα μοντέλο με απόλυτο Recall διασφαλίζει ότι κανένα ανακληθέν άρθρο δεν έχει περάσει απαρατήρητο, ακόμα και αν αυτό κοστίσει σε μερικά παραπάνω False Positives.

4. F1-Score

Επειδή η Ακρίβεια και η Ανάκληση βρίσκονται συχνά σε σχέση αντιστρόφως ανάλογη (trade-off) —δηλαδή η βελτίωση της μίας οδηγεί στην επιδείνωση της άλλης— εισάγεται το F1-Score. Το F1-Score αποτελεί τον αρμονικό μέσο (harmonic mean) του Precision και του Recall:

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN} \tag{3.6}$$

Ο αρμονικός μέσος τιμωρεί αυστηρά τις ακραίες τιμές. Έτσι, το F1-Score θα είναι υψηλό όταν οι μετρικές *Precision* και *Recall* είναι εξίσου υψηλές. Για τον λόγο αυτό, θεωρείται η πλέον αξιόπιστη μετρική για την αξιολόγηση μοντέλων που εκπαιδεύονται σε ανισόρροπα δεδομένα.

3.7 Βασικές αρχιτεκτονικές GNN

3.7.1 Graph Convolutional Networks (GCN)

Τα Graph Convolutional Networks, που εισήχθησαν από τους Kipf και Welling [31], αποτελούν την πιο κλασσική προσέγγιση συνέλιξης σε γράφους. Η μαθηματική εξίσωση ενημέρωσης ενός κόμβου v διαμορφώνεται ως εξής:

$$\mathbf{h}_v^{(l+1)} = \sigma\left(\mathbf{W}^{(l)} \sum_{u \in \mathcal{N}(v) \cup \{v\}} \frac{1}{\sqrt{|\mathcal{N}(v)||\mathcal{N}(u)|}} \mathbf{h}_u^{(l)}\right) \tag{3.7}$$

Όπου $W^{(l)}$ είναι ο πίνακας εκπαιδεύσιμων βαρών, σ μια μη-γραμμική συνάρτηση ενεργοποίησης (π.χ. ReLU), ενώ ο όρος κάτω από το κλάσμα εκτελεί μια συμμετρική κανονικοποίηση με βάση τους βαθμούς των κόμβων, αποτρέποντας την εκρηκτική αύξηση των τιμών σε κόμβους με πάρα πολλές συνδέσεις (hubs). Ο περιορισμός των GCN έγκειται στον συγκεκριμένο τρόπο με τον οποίο διατυπώθηκε αρχικά το μοντέλο από τους Kipf και Welling: η ενημέρωση κάθε κόμβου ορίζεται μέσω μιας κανονικοποίησης που εξαρτάται από τον πλήρη, σταθερό πίνακα γειτνίασης (και τον αντίστοιχο Laplacian) ολόκληρου του γράφου. Αυτό καθιστά το πρωτότυπο GCN de facto μεταβατικό (transductive) στην πράξη, καθώς απαιτεί τη γνώση ολόκληρης της δομής του γράφου -συμπεριλαμβανομένων και των test δεδομένων- κατά την εκπαίδευση, και αδυνατεί να υπολογίσει άμεσα αναπαραστάσεις για νέους κόμβους που προστίθενται δυναμικά, χωρίς κάποια μορφή επανεκπαίδευσης ή προσαρμογής. Μεταγενέστερες εργασίες, όπως το GraphSAGE, απέδειξαν ότι η ίδια βασική λογική της νευρωνικής μεταβίβασης μηνυμάτων μπορεί να διατυπωθεί με τρόπο ανεξάρτητο από τη σταθερή τοπολογία, μέσω ρητού διαχωρισμού μεταξύ της συνάρτησης συνάθροισης (η οποία εκπαιδεύεται) και της συγκεκριμένης δομής του γράφου (η οποία απλώς παρέχει το receptive field κατά το forward pass).

3.7.2 GraphSAGE (Graph Sample and Aggregate)

Για την επίλυση των περιορισμών του GCN, οι Hamilton et al. [32] πρότειναν την αρχιτεκτονική GraphSAGE, η οποία εισάγει την επαγωγική μάθηση (inductive learning) στους γράφους. Αντί το μοντέλο να απομνημονεύει σταθερές αναπαραστάσεις, μαθαίνει γενικεύσιμες συναρτήσεις συνάθροισης πληροφορίας. Η βασική εξίσωση με τη χρήση του mean aggregator (συναρτήματος μέσου όρου) ορίζεται ως:

$$\mathbf{h}_v^{(l+1)} = \sigma\left(\mathbf{W}^{(l)} \cdot \text{CONCAT}\left(\mathbf{h}_v^{(l)}, \text{MEAN}\left(\left\{\mathbf{h}_u^{(l)} \mid u \in \mathcal{N}(v)\right\}\right)\right)\right) \tag{3.8}$$

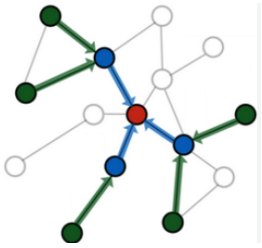
Το GraphSAGE προσφέρει τρεις διαφορετικούς aggregators (συναρτήσεις συνάθροισης):

1. Mean Aggregator: Υπολογίζει τον απλό μέσο όρο των διανυσμάτων των γειτόνων, αποτελώντας μια καθαρή και υπολογιστικά ελαφριά προσέγγιση.

2.Pooling Aggregator: Τροφοδοτεί κάθε γειτονικό διάνυσμα σε ένα πλήρως συνδεδεμένο επίπεδο και εφαρμόζει μία πράξη στοιχειακού μεγίστου (max-pooling) απομονώνοντας τα πιο κυρί-

αρχα χαρακτηριστικά της γειτονιάς.

3.LSTM Aggregator: Προσφέρει μεγαλύτερη εκφραστική ικανότητα χρησιμοποιώντας μία δομή LSTM, ωστόσο απαιτεί την τυχαία διάταξη των γειτόνων κατά την εκπαίδευση, καθώς οι LSTMs δεν είναι εκ φύσεως permutation invariant.



Σχήμα 3.4: Ο μηχανισμός Neighbor Sampling: το μοντέλο επιλέγει τυχαία έναν στα- θερό, προκαθορισμένο αριθμό γειτόνων σε κάθε επίπεδο

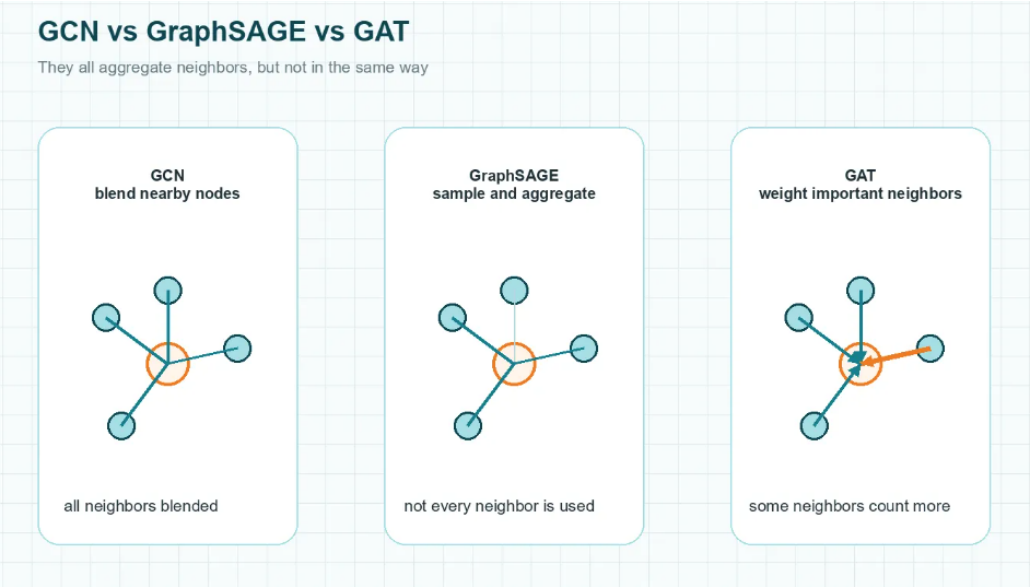
Ένα από τα πιο ισχυρά χαρακτηριστικά του GraphSAGE είναι η τεχνική του neighbor sampling (δειγματοληψία γειτόνων). Αντί να επεξεργάζεται το σύνολο των γειτόνων ενός κόμβου -κάτι που θα προκαλούσε υπολογιστική ασφυξία σε πυκνά δίκτυα- το μοντέλο επιλέγει τυχαία έναν σταθερό, προκαθορισμένο αριθμό γειτόνων σε κάθε επίπεδο. Η διαδικασία αυτή υλοποιείται μέσω εξειδικευμένων φορτωτών δεδομένων, όπως ο NeighborLoader, ο οποίος επιτρέπει την εκπαίδευση σε mini-batches και αυτή η επαγωγική φύση καθιστά το GraphSAGE ιδανικό για πραγματικές εφαρμογές.

3.7.3 Graph Attention Networks (GAT)

Η αρχιτεκτονική Graph Attention Networks [33] εισάγει τον μηχανισμό της δυναμικής προσοχής (self-attention) στις συνδέσεις του γράφου. Σε αντίθεση με το GCN και το GraphSAGE, όπου η συνεισφορά κάθε γείτονα καθορίζεται στατικά από τη δομή, το GAT επιτρέπει στο μοντέλο να ”προσέχει” περισσότερο τους κόμβους που φέρουν την πιο κρίσιμη πληροφορία. Οι συντελεστές προσοχής α_{vu}, που ορίζουν τη βαρύτητα της ακμής μεταξύ του κόμβου v και του γείτονα u, υπολογίζονται μέσω της εξίσωσης:

$$\alpha_{vu} = \frac{\exp\left(\text{LeakyReLU}\left(a^T[Wh_v \| Wh_u]\right)\right)}{\sum_{k \in N(v)} \exp\left(\text{LeakyReLU}\left(a^T[Wh_v \| Wh_k]\right)\right)} \tag{3.9}$$

Όπου W είναι ο πίνακας βαρών, a^T το διάνυσμα παραμέτρων του μηχανισμού προσοχής, ενώ το σύμβολο $\|$ αναπαριστά την πράξη της συνένωσης (concatenation). Η χρήση του LeakyReLU εξασφαλίζει τη μη-γραμμικότητα, ενώ η συνάρτηση softmax κανονικοποιεί τα βάρη σε μία κατανομή πιθανότητας πάνω σε μία γειτονιά. Το GAT επιτρέπει στο μοντέλο να απομονώνει και να αναδεικνύει μη κανονικές σχέσεις, καθιστώντας το εξαιρετικά ευέλικτο.



Σχήμα 3.5: Οι βασικές αρχιτεκτονικές GNN

3.8 Οι ετερογενείς γράφοι

Οι αρχιτεκτονικές GCN, GraphSAGE και GAT ορίζονται πάνω σε ομογενή γραφήματα, όπου όλοι οι κόμβοι και όλες οι ακμές ανήκουν σε έναν ενιαίο τύπο. Πολλά συστήματα και ειδικότερα το ακαδημαϊκό δίκτυο που μελετά η παρούσα εργασία δεν έχουν αυτή τη μορφή: περιλαμβάνουν πολλαπλούς τύπους οντοτήτων (άρθρα, συγγραφείς, επιστημονικά περιοδικά) και πολλαπλούς τύπους σχέσεων μεταξύ τους (συγγραφή, αναφορά, συνεργασία). Τα ετερογενή γραφήματα (heterogeneous graphs) αποτελούν τη γενίκευση των GNN αρχιτεκτονικών σε αυτή την περίπτωση.

3.8.1 Ορισμός

Ένα ετερογενές γράφημα ορίζεται ως μία υποκατηγορία των πολυ-σχεσιακών γραφημάτων (multi-relational graphs), στα οποία οι κόμβοι είναι εμπλουτισμένοι με συγκεκριμένους τύπους. Τυπικά, ένα ετερογενές γράφημα είναι μία πλειάδα $G = (V, E, \phi, \psi)$, όπου το συνολικό σύνολο κόμβων V διαχωρίζεται σε ξένα μεταξύ τους υποσύνολα $V = V_1 \cup V_2 \cup \cdots \cup V_k$ ανάλογα με τον τύπο κόμβου $\phi : V \to \mathcal{T}_V$ (όπου $\mathcal{T}_V$ το σύνολο των τύπων κόμβων), ενώ κάθε ακμή αντιστοιχίζεται σε έναν τύπο σχέσης μέσω της συνάρτησης $\psi : E \to \mathcal{T}_E$. Επιπλέον, κάθε τύπος κόμβου διαθέτει το δικό του διακριτό σύνολο χαρακτηριστικών εισόδου, επιτρέποντας την αποτύπωση συστημάτων με θεμελιωδώς διαφορετικά είδη οντοτήτων εντός του ίδιου γραφήματος.

3.8.2 Ετερογενής Συνέλιξη: Γενίκευση της Νευρωνικής Μεταβίβασης Μηνυμάτων

Η βασική πρόκληση στην επέκταση ενός GNN σε ετερογενές γράφημα είναι ότι ένας ενιαίος πίνακας βαρών W δεν αρκεί: η σημασιολογία μιας σχέσης `cites` είναι θεμελιωδώς διαφορετική από τη σημασιολογία μιας σχέσης `writes`, οπότε η μεταβίβαση μηνυμάτων πρέπει να διαφοροποιείται ανά τύπο σχέσης. Η προσέγγιση αυτή εισήχθη συστηματικά από τους Schlichtkrull et al. [34] με τα Relational Graph Convolutional Networks (R-GCN) και αποτελεί πλέον το κοινό θεμέλιο πάνω στο οποίο βασίζονται όλες οι σύγχρονες βιβλιοθήκες (όπως η PyTorch Geometric) για την κατασκευή ετερογενών GNN.

Στα ομογενή δίκτυα, η ενημέρωση του κόμβου v βασίζεται σε έναν ενιαίο πίνακα βαρών $W^{(l)}$ για όλους τους γείτονες, ανεξάρτητα από τη σημασιολογία της σύνδεσης:

$$h_v^{(l+1)} = \sigma\left(W^{(l)} \cdot \text{AGGREGATE}\left(h_u^{(l)}, \forall u \in \mathcal{N}(v)\right)\right) \tag{3.10}$$

Αντίθετα, στα ετερογενή γραφήματα, η συνέλιξη επεκτείνεται μαθηματικά ώστε να διασπάται ανά τύπο σχέσης $r \in \mathcal{T}_E$ (όπως writes, cites, collaborates with), εφαρμόζοντας ανεξάρτητους πίνακες βαρών $W_r^{(l)}$ ανά σχέση και συνδυάζοντας τα αποτελέσματα μέσω ενός δευτερογενούς επιπέδου συνάθροισης (π.χ., μέσου όρου).

Για έναν κόμβο-στόχο v τύπου τ και το σύνολο τύπων σχέσεων $\mathcal{R}(\tau) \subseteq \mathcal{T}_E$ που καταλήγουν σε κόμβους τύπου τ, η ενημέρωση της αναπαράστασής του στο επίπεδο $l+1$ γενικεύει την Εξίσωση 3.2 ως εξής:

$$h_v^{(l+1)} \;=\; \sigma\left(\underbrace{\sum_{r\in\mathcal{R}(\tau)} \frac{1}{|\mathcal{N}_r(v)|} \sum_{u\in\mathcal{N}_r(v)} W_r^{(l)}\, h_u^{(l)}}_{\text{συνάθροιση ανά σχέση } r} \;+\; W_{\text{self}}^{(l)}\, h_v^{(l)}\right) \tag{3.11}$$

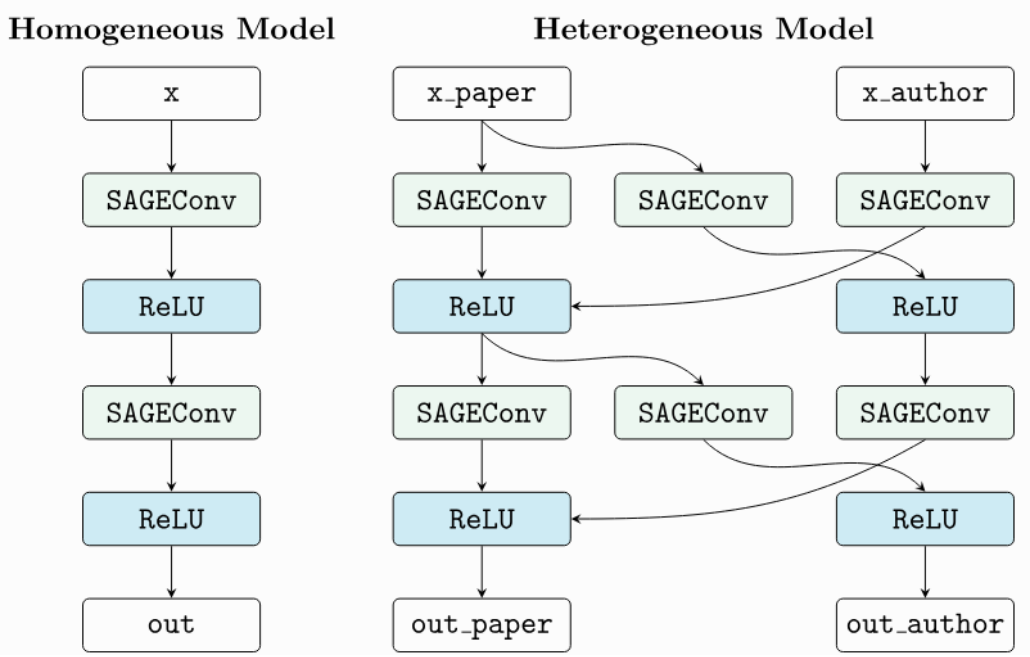
όπου $\mathcal{N}_r(v)$ είναι οι γείτονες του v ειδικά μέσω σχέσης τύπου r, και $W_r^{(l)}$ ο πίνακας βαρών **που αντιστοιχεί αποκλειστικά στη σχέση** r στο επίπεδο l — διαφορετικός για κάθε τύπο σχέσης, σε αντίθεση με το ομογενές GNN όπου υπάρχει ένας μόνο κοινός πίνακας $W^{(l)}$. Ο όρος $W_{\text{self}}^{(l)} h_v^{(l)}$ αντιστοιχεί σε αυτο-σύνδεση (self-loop), διατηρώντας πληροφορία από την προηγούμενη κατάσταση του ίδιου του κόμβου. Η Εξίσωση 3.11 αποτελεί την *κατευθυντήρια* μορφή της ετερογενούς συνέλιξης· κάθε συγκεκριμένη αρχιτεκτονική (R-GCN, HAN, HGT, ή ετερογενής GraphSAGE) διαφοροποιείται ως προς τον ακριβή τύπο συνάθροισης εντός κάθε σχέσης r (π.χ. mean, sum, attention) και ως προς τον τρόπο συνδυασμού των επιμέρους αθροισμάτων ανά σχέση.

Μία άμεση συνέπεια της Εξίσωσης 3.11 είναι ότι ο συνολικός αριθμός εκπαιδεύσιμων παραμέτρων ενός ετερογενούς GNN κλιμακώνεται γραμμικά με τον αριθμό των τύπων σχέσεων $|\mathcal{T}_E|$, αφού απαιτείται ένας ξεχωριστός πίνακας W_r ανά σχέση και ανά επίπεδο. Σε γραφήματα με πολλούς τύπους σχέσεων, αυτό μπορεί να οδηγήσει σε υπερβολικό αριθμό παραμέτρων και κίνδυνο υπερεκπαίδευσης, ειδικά για σχέσεις με λίγες ακμές. Η βασική τεχνική αντιμετώπισης είναι η *αποσύνθεση βάσης* (basis decomposition), όπου όλοι οι πίνακες W_r εκφράζονται ως γραμμικοί

συνδυασμοί ενός μικρού, κοινού συνόλου βάσεων πινάκων, μειώνοντας δραστικά τον αριθμό των ανεξάρτητων παραμέτρων.

3.8.3 Ανεξαρτησία Τύπων Χαρακτηριστικών

Πέρα από τη διαφοροποίηση των βαρών ανά σχέση, το ετερογενές πλαίσιο επιτρέπει επίσης κάθε τύπο κόμβου να έχει εντελώς διαφορετική διάσταση χαρακτηριστικών εισόδου $x_u \in \mathbb{R}^{d_\tau}$, όπου η διάσταση d_τ εξαρτάται από τον τύπο τ. Αυτό επιτυγχάνεται στην πράξη μέσω *οκνηρής αρχικοποίησης* (lazy initialization) των πινάκων W_r, οι οποίοι συνάγουν τις διαστάσεις εισόδου τους αυτόματα κατά το πρώτο forward pass, ξεχωριστά για κάθε σχέση.



Σχήμα 3.6: Η διαδικασία λαμβάνει ένα υπάρχον μοντέλο GNN και αντιγράφει τις συναρτήσεις μηνυμάτων για να λειτουργήσει σε κάθε τύπο ακμής ξεχωριστά.

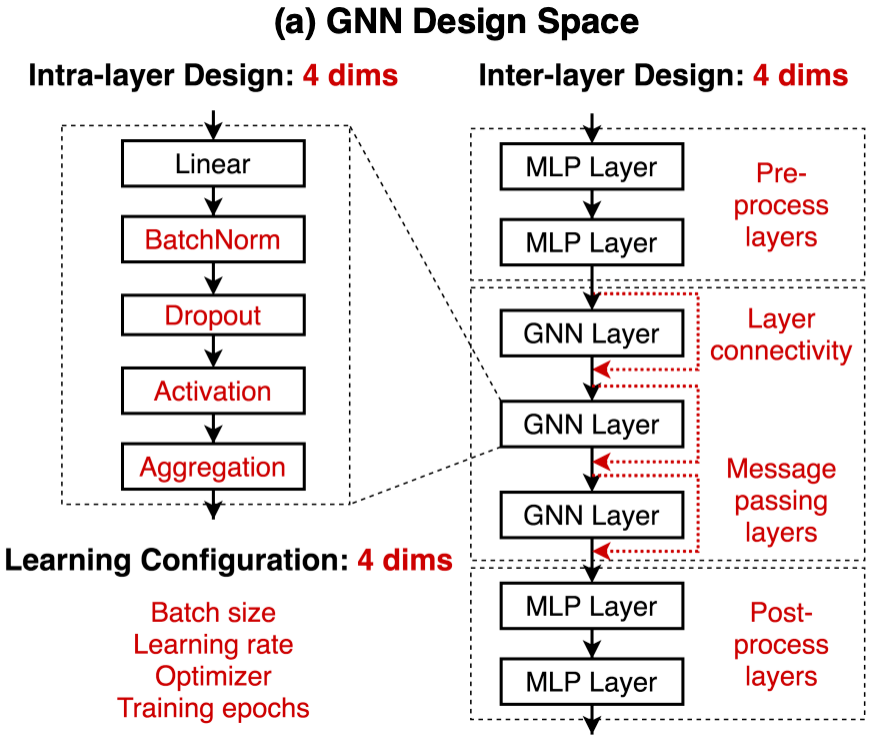
3.9 Ο χώρος σχεδιασμού των GNNs

Η αρχιτεκτονική ενός GNN μπορεί να αναλυθεί σε έναν δομημένο χώρο σχεδιασμού (design space), ο οποίος κατηγοριοποιεί τις επιλογές μοντελοποίησης σε τρεις βασικούς άξονες:

- Ενδο-επιπεδικός σχεδιασμός (intra-layer design): Αφορά την εσωτερική δομή ενός μεμονωμένου επιπέδου GNN. Περιλαμβάνει τη γραμμική μετατροπή των χαρακτηριστικών (Linear), τη χρήση μηχανισμών κανονικοποίησης (όπως Batch Normalization), τεχνικές αποφυγής υπερεκπαίδευσης (όπως dropout), τη μη-γραμμική συνάρτηση ενεργοποίησης (Activation, όπως η συνάρτηση ReLU) και φυσικά τη στρατηγική συνάθροισης των μηνυμάτων της γειτονιάς (aggregation, π.χ. mean, sum, max).

- Δια-επιπεδικός σχεδιασμός (inter-layer design): Καθορίζει τη μακρο-αρχιτεκτονική του δικτύου. Περιλαμβάνει το πλήθος των επιπέδων επεξεργασίας (Message passing layers), τη στρατηγική σύνδεσης μεταξύ τους (π.χ. skip/residual connections για την αποφυγή απώλειας πληροφορίας σε βαθιά δίκτυα), καθώς και τεχνικές συγκέντρωσης πληροφορίας (graph pooling/readout) που καθορίζουν αν η μάθηση αφορά μεμονωμένους κόμβους ή ολόκληρο τον γράφο. Επιπλέον, καλύπτει τη χρήση πλήρως συνδεδεμένων νευρωνικών δικτύων (MLPs) για την προ-επεξεργασία (pre-processing) των αρχικών χαρακτηριστικών ή την τελική ταξινόμηση (post-processing) των εξαχθέντων αναπαραστάσεων.

-Ρυθμίσεις εκπαίδευσης (learning configuration): Αφορά τις υπερπαραμέτρους που καθορίζουν τη διαδικασία βελτιστοποίησης του μοντέλου, ανεξάρτητα από την τοπολογία του. Εδώ περιλαμβάνονται τα εξής: το μέγεθος της δεσμίδας (batch size), ο ρυθμός μάθησης (learning rate), ο αλγόριθμος βελτιστοποίησης (optimizer) και ο συνολικός αριθμός εποχών (training epochs).



Σχήμα 3.7: Ο χώρος σχεδιασμού των GNNs

3.10 Εφαρμογές GNNs σε επιστημονικά γραφήματα

Η αποτελεσματικότητα των GNNs στην ανάλυση ακαδημαϊκών δεδομένων έχει δοκιμαστεί εκτενώς σε κλασσικά σύνολα δεδομένων αναφορών, όπως τα Cora, Citeseer και PubMed, όπου χρησιμοποιούνται παραδοσιακά για την κατηγοριοποίηση άρθρων με βάση το θεματικό τους πεδίο. Ωστόσο, η σύγχρονη έρευνα έχει στρέψει το ενδιαφέρον της στην ανίχνευση κακόβουλων συμπεριφορών. Μοντέλα όπως το PDCN [12] απέδειξαν ότι η μελέτη των ετερογενών σχέσεων και των δικτύων χειραγώγησης αναφορών μπορεί να αποκαλύψει τη δομημένη δραστηριότητα των Paper mills.

Παράλληλα, προσεγγίσεις όπως το CIDRE και μελέτες [20] επικεντρώνονται στον εντοπισμό ανώμαλων συστάδων συγγραφής, αναδεικνύοντας ότι οι οργανωμένες απάτες χαρακτηρίζονται από ασυνήθιστα χαμηλό συντελεστή ομαδοποίησης (clustering coefficient), γεγονός που υποδηλώνει καθαρά εμπορικές και συναλλακτικές σχέσεις αντί για αυθεντικές επιστημονικές συνεργασίες. Στον αντίποδα, έρευνες που στοχεύουν ρητά στην πρόβλεψη της ανάκλησης (retraction prediction) [35] βασίζονται κατά κύριο λόγο σε παραδοσιακά μοντέλα μηχανικής μάθησης και Μεγάλα Γλωσσικά Μοντέλα (LLMs), εξετάζοντας τα κείμενα ως ανεξάρτητες και απομονωμένες μονάδες πληροφορίας.

3.11 Το ερευνητικό κενό και η συμβολή της διπλωματικής εργασίας

Συνοψίζοντας, η ανασκόπηση της σύγχρονης βιβλιογραφίας αναδεικνύει ένα σαφές ερευνητικό κενό στην υπολογιστική αντιμετώπιση της ακαδημαϊκής απάτης. Από τη μία πλευρά, οι υπάρχουσες δομικές προσεγγίσεις με Νευρωνικά Δίκτυα Γράφων εστιάζουν σχεδόν αποκλειστικά στον εντοπισμό οργανωμένων δικτύων παραγωγής ψευδών επιστημονικών άρθρων (paper mills). Από την άλλη πλευρά, οι μελέτες που στοχεύουν στην πρόβλεψη ανακλήσεων περιορίζονται σε κειμενικά ή απλά βιβλιομετρικά χαρακτηριστικά, αγνοώντας πλήρως την τοπολογία του δικτύου αναφορών. Η παρούσα διπλωματική εργασία εισάγει μια διαφοροποιημένη προσέγγιση: προτείνει ένα επαγωγικό μοντέλο GraphSAGE εκπαιδευμένο σε έναν ετερογενή γράφο 6.190 άρθρων (με κόμβους άρθρων,συγγραφέων, περιοδικών, πανεπιστημίων, χωρών), το οποίο συνδυάζει τη δομική πληροφορία του δικτύου με εξειδικευμένα σημασιολογικά SPECTER 2 embeddings, για την άμεση και προληπτική πρόβλεψη της ανάκλησης άρθρων.

Κεφάλαιο 4

Δημιουργία κατάλληλου dataset

4.1 Επισκόπηση και αξιολόγηση υπαρχόντων συνόλων δεδομένων

Η έρευνα για την ανίχνευση και την πρόβλεψη ανακλήσεων επιστημονικών άρθρων αποτελεί πλέον έναν από τους πιο κρίσιμους πυλώνες για τη διασφάλιση της ακαδημαϊκής ακεραιότητας, καθώς το οικοσύστημα των επιστημονικών δημοσιεύσεων αντιμετωπίζει μια άνευ προηγουμένου κλιμάκωση της χειραγώγησης. Η πρόοδος στο πεδίο αυτό βασίζεται σε ένα αυξανόμενο, αν και ακόμη περιορισμένο, σύνολο βιβλιογραφικών πηγών. Ακολουθεί μια συνοπτική και κατηγοριοποιημένη παρουσίαση των κυριότερων συνόλων δεδομένων που έχουν χρησιμοποιηθεί στη διεθνή βιβλιογραφία.

4.1.1 Βάσεις δεδομένων ανακλήσεων άρθρων

- **Retraction Watch Database (Crossref) [36]:** Αποτελεί την εκτενέστερη, συνεχώς ενημερωμένη συλλογή ανακλήσεων παγκοσμίως, περιλαμβάνοντας πάνω από 50.000 εγγραφές από τη δεκαετία του 1970 έως σήμερα. Κάθε εγγραφή περιέχει μεταδεδομένα όπως τίτλο, περιοδικό, εκδότη, ημερομηνία και αιτία ανάκλησης, αποτελώντας την πρωτογενή πηγή για τη συντριπτική πλειονότητα των μελετών. Η βάση αυτή κατηγοριοποιεί τους λόγους ανάκλησης άρθρων, γεγονός που αποτελεί σημαντική προσθήκη στην εκπαίδευση μοντέλων μηχανικής μάθησης. Οι λόγοι ανάκλησης μπορεί να είναι εκούσια χειραγώγηση, όπως πλαστογραφία δεδομένων (fabrication), παραποίηση αποτελεσμάτων (falsification) και λογοκλοπή (plagiarism), είτε ακούσια σφάλματα όπως λάθη σε αναλύσεις, στατιστικές ανακρίβειες και προβληματικές εικόνες.

4.1.2 Datasets πρόβλεψης ανακλήσεων

- **BMDetect - BioMCD Dataset [37]:** Εστιάζει στον εντοπισμό παραπτωμάτων σε 66.571 άρθρα, επιτυγχάνοντας AUC 74.33%. Το σύνολο αυτό είναι ιδιαίτερα χρήσιμο καθώς διαχωρίζει τις αιτίες ανάκλησης, βοηθώντας στην εκπαίδευση μοντέλων που στοχεύουν σε συγκεκριμένους τύπους ακαδημαϊκής ανεντιμότητας. Πρόκειται για ένα από τα πιο εξειδικευμένα σύνολα δεδομένων στον τομέα της βιοϊατρικής, το οποίο διαχωρίζει τις ανακλήσεις βάσει της αιτιολογίας τους. Η υψηλή απόδοση AUC υπογραμμίζει τη σημασία της πολυτροπικής προσέγγισης, όπου ο συνδυασμός γλωσσικών μοντέλων (LLMs) και ταξινομητών τύπου Gradient Boosted Trees αποδεικνύεται ανώτερος από μεμονωμένες στατιστικές μεθόδους. Το dataset αυτό είναι καθοριστικό για την ανάπτυξη προληπτικών μηχανισμών που αξιολογούν τον κίνδυνο πρόκλησης "ακαδημαϊκής βλάβης" (citation harm) πριν την αναφορά ενός άρθρου.

- **Fletcher & Stevenson [38] :** Πρόκειται για μια μελέτη με 9.028 άρθρα (2000–2020), όπου χρησιμοποιείται διαδικασία αντιστοίχισης (matching) δηλαδή κάθε ανακληθέν άρθρο αντιστοιχίζεται με ένα έγκυρο, δημοσιευμένο την ίδια περίοδο, επιλύοντας το πρόβλημα της χρονικής μεροληψίας (temporal bias). Τα αποτελέσματα της μελέτης αποδεικνύουν ότι τα μοντέλα που βασίζονται σε χαρακτηριστικά (feature-based classifiers) παραμένουν ανταγωνιστικά, ενώ η χρήση προηγμένων μοντέλων όπως το Llama 3.2 προσφέρει αυξημένη ακρίβεια στην αναγνώριση προβληματικών δημοσιεύσεων. Η σύγκλιση μεταξύ στατιστικών μεθόδων και contextual embeddings αποτελεί την καλύτερη λύση για την αυτόματη υποστήριξη της διαδικασίας peer-review.

4.1.3 Σύνολα δεδομένων για αποσύρσεις και χειραγώγηση εικόνων

- **WithdrarXiv [39]:** Το πρώτο μεγάλης κλίμακας dataset αποσύρσεων από το arXiv, με πάνω από 14.000 χειρόγραφα και λεπτομερή ταξινόμηση 10 κατηγοριών. Η διαθεσιμότητα των σχολίων απόσυρσης καθιστά το σύνολο αυτό μοναδικό για τη μελέτη της εξέλιξης των σφαλμάτων στη ροή της προδημοσίευσης, όπου η απουσία επίσημης αξιολόγησης καθιστά την χειραγώγηση πιο εύκολη. Η εμφάνιση αναφορών σε ανύπαρκτες πηγές (hallucinated citations) από LLMs αποτελεί νέα πρόκληση, καθιστώντας την ανάγκη για datasets όπως το WithdrarXiv πιο επίκαιρη από ποτέ.

- **BioFors [40]:** Αυτό το εξειδικευμένο σύνολο δεδομένων χρησιμοποιείται για την εκπαίδευση αλγορίθμων στην ανίχνευση ψηφιακά παραποιημένων επιστημονικών εικόνων. Περιλαμβάνει ποικιλία βιοϊατρικών απεικονίσεων, όπως ιστολογικές τομές, με τεκμηριωμένα παραδείγματα αλλοιώσεων, όπως αντιγραφές ή συνθέσεις. Υπάρχει διότι τα γενικά εργαλεία ανίχνευσης αποτυγχάνουν να εντοπίσουν τις εξελιγμένες τεχνικές παραποίησης που χρησιμοποιούν τα paper mills για να κατασκευάσουν ψευδή πειραματικά δεδομένα. Η ύπαρξή τους κρίνεται απαραίτητη ώστε οι ερευνητές να αναπτύσσουν εξειδικευμένα μοντέλα ικανά να αναγνωρίζουν τα ιδιαίτερα οπτικά χαρακτηριστικά της βιοϊατρικής απά-

της. Τελικός στόχος είναι η προστασία της επιστημονικής ακεραιότητας μέσω της αυτόματης επαλήθευσης των οπτικών αποτελεσμάτων κατά τη διαδικασία αξιολόγησης άρθρων.

4.1.4 Λοιπά σύνολα δεδομένων

- **Google Scholar is manipulatable [15]** Αποτελεί έρευνα που αποδεικνύει την αδυναμία των βιβλιομετρικών δεικτών, συλλέγοντας πάνω από 1,6 εκατομμύρια προφίλ του Google Scholar και αποκαλύπτοντας υπηρεσίες αγοράς αναφορών (citation purchasing). Παρότι η μελέτη επιβεβαιώνει τη δομική φύση της χειραγώγησης, το dataset τους δεν είναι δημόσια διαθέσιμο.

4.2 Η ανάγκη δημιουργίας νέου συνόλου δεδομένων

Κατά την ανασκόπηση της βιβλιογραφίας, διαπιστώθηκε ότι δεν υπάρχει δημόσια διαθέσιμο σύνολο δεδομένων που να συνδυάζει ταυτόχρονα τα ανακληθέντα άρθρα με την πλήρη τοπολογία του δικτύου αναφοράς τους. Από την επισκόπηση των υπαρχουσών πηγών προκύπτει ότι κανένα από τα γνωστά σύνολα δεδομένων δεν διαθέτει δομημένη πληροφορία τοπολογίας δικτύου κατάλληλη για την εκπαίδευση Νευρωνικών Δικτύων Γράφων (GNNs). Η πλειονότητα των ερευνών περιορίζεται σε πίνακες χαρακτηριστικών (feature matrices) χωρίς ρητές ακμές σχέσεων, ενώ ακόμη και οι μελέτες που ενσωματώνουν κάποια μορφή δικτυακής δομής, όπως το WithdrarXiv, δεν περιλαμβάνουν ετερογενείς οντότητες (π.χ. συγγραφείς, περιοδικά, ιδρύματα) που είναι απαραίτητες για ανάλυση.

Το κενό αυτό καθιστά αναγκαία τη δημιουργία ενός νέου συνόλου δεδομένων που να ενσωματώνει ταυτόχρονα ανακληθέντα άρθρα, πλήρη τοπολογία αναφορών και πολλαπλούς τύπους κόμβων. Προκειμένου η εργασία να βασιστεί σε ένα ήδη ελεγμένο πλαίσιο, πραγματοποιήθηκε επικοινωνία με τους συγγραφείς της μελέτης «Google Scholar is manipulatable» [15] για την παραχώρηση του συνόλου δεδομένων τους, καθώς περιελάμβανε καταγεγραμμένες περιπτώσεις συγγραφέων που είχαν εξαγοράσει εικονικές αναφορές μέσω οργανωμένων δικτύων απάτης. Ωστόσο, το αίτημα απορρίφθηκε για λόγους προστασίας της ιδιωτικότητας των εμπλεκόμενων μερών. Η απουσία ενός έτοιμου και προσπελάσιμου dataset σε συνδυασμό με την ανάγκη για ετερογενή δομή, κατέστησε επιτακτική τη δημιουργία ενός νέου συνόλου δεδομένων, το οποίο περιγράφεται αναλυτικά στις επόμενες ενότητες και θα λειτουργήσει ως η θεμελιώδης βάση για την εκπαίδευση των GNN μοντέλων που προτείνονται στην παρούσα εργασία.

4.3 Αρχική προσέγγιση συλλογής δεδομένων: δομικοί περιορισμοί και αναθεώρηση

Η κατασκευή του συνόλου δεδομένων υλοποιήθηκε στο υπολογιστικό περιβάλλον Google Colab με χρήση της γλώσσας Python. Αρχικά, η στρατηγική βασίστηκε στη διερεύνηση προϋπαρχουσών λύσεων και συγκεκριμένα στην αξιοποίηση του "Citation Network Dataset" [41] από την πλατφόρμα του Kaggle. Η αρχική προσέγγιση αποσκοπούσε στη διασταύρωση των ανακληθέντων άρθρων από το αποθετήριο του Retraction Watch [36] με τον εν λόγω έτοιμο γράφο, ώστε να χαρτογραφηθούν οι μεταξύ τους σύνδεσμοι και να εξαχθεί η δικτυακή τοπολογία.

Ωστόσο, κατά την εκτέλεση του αλγορίθμου αναζήτησης σε ένα πρώτο δείγμα 500.000 άρθρων, διαπιστώθηκε εξαιρετικά χαμηλή επικάλυψη, καθώς εντοπίστηκαν μόλις 14 κοινά στοιχεία. Η αποτυχία αυτή ανέδειξε έναν σημαντικό δομικό περιορισμό: τα περισσότερα δημόσια και στατικά ακαδημαϊκά datasets (όπως το DBLP, στο οποίο βασιζόταν η βάση του Kaggle) περιορίζονται αυστηρά στον τομέα της Πληροφορικής. Αντίθετα, η βιομηχανοποιημένη επιστημονική απάτη και τα οργανωμένα δίκτυα ψευδών δημοσιεύσεων (paper mills) πλήττουν ευρύτερα επιστημονικά πεδία, όπως η Ιατρική, η Χημεία και η Βιολογία. Η διαπίστωση αυτή κατέστησε σαφές ότι τα στατικά μητρώα ήταν ανεπαρκή για τους σκοπούς της παρούσας έρευνας, επιβάλλοντας τη στροφή στην πλατφόρμα του OpenAlex για τη δυναμική ανάκτηση και κατασκευή του δικτύου αναφορών.

4.4 Εξόρυξη δικτυακής τοπολογίας

Για το τελικό dataset χρειάστηκαν δύο σημαντικές πηγές: η βάση του Crossref (μέσω Retraction Watch) και η πλατφόρμα του OpenAlex. Έτσι κάθε ανακληθέν άρθρο από την βάση Retraction Watch ταυτοποιείται στον βιβλιογραφικό κατάλογο του OpenAlex και εξάγεται η απαραίτητη πληροφορία. Ειδικότερα, για κάθε έγκυρο DOI από την βάση crossref πραγματοποιούνται κλήσεις API στο OpenAlex χρησιμοποιώντας την βιβλιοθήκη `pyalex`. Όταν το άρθρο ταυτοποιηθεί επιτυχώς, το API επιστρέφει ένα δομημένο αντικείμενο τύπου JSON, από το οποίο εξάγονται τα απαραίτητα στοιχεία για χαρτογράφηση της δικτυακής τοπολογίας ενός ετερογενούς γράφου. Τα αναγνωρισμένα άρθρα και οι ερευνητές ορίζονται ως διακριτοί τύποι κόμβων του δικτύου. Οι τοπολογικές συνδέσεις (ακμές) προκύπτουν αφενός από τις πληροφορίες του συγγραφέα, συνδέοντας συγγραφείς με τα έργα τους, και αφετέρου από τη λίστα των βιβλιογραφικών παραπομπών (referenced works), η οποία διαμόρφωσε το δίκτυο αναφορών μεταξύ των άρθρων.

4.5 Ανάκτηση και ανακατασκευή περιλήψεων (abstracts)

Η εξασφάλιση της κειμενικής πληροφορίας των περιλήψεων (abstracts) πραγματοποιήθηκε με ομαδικές κλήσεις (batching) στο OpenAlex με την πλατφόρμα να επιστρέφει τα δεδομένα σε μορφή ανεστραμμένου ευρετηρίου (abstract inverted index). Για τον λόγο αυτό, έπρεπε να γίνει ανακατασκευή του κειμένου σύμφωνα με τις θέσεις των λέξεων ώστε να αποκατασταθεί η αρ-

χική δομή του abstract. Σε περιπτώσεις όπου η περίληψη απουσίαζε από OpenAlex, η σχετική πληροφορία εξαγόταν από την βάση δεδομένων retraction watch database. Στην συνέχεια τα ανακατασκευασμένα κείμενα τροφοδότησαν το προεκπαιδευμένο γλωσσικό μοντέλο SPECTER 2 μέσω της βιβλιοθήκης `sentence-transformers`. Η διαδικασία μετατροπής (encoding) παρήγαγε για κάθε κόμβο-άρθρο του γράφου ένα πυκνό σημασιολογικό διάνυσμα (embedding) 768 διαστάσεων, το οποίο συμπυκνώνει τη θεματική συνάφεια των άρθρων. Ο τελικός πίνακας διανυσμάτων αποθηκεύτηκε σε μορφή τανυστή PyTorch (`.pt`), αποτελώντας το βασικό κειμενικό χαρακτηριστικό (node feature) των άρθρων για την εκπαίδευση του νευρωνικού δικτύου γράφων.

4.6 Δομή και χαρακτηριστικά τελικής έκδοσης dataset

Κατά τη διαδικασία προεπεξεργασίας, το σύνολο δεδομένων (dataset.csv) υποβλήθηκε σε εξισορρόπηση κλάσεων μέσω υποδειγματοληψίας των εγκύρων άρθρων, επιτυγχάνοντας μια αναλογία 50% έγκυρων προς 50% ανακληθέντων άρθρων, λαμβάνοντας υπόψη τον χρόνο δημοσίευσης και το επιστημονικό περιοδικό για τη διασφάλιση της αντιπροσωπευτικότητας. Η παρέμβαση αυτή κρίθηκε απαραίτητη, δεδομένου ότι η φυσική κατανομή του γράφου περιλαμβάνει μόλις 0.95% ποσοστό ανακληθέντων άρθρων· χωρίς την εξισορρόπηση αυτή, το μοντέλο θα παρουσίαζε μεροληψία υπέρ της πλειοψηφικής κλάσης, επιτυγχάνοντας υψηλή συνολική ορθότητα (Accuracy) αλλά αδυνατώντας να αναγνωρίσει αποτελεσματικά τα χαρακτηριστικά της απάτης. Διευκρινίζεται ότι η διαδικασία αυτή εφαρμόστηκε με αυστηρό διαχωρισμό, διασφαλίζοντας ότι δεν υφίσταται διαρροή πληροφορίας (data leakage) από το σύνολο ελέγχου στο σύνολο εκπαίδευσης, καθώς η εξισορρόπηση αφορά αποκλειστικά την ποσοστιαία κατανομή των δειγμάτων και δεν μεταβάλλει την τοπολογική ακεραιότητα του γράφου. Κάθε εγγραφή στο αρχείο αντιπροσωπεύει έναν κόμβο-άρθρο και περιλαμβάνει τα εξής χαρακτηριστικά: `count` (για αρίθμηση στο dataset), `label`, `id`, `doi`, `title`, `authors`, `orcid`, `reasons`, `references`, `cited_by_count`, `counts_by_year`, `cited_by_percentile_year`, `abstract`, `journal`. Το label είναι η ετικέτα ταξινόμησης και αποτελεί μία δυαδική μεταβλητή (1 για ανακληθέν, 0 αλλιώς) που είναι και ο στόχος πρόβλεψης. Το id (OpenAlex) και doi είναι τα μοναδικά χαρακτηριστικά του άρθρου που ταυτοποιούν τον κόμβο του. Το title και abstract είναι τα κειμενικά μεταδεδομένα του άρθρου. Το orcid είναι ένα μοναδικό αναγνωριστικό για τους συγγραφείς (authors). Επιπροσθέτως για τους συγγραφείς συγκρατείται το πανεπιστήμιο και η χώρα. Αντλείται η πληροφορία για τον λόγο ανάκλησης και μία λίστα από τις αναφορές σε άλλα άρθρα, τα εξωτερικά άρθρα αυτού του dataset. Τα πεδία cited by count, counts by year, cited by percentile year είναι δείκτες που μετρούν την απήχηση του άρθρου όσον αφορά τον συνολικό αριθμό αναφορών, την κατανομή των αναφορών ανά έτος και την εκατοστιαία κατάταξη βάσει αναφορών συγκριτικά με όλα τα υπόλοιπα άρθρα της ίδιας χρονιάς.

4.7 Από το αρχείο dataset.csv σε ετερογενή γράφο

Το αρχείο dataset.csv είναι μία συλλογή σε μορφή πίνακα 6.190 εγγραφών, όπου η κάθε μία αποτελεί ένα επιστημονικό άρθρο με τα μεταδεδομένα του. Ο ετερογενής γράφος κατασκευάζεται από αυτό το αρχείο το οποίο επεξεργάζεται και κάθε εγγραφή αποτελεί πολλαπλούς κόμβους αλλά και ακμές -οι συγγραφείς γίνονται ανεξάρτητοι κόμβοι, οι αναφορές των βασικών άρθρων εισάγουν νέους (”εξωτερικούς”) κόμβους-άρθρα. Το αποτέλεσμα είναι ένας γράφος με 351.805 κόμβους και 1.046.578 ακμές.

4.7.1 Κόμβοι γράφου

Πίνακας 4.1: Ανάλυση τύπων κόμβων στο δίκτυο (HeteroData)

Τύπος κόμβου	**Όνομα στο PyG**	**Πλήθος**	**Πηγή**	**Χαρακτηριστικά**
Βασικό άρθρο	`paper`	6.190	dataset.csv	embeddings + βιβλιομετρικά
Άρθρο (εξωτερικό)	`paper`	325.115	references	Μηδενικά
Συγγραφέας	`author`	26.690	Regex	Δυαδικό ORCID
Σύνολο κόμβων		**357.995**		

Πίνακας 4.2: Μέσος βαθμός συνδεσιμότητας ανά τύπο κόμβου

Τύπος Κόμβου	**Μέσος Βαθμός (Average Degree)**
Βασικά άρθρα	129.77
Άρθρα (Βιβλιογραφίας)	1.12
Συγγραφείς (Σύνολο)	11.44

Ο υψηλός μέσος βαθμός των βασικών άρθρων οφείλεται στον αυξημένο αριθμό αναφορών σε άλλα άρθρα (πεδίο references) και έτσι το μοντέλο λαμβάνει πληροφορία από πολλούς γείτονες του άρθρου. Σε αντίθεση, τα άρθρα-references (εξωτερικά) αποτελούν ”φύλλα” (leaf nodes) στον ετερογενή γράφο καθώς έχουν μία σύνδεση με το βασικό άρθρο. Επειδή δεν έχουν πλούσια συνδεσιμότητα, η χρήση τους περιορίζεται στην υποστήριξη της δομής του γράφου. Όσον αφορά τον μέσο βαθμό των συγγραφέων, αυτός μας δείχνει πως η τοπολογική πληροφορία που δίνουν οι ακμές των συγγραφέων, είτε είναι σύνδεση συγγραφής άρθρου είτε είναι σύνδεση με άλλον συγγραφέα, μπορεί να εντοπίσει τα paper mills ή τις ύποπτες ομάδες συγγραφέων.

4.7.2 Ακμές γράφου

Στον ετερογενή γράφο εμφανίζονται οι εξής ακμές:

1. Σχέση Συγγραφής (`'author','writes','paper'`): εξάγεται από το πεδίο authors. Μέσω κανονικών εκφράσεων (Regex) απομονώνεται το όνομα, το ίδρυμα και η χώρα του συγγραφέα. Αν ο συγγραφέας εμφανίζεται για πρώτη φορά, εισάγεται στο λεξικό author mapping και αποκτά ένα μοναδικό αριθμητικό ID. Για κάθε συγγραφέα, δημιουργείται μια κατευθυνόμενη ακμή προς το άρθρο που συνέγραψε. Για την εξασφάλιση της αμφίδρομης ροής μηνυμάτων, κατασκευάζεται και η ανάστροφη ακμή (`'paper','written by','author'`).

2. Δίκτυο αναφορών (`'paper', 'cites', 'paper'`): προκύπτει από τη στήλη references, όπου τα IDs των αναφορών διαχωρίζονται με ελληνικό ερωτηματικό (;). Αν μία αναφορά αφορά άρθρο εκτός του αρχικού dataset των 6.190 άρθρων, το άρθρο αυτό προστίθεται δυναμικά ως ”εξωτερικός κόμβος” στο `paper mapping`. Η σύνδεση δηλώνει την κατευθυνόμενη ροή από το τρέχον άρθρο προς το άρθρο αναφοράς και εισάγεται κι η ανάστροφη σχέση (`'paper','cited by','paper'`).

3. Συνεργασία συγγραφέων (`'author','collaborates with','author'`): κατασκευάζεται με την ανάλυση του λεξικού `paper to authors`. Για κάθε άρθρο με περισσότερους από έναν συγγραφείς, χρησιμοποιείται η συνάρτηση combinations για τη δημιουργία όλων των πιθανών ζευγαριών συνεργασίας. Η σχέση αυτή είναι συμμετρική και αμφίδρομη. Η ακμή συν-συγγραφής υλοποιείται ως μία ενιαία, αμφίδρομη σύνδεση, καθώς εκφράζει μια εγγενώς συμμετρική σχέση μεταξύ κόμβων του ίδιου τύπου (author), καθιστώντας περιττό τον ορισμό αντίστροφης ακμής, σε αντίθεση με τις ετερογενείς συνδέσεις.

4. Σύζευξη βιβλιογραφίας (`'paper', 'shares refs with', 'paper'`): υλοποιεί την τεχνική του top-k bibliographic coupling. Οι λίστες αναφορών μετατρέπονται σε έναν αραιό πίνακα (sparse matrix) με τη χρήση του CountVectorizer. Το εσωτερικό γινόμενο του πίνακα με τον ανάστροφό του παράγει ένα μητρώο όπου κάθε στοιχείο δηλώνει τον αριθμό των κοινών αναφορών μεταξύ των άρθρων. Με τη χρήση της συνάρτησης `torch.topk`, επιλέγονται οι 5 κορυφαίοι γείτονες για κάθε άρθρο. Ακμή δημιουργείται μόνο αν δύο άρθρα μοιράζονται τουλάχιστον δύο κοινές αναφορές, εισάγοντας παράλληλα και την ανάστροφη ακμή (`'paper', 'shared refs by', 'paper'`).

Πίνακας 4.3: Ανάλυση τύπων ακμών (edge types) στο δίκτυο

Σχέση	**Πηγή**	**Πλήθος**
`writes`	authors	31.065
`written_by`	authors	31.065
`cites`	references	357.977
`cited_by`	references	357.977
`collaborates_with`	authors	243.310
`shares_refs`	references	12.592
`shared_by`	references	12.592
Σύνολο ακμών		**1.046.578**

4.7.3 Χαρακτηριστικά κόμβων-άρθρων

Πίνακας 4.4: Χαρακτηριστικά κόμβων-άρθρων (Node Features)

Χαρακτηριστικό	**Διαστάσεις**	**Πεδίο**	**Μετασχ/μός**	**Σκοπός**
SPECTER 2 embedding	768	abstracts	AllenAI/specter2	Σημασιολογική αναπαράσταση
Εκατοστημόριο αναφορές	1	cited_by_perc.	Κανονικοποίηση	Σχετική απήχηση
Συνολικές αναφορές	1	cited_by_count	log1p	Συμπίεση outliers
Μέγιστες ετήσιες	1	counts_by_year	max(y_cites)	Ένδειξη δημοτικότητας
Έτη ενεργής παρουσίασης	1	counts_by_year	len(y_cites)	Διάρκεια ζωής
Δείκτης έκρηξης	1	counts/total	max/total	Ανίχνευση αύξησης

Πίνακας 4.5: Ετικέτες (labels) και συμμετοχή κόμβων στη διαδικασία εκπαίδευσης

Άρθρο	**Label**	**Κόμβος**
Ανακληθέν άρθρο	1	Κόμβος-άρθρο
Έγκυρο άρθρο	0	Κόμβος-άρθρο
Εξωτερικό	-1	Κόμβος-αναφορά

Τα χαρακτηριστικά των κόμβων-άρθρων είναι ένας συνδυασμός σημασιολογικών embeddings με δομικά και χρονικά χαρακτηριστικά (features).Πιο συγκεκριμένα, αποτελούν ένα ενιαίο διάνυσμα μέσω της συνένωσης (`torch.cat`) των εξής συνιστωσών: τα SPECTER 2 embeddings (768 διαστάσεις) κανονικοποιημένα, το κανονικοποιημένο εκατοστημόριο αναφορών (cited by percentile year/100), το οποίο τοποθετεί την απήχηση του άρθρου σε κλίμακα [0,1], συγκριτικά με τα άρθρα του ίδιου έτους, τον κανονικοποιημένο συνολικό αριθμό αναφορών, στον οποίο εφαρμόζεται ο λογαριθμικός μετασχηματισμός `torch.log1p(count)`. Ο μετασχηματισμός αυτός συμπιέζει τις ακραίες τιμές (outliers) των άρθρων με υπερβολικά υψηλό αριθμό αναφορών, επιτρέποντας στο δίκτυο να επεξεργάζεται ομαλά τα δεδομένα, και τέλος τα χρονικά χαρακτηριστικά (`time features`) που εξάγονται από το πεδίο `counts_by_year` μέσω της συνάρτησης `get_time_features`.

Αυτά περιλαμβάνουν:

α) τις μέγιστες αναφορές που έλαβε το άρθρο σε ένα μόνο έτος (`max_yearly`),

β)τα συνολικά έτη ενεργούς παρουσίας του άρθρου (`active years`),

γ)τον δείκτη έκρηξης (`burst_ratio`), ο οποίος ορίζεται ως (`max_yearly /total_cites`) και υποδεικνύει αν ένα άρθρο απέκτησε απότομη, αφύσικη δημοτικότητα (χαρακτηριστικό των citation mills). Η απότομη αυτή αύξηση έρχεται σε αντίθεση με το φυσιολογικό πρότυπο ”σταδιακής συσσώρευσης” της επιστημονικής επίδρασης, αποτελώντας, σύμφωνα με τους Ibrahim et al. [18], ισχυρή ένδειξη τεχνητής χειραγώγησης μετρικών για την ταχεία αναβάθμιση του ακαδημαϊκού προφίλ.

Όσον αφορά τα εξωτερικά άρθρα, δηλαδή τα άρθρα αναφορές που δεν ανήκουν στο βασικό dataset, αυτά δεν διαθέτουν μεταδεδομένα. Για την αποφυγή σφαλμάτων διάστασης, ο κώδικας εισάγει μηδενικά διανύσματα χαρακτηριστικών (`torch.zeros`) για αυτούς τους κόμβους. Παράλληλα, τους αποδίδεται η ετικέτα στόχος -1, η οποία καθοδηγεί τη συνάρτηση κόστους να τους αγνοήσει πλήρως κατά την εκπαίδευση και την αξιολόγηση. Η απουσία έγκυρων ετικετών (labels), καθώς και πραγματικών σημασιολογικών χαρακτηριστικών (όπως τα διανύσματα SPECTER) για τους εξωτερικούς κόμβους βιβλιογραφίας (leaf nodes), δεν αποτελεί περιορισμό, αλλά αναδεικνύει την ικανότητα των Νευρωνικών Δικτύων Γράφων να αξιοποιούν την τοπολογία. Εφόσον οι εξωτερικοί κόμβοι στερούνται κειμενικής πληροφορίας, η συνεισφορά τους στο δίκτυο είναι αμιγώς δομική. Λειτουργούν αποκλειστικά ως ”τοπολογικές γέφυρες” που χαρτογραφούν τις σχέσεις μεταξύ των βασικών άρθρων. Κατά την φάση της συνάθροισης γειτονιάς (neighborhood aggregation), το μοντέλο δεν αντλεί σημασιολογικά στοιχεία από αυτά τα εξωτερικά άρθρα, αλλά αποκωδικοποιεί τα μοτίβα συνδεσιμότητας, όπως τους κόμβους-κέντρα (hubs) ή την ύπαρξη κοινών αναφορών (co-citations). Ο υπολογισμός του σφάλματος (loss) και η βελτιστοποίηση των βαρών πραγματοποιούνται αυστηρά πάνω στους βασικούς κόμβους-στόχους, επιτρέποντας στο σύστημα να εντοπίζει πιθανή απάτη συνδυάζοντας την κειμενική πληροφορία των στόχων με τον ευρύτερο δομικό ιστό του δικτύου αναφορών τους. Για το χαρακτηριστικό των κόμβων-συγγραφέων (authors) `orcid` γίνεται έλεγχος της στήλης orcid και αποδίδεται η τιμή 1.0 στον συγγραφέα αν ο ίδιος διαθέτει έγκυρο ORCID, αλλιώς 0.0 και έτσι παράγεται ένα κάθετο `tensor` διάστασης [πλήθος συγγραφέων, 1].

Κεφάλαιο 5

Προτεινόμενη αρχιτεκτονική μοντέλου Hetero-GraphSAGE

5.1 Ο μηχανισμός to_hetero

Η αρχιτεκτονική που υλοποιήθηκε στον κώδικα της πειραματικής διαδικασίας περιείχε την κλάση `Retraction Detector SAGE` και τον μηχανισμό `to_hetero` της βιβλιοθήκης PyTorch Geometric (PyG), ο οποίος τη μετατρέπει από ομογενές σε ετερογενές δίκτυο. Οι εξισώσεις του GraphSAGE εφαρμόζονται ξεχωριστά ανά τύπο σχέσης στον ετερογενή γράφο και επιλέγονται μηχανικές λεπτομέρειες όπως κανονικοποίηση, σταθεροποίηση εκπαίδευσης και δύο επίπεδα συνέλιξης, οι οποίες καθορίζουν την τελική συμπεριφορά του μοντέλου.

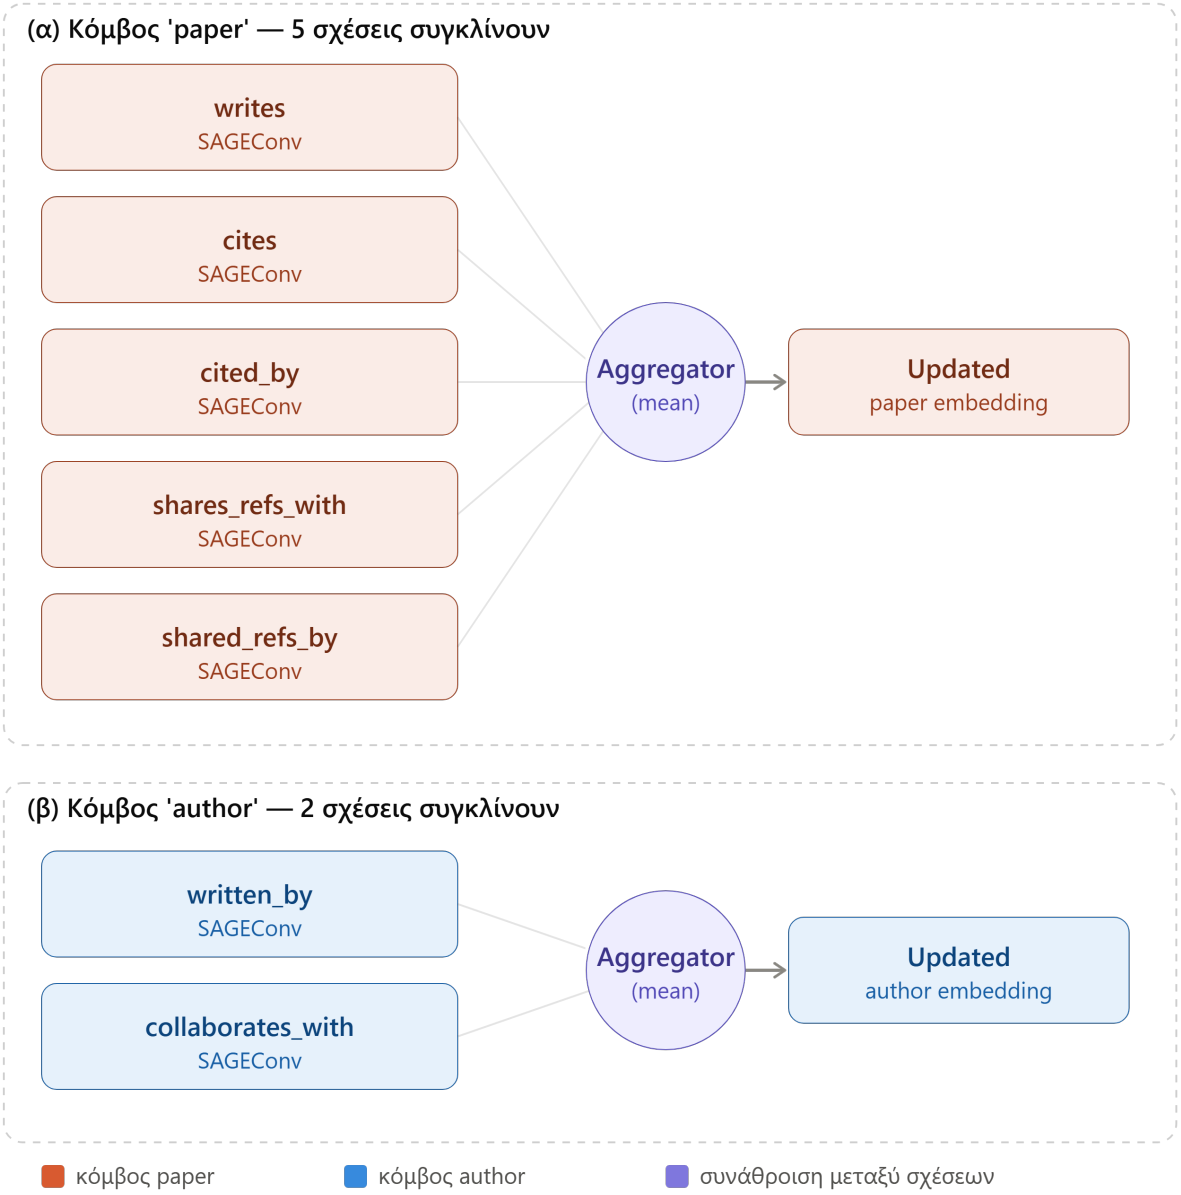
Το βασικό μοντέλο ορίζεται ως ένα ομογενές δίκτυο δύο επιπέδων SAGEConv, το οποίο όμως καλείται να λειτουργήσει πάνω σε έναν γράφο με πολλαπλούς τύπους κόμβων (`paper`, `author`, και ανάλογα με το πείραμα `university`, `country`, `journal`, `virtual_node`), και πολλαπλούς τύπους ακμών. Η μετάβαση γίνεται μέσω της συνάρτησης `to_hetero(model, data.metadata(), aggr='mean')` της PyG, η οποία αναλαμβάνει δύο διακριτές εργασίες:

1. **Κλωνοποίηση ανά σχέση:** Κάθε επίπεδο SAGEConv του αρχικού ομογενούς μοντέλου αντιγράφεται εσωτερικά μία φορά για κάθε τύπο ακμής (edge type) του γράφου, με κάθε αντίγραφο να διατηρεί το δικό του ανεξάρτητο, εκπαιδεύσιμο σύνολο βαρών. Έτσι, η σχέση `('author','writes','paper')` μαθαίνει διαφορετικό πίνακα βαρών από τη σχέση `('paper','cites','paper')`, παρότι καθ οι δύο υολοποιούνται από το ίδιο SAGEConv module στον ορισμό της κλάσης.

2. **Συνάθροιση μεταξύ σχέσεων:** Όταν ένας τύπος κόμβου (π.χ. `paper`) δέχεται ακμές από περισσότερες από μία σχέσεις ταυτόχρονα, τα ενδιάμεσα μηνύματα που παράγονται από κάθε σχέση συνδυάζονται μέσω της παραμέτρου `aggr='mean'` που δόθηκε στο `to_hetero`. Πρόκειται για ένα δεύτερο, ανεξάρτητο επίπεδο συνάθροισης, διακριτό από τη συνάθροιση γειτόνων εντός μια σχέσης που ήδη εκτελεί εσωτερικά το SAGEConv.

Η παραπάνω διαδικασία αποτελεί ουσιαστικά επέκταση του γενικού πλαισίου AGGREGATE-UPDATE στην ετερογενή περίπτωση: οι συναρτήσεις AGGREGATE-UPDATE εφαρμόζονται πλή-

ρως και ανεξάρτητα εντός κάθε σχέσης, ενώ η συνάθροιση με aggr='mean' εισάγει ένα δεύτερο, ιεραρχικά ανώτερο επίπεδο συνδυασμού των επιμέρους αναπαραστάσεων που προκύπτουν από κάθε σχέση. Στο βασικό μοντέλο, ο κόμβος-στόχος paper δέχεται μηνύματα από πέντε σχέσεις: `writes`, `cites`, `cited_by`, `shares_refs_with` και `shared_refs_by`. Παράλληλα, ο κόμβος-στόχος `author` δέχεται μηνύματα από δύο σχέσεις: την ανάστροφη σχέση `written_by` (`paper`→ `author`, που μεταφέρει πληροφορία από τα άρθρα προς τους συγγραφείς) και τη σχέση `collaborates_with` (`author`→`author`), η οποία υλοποιείται ως μία, αμφίδρομη ακμή, δεν απαιτεί δηλαδή ξεχωριστή ανάστροφη σχέση, καθώς και τα δύο άκρα της είναι του ίδιου τύπου κόμβοι.



Σχήμα 5.1: Σύγκλιση μηνυμάτων ανά τύπο κόμβου-στόχου στο βασικό μοντέλο. (α) Ο κόμβος `paper` δέχεται από πέντε σχέσεις· (β) ο κόμβος `author` δέχεται από δύο σχέσεις, `written_by` και `collaborates_with`. Κάθε σχέση διαθέτει ανεξάρτητο πίνακα βαρών W_r, και τα αποτελέσματα συνδυάζονται με μέσο όρο πριν προχωρήσουν στην κανονικοποίηση.

Το μοντέλο υπολογίζει ενημερωμένες αναπαραστάσεις και για τον τύπο κόμβου `author` σε κάθε επίπεδο, αφού το `to_hetero` ενημερώνει όλους τους τύπους κόμβων ταυτόχρονα σε κάθε forward pass, η συνάρτηση κόστους υπολογίζεται αποκλειστικά πάνω στις εξόδους τύπου `paper`. Τα embeddings `author` συμμετέχουν επομένως στην εκπαίδευση μόνο έμμεσα, ως ενδιάμεσος σταθμός μετάδοσης πληροφορίας προς τους γειτονικούς κόμβους-άρθρα στο επόμενο επίπεδο συνέλιξης.

Για έναν κόμβο-στόχο v τύπου τ (π.χ. $\tau = \texttt{paper}$) και το σύνολο σχέσεων $R(\tau)$ που καταλήγουν σε αυτόν τον τύπο, η ενημέρωση στο επίπεδο l περιγράφεται ως:

$$h_v^{(l+1),\tau} \;=\; \frac{1}{|R(\tau)|} \sum_{r \in R(\tau)} \sigma\left(W_r^{(l)} \cdot \text{CONCAT}\left(h_v^{(l)},\; \frac{1}{|N_r(v)|} \sum_{u \in N_r(v)} h_u^{(l)} \right) \right) \tag{5.1}$$

όπου $N_r(v)$ είναι οι γείτονες του v μέσω της σχέσης r συγκεκριμένα, και $W_r^{(l)}$ ο πίνακας βαρών που αντιστοιχεί αποκλειστικά σε αυτή τη σχέση στο επίπεδο l. Η Εξίσωση 5.1 αποτελεί ουσιαστικά την επέκταση της Εξίσωσης 3.8 στην ετερογενή περίπτωση, με την προσθήκη ενός εξωτερικού μέσου όρου πάνω στις σχέσεις $r \in R(\tau)$.

Μια πρακτική συνέπεια αυτής της σχεδίασης είναι ότι το μοντέλο μπορεί να χειριστεί κόμβους με τελείως διαφορετική διάσταση των χαρακτηριστικών εισόδου, οι κόμβοι-papers έχουν 776 διαστάσεις (768 SPECTER 2 + 8 βιβλιομετρικά), ενώ οι κόμβοι-authors έχουν μόλις μία διάσταση (δυαδικό ORCID) και οι κόμβοι-γέφυρες (`university`, `country`, `journal`) έχουν επίσης μία διάσταση (dummy feature `torch.ones`). Αυτό καθίσταται δυνατό χάρη στην αρχικοποίηση (*lazy initialization*) `SAGEConv((-1,-1), hidden_dim)` όπου οι διαστάσεις εισόδου δεν ορίζονται ρητά στον κώδικα, αλλά εξάγονται αυτόματα κατά το πρώτο forward pass, ξεχωριστά για κάθε σχέση, χωρίς να απαιτείται προσαρμογή του μοντέλου κάθε φορά που πραγματοποιείται ένα πείραμα εμπλουτισμού του γράφου.

5.2 RetractionDetectorSAGE: Αρχιτεκτονική δύο επιπέδων

Ο πυρήνας του μοντέλου ορίζεται στον παρακάτω κώδικα:

```
class RetractionDetectorSAGE(torch.nn.Module):
    def __init__(self, hidden_dim, dropout_p, use_layer_norm=False):
        super().__init__()
        self.conv1   = SAGEConv((-1, -1), hidden_dim)
        self.dropout = torch.nn.Dropout(p=dropout_p)
        self.conv2   = SAGEConv((-1, -1), 2)
        self.norm    = (torch.nn.LayerNorm(hidden_dim) if use_layer_norm
                        else torch.nn.BatchNorm1d(hidden_dim))

    def forward(self, x, edge_index):
        x = F.relu(self.norm(self.conv1(x, edge_index)))
```

```
x = self.dropout(x)
return self.conv2(x, edge_index)
```

Το dropout εφαρμόζεται μία φορά ανάμεσα στο πρώτο και το δεύτερο επίπεδο συνέλιξης. Αυτό γίνεται καθώς το δεύτερο επίπεδο παράγει απευθείας τα μη κανονικοποιημένα logits για την ταξινόμηση και η εφαρμογή dropout σε αυτά θα εισήγαγε θόρυβο στην απόφαση ταξινόμησης. Το δεύτερο επίπεδο SAGEConv παράγει έξοδο διάστασης 2 (logits για δύο κλάσεις) για όλους τους τύπους κόμβων μέσω του to_hetero, αλλά μόνο η έξοδος του τύπου paper χρησιμοποιείται ουσιαστικά: η συνάρτηση κόστους υπολογίζεται αποκλειστικά πάνω σε αυτή (`out['paper'][train_mask]`), ενώ οι υπόλοιπες έξοδοι απορρίπτονται.

5.3 Κανονικοποίηση: διαφοροποίηση στον εικονικό κόμβο

Ενώ στα περισσότερα πειράματα χρησιμοποιείται `BatchNorm1d`, στο πέμπτο πείραμα με τον εικονικό κόμβο χρησιμοποιείται `use_layer_norm`, καθώς ο `virtual_node` αποτελεί έναν μόνο κόμβο. Το `BatchNorm1d` υπολογίζει στατιστικά (μέσο όρο, διακύμανση) πάνω στην διάσταση της δεσμίδας (*batch*) και αποτυγχάνει ή παράγει ασταθή αποτελέσματα όταν η δεσμίδα αυτή περιέχει μόνο ένα δείγμα. Για τον λόγο αυτό, χρησιμοποιείται `LayerNorm` στο συγκεκριμένο πείραμα, το οποίο κανονικοποιεί κατά μήκος των χαρακτηριστικών ενός μεμονωμένου δείγματος και άρα δεν εξαρτάται από το μέγεθος της δεσμίδας.

5.4 Μηχανισμοί σταθεροποίησης της εκπαίδευσης

Η βελτιστοποίηση των βαρών πραγματοποιείται με τον αλγόριθμο Adam (`lr=0.01`) στα transductive learning πειράματα, σε συνδυασμό με τρεις μηχανισμούς σταθεροποίησης πυο εφαρμόζονται κατά τη διάρκεια κάθε εποχής.

1. **Gradient clipping** με `max_norm=1.0`, εφαρμόζεται αμέσως μετά το loss.backward και πριν το optimizer step, και περιορίζει το συνολικό μέγεθος (norm) των παραγώγων πριν την ενημέρωση βαρών, ώστε ένα ασυνήθιστα μεγάλο batch loss να μην προκαλέσει υπερβολικά μεγάλο βήμα. Συνεπώς αποτρέπεται το φαινόμενο exploding gradients, που είναι συχνό σε γράφους με κόμβους διαφορετικού βαθμού συνδεσιμότητας.

2. **Δυναμική προσαρμογή ρυθμού μάθησης** μέσω `ReduceLROnPlateau (mode='min', patience=5, factor=0.5)`, όπου παρακολουθείται το validation loss και αν δεν βελτιωθεί για πέντε συνεχόμενες εποχές, υποδιπλασιάζει τον ρυθμό μάθησης και έτσι επιτρέπει μεγάλη, γρήγορα βήματα στην αρχή της εκπαίδευσης και μικρότερα, πιο προσεκτικά βήματα καθώς το μοντέλο πλησιάζει σε ένα ελάχιστο.

3. **Ealy stopping** με `patience=20` εποχές πάνω στο validation loss. Διακόπτει την εκπαίδευση αν το val loss δεν βελτιωθεί για 20 συνεχόμενες εποχές, αποτρέποντας υπερεκπαίδευση (overfitting) πέρα από το σημείο βέλτιστης γενίκευσης. Το μοντέλο που τελικά αξιολογείται

στο test set δεν είναι αυτό της τελευταίας εποχής, αλλά το checkpoint με το χαμηλότερο val loss που καταγράφηκε συνολικά.

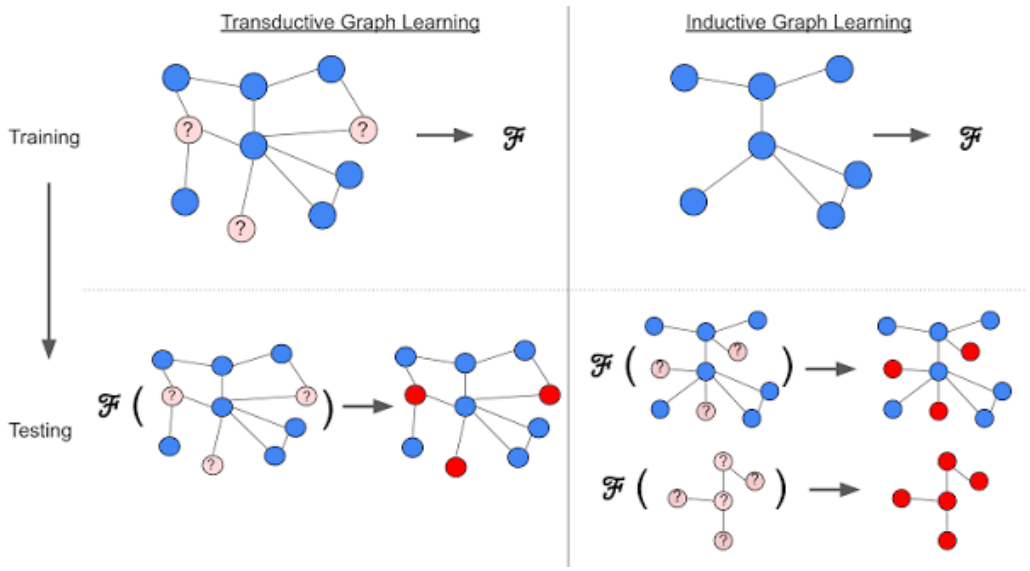
Η συνάρτηση κόστους είναι `F.cross_entropy`, όπου η ετικέτα -1 αντιστοιχεί στους «εξωτερικούς» κόμβους-αναφορές (*leafreferences*) που δεν ανήκουν στο αρχικό σύνολο δεδομένων. Η παράμετρος `ignore_index` διασφαλίζει ότι αυτοί οι κόμβοι, παρότι συμμετέχουν πλήρως στο message passing ως τοπολογικές γέφυρες, αποκλείονται τελείως από τον υπολογισμό του σφάλματος και τη διαδικασία οπισθοδιάδοσης.

5.5 Δύο είδη εκπαίδευσης: Transductive έναντι Inductive

Ο κώδικας υλοποιεί δύο διαφορετικούς βρόχους εκπαίδευσης:

- **Transductive:** Σε κάθε εποχή, ολόκληρος ο γράφος περνάει από το μοντέλο σε ένα ενιαίο forward pass (`model(data.x_dict, data.edge_index_dict)`) και η συνάρτηση κόστους υπολογίζεται επιλεκτικά μέσω των μασκών `train_mask` / `val_mask`. Το μοντέλο προβλέπει ετικέτες για ένα συγκεκριμένο, γνωστό σύνολο δεδομένων δοκιμών. Παρατηρώντας ταυτόχρονα τόσο τα σημεία εκπαίδευσης με ετικέτες όσο και τα σημεία χωρίς ετικέτες στις δοκιμαστικές περιπτώσεις, το μοντέλο προσαρμόζεται στην ακριβή κατανομή των δεδομένων-στόχων. Μπορεί να αποφέρει μεγαλύτερη ακρίβεια όταν τα δεδομένα είναι σπάνια, επειδή αξιοποιεί την βαθύτερη δομή του ίδιου του συνόλου δοκιμών.
- **Inductive:** Χρησιμοποιείται `NeighborLoader num_neighbors=[10, 10]` και `batch_size=256`. Η επιλογή δύο τιμών στη λίστα `num_neighbors` δεν είναι τυχαία: αντιστοιχεί ακριβώς στα δύο επίπεδα `SAGEConv` του μοντέλου, δειγματοληπτώντας έως 10 γείτονες σε κάθε ένα από τα δύο *hops* που «βλέπει» το δίκτυο. Επιπλέον, πριν την κατασκευή του `train_loader`, ο γράφος περιορίζεται σε ένα υπογράφημα μέσω `data.subgraph(...)` που περιλαμβάνει μόνο τα άρθρα εκπαίδευσης και τους «ασφαλείς» συγγραφείς (`safe_train_authors = author_in_train - author_in_nontr`) — δηλαδή συγγραφείς που δεν εμφανίζονται ταυτόχρονα στα σύνολα επικύρωσης/ελέγχου, αποτρέποντας δομική διαρροή πληροφορίας μέσω κοινών συγγραφέων.

Ορίζεται `LR = 0.001` (αντί για 0.01) και προστίθεται `weight_decay=5e-4` στον optimizer Adam αποκλειστικά για το πείραμα `'inductive learning'`. Στο transductive learning γίνεται ένα optimizer.step ανά εποχή (πάνω σε ολόκληρο τον γράφο) ενώ στο inductive γίνονται πολλά optimizer.step ανά εποχή, ένα για κάθε mini-batch που επιστρέφει ο NeighborLoader. Περισσότερα και συχνότερα βήματα σημαίνουν ότι ένα ίδιο lr=0.01 θα προκαλούσε πολύ μεγαλύτερη συνολική μετατόπιση των βαρών ανά εποχή με κίνδυνο αστάθειας. Επιπλέον, κάθε mini-batch βασίζεται σε τυχαία δειγματοληπτημένη γειτονιά (num_neighbors=[10,10]), άρα η εκτίμηση της κλίσης είναι εγγενώς πιο θορυβώδης απ' ό,τι στο full-batch gradient του transductive μοντέλου και έτσι το μικρότερο lr αντισταθμίζει αυτόν τον επιπλέον θόρυβο. Η τιμή 10 αποτελεί μια καθιερωμένη επιλογή στη βιβλιογραφία του GraphSAGE (χρησιμοποιήθηκε και στο πρωτότυπο paper των Hamilton et

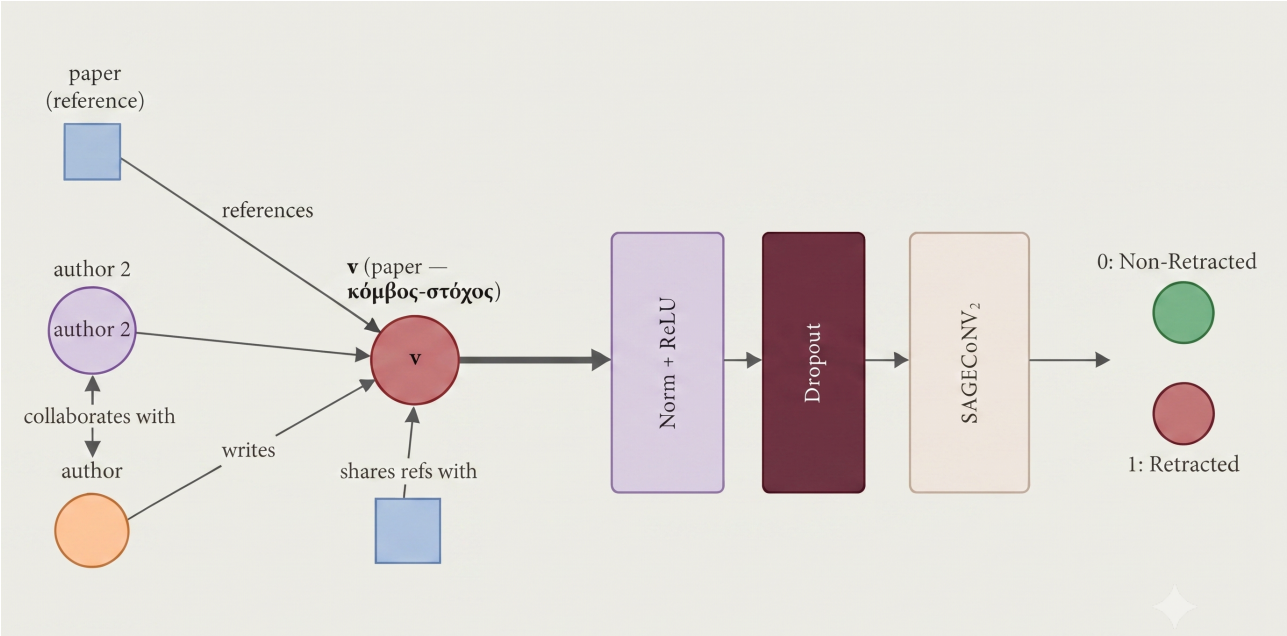


Σχήμα 5.2: Inductive vs Transductive learning

al. [32]), και εξισορροπεί ικανοποιητικά το receptive field του μοντέλου με το υπολογιστικό κόστος. Με δύο επίπεδα SAGEConv, [10,10] σημαίνει ότι κάθε κόμβος-στόχος βλέπει έως 100 κόμβους συνολικά, κάτι διαχειρίσιμο σε συνδυασμό με batch size=256. Δεν πραγματοποιήθηκε συστηματική μελέτη ευαισθησίας πάνω σε αυτή την υπερπαράμετρο.

Στο inductive learning το μοντέλο εκπαιδεύεται σε ένα μικρότερο υπογράφημα (μόνο τα άρθρα εκπαίδευσης και οι συγγραφείς αυτών), το οποίο έχει μικρότερη τοπολογική ποικιλομορφία και άρα μεγαλύτερο κίνδυνο υπερπροσαρμογής (overfitting) σε αυτό το συγκεκριμένο υποσύνολο. Το weight decay (L2 κανονικοποίηση) περιορίζει το μέγεθος των βαρών, ενισχύοντας τη γενίκευση.

5.6 Υπολογιστικός γράφος



Σχήμα 5.3: Αρχιτεκτονική της κλάσης RetractionDetectorSAGE

Το σχήμα αναπαριστά τη λειτουργία του μοντέλου RetractionDetectorSAGE ως υπολογιστικό γράφο (computation graph), αποτυπώνοντας τη διαδικασία λήψης απόφασης για έναν κόμβο-στόχο v (paper). Στο αριστερό μέρος, απεικονίζεται το ”receptive field” του μοντέλου, το οποίο μέσω της διαδικασίας AGGREGATE και UPDATE συγκεντρώνει πληροφορίες από τους γείτονες 2-hop (κόμβοι-συγγραφείς και άλλα άρθρα), χρησιμοποιώντας κοινά βάρη $W_r^{(k)}$ για κάθε τύπο σχέσης. Στο δεξί μέρος, όλη η πληροφορία περνά από το στάδιο επεξεργασίας, το οποίο περιλαμβάνει κανονικοποίηση (Norm), ενεργοποίηση ReLU και Dropout, προκειμένου να αποτραπεί η υπερεκπαίδευση (overfitting). Η διαδικασία καταλήγει στην τελική συνέλιξη (SAGEConv2), όπου το μοντέλο παράγει τα logits για την ταξινόμηση του άρθρου στις κατηγορίες ”Non-Retracted” ή ”Retracted”. Συνολικά, το διάγραμμα αναδεικνύει την ικανότητα της αρχιτεκτονικής να συνθέτει δομικά και σημασιολογικά χαρακτηριστικά, επιτρέποντας στο σύστημα να αναγνωρίζει μοτίβα απάτης πέρα από τα όρια της άμεσης γειτονιάς ενός άρθρου.

Κεφάλαιο 6

Πειραματική αξιολόγηση και ανάλυση αποτελεσμάτων

6.1 Σκοπός και οργάνωση πειραματικής διαδικασίας

Η πειραματική αξιολόγηση του προτεινόμενου συστήματος ανίχνευσης κακόβουλου χειρισμού επιστημονικών μετρικών βασίζεται στην αρχιτεκτονική Hetero-GraphSAGE και στον ετερογενή γράφο που δημιουργήθηκε από το σύνολο δεδομένων. Η πειραματική διαδικασία δεν περιορίζεται μόνο στην εκπαίδευση και αξιολόγηση ενός μοντέλου, αλλά είναι σχεδιασμένη ώστε να διερευνήσει συστηματικά τη συνεισφορά επιμέρους στοιχείων της τοπολογίας του γράφου στην τελική απόδοση, καθώς και την δυνατότητα εφαρμογής της σε ρεαλιστικές συνθήκες. Παρουσιάζονται τέσσερις διακριτοί άξονες διερεύνησης, οι οποίοι απορρέουν άμεσα από το ερευνητικό κενό που υπάρχει στην μελέτη για πρόβλεψη ανάκλησης άρθρου.

Ο πρώτος άξονας αφορά τη θεμελίωση της κεντρικής υπόθεσης, ότι δηλαδή η τοπολογική πληροφορία ενός δικτύου αναφορών, συγγραφής και συνεργασιών, σε συνδυασμό με σημασιολογικά χαρακτηριστικά κειμένου και στατιστικά στοιχεία των αναφορών των άρθρων, επαρκεί για τον αξιόπιστο διαχωρισμό ανακληθέντων άρθρων από τα έγκυρα. Η υπόθεση αυτή ελέγχεται μέσω της εκπαίδευσης και αξιολόγησης ενός βασικού μοντέλου, η οποία έπεται του ελέγχου της επαναληψιμότητας των αποτελεσμάτων και της συστηματικής μελέτης ευαισθησίας των υπερπαραμέτρων.

Ο δεύτερος άξονας εξετάζει κατά πόσο ο σταδιακός εμπλουτισμός της τοπολογίας του γράφου με πρόσθετη πληροφορία -σημασιολογικής, θεσμικής ή εκδοτικής φύσης- οδηγεί σε βελτίωση της διαγνωστικής ικανότητας του μοντέλου πέραν αυτής που επιτυγχάνει η βασική δομή αναφορών. Η διερεύνηση αυτή υλοποιείται μέσω τεσσάρων διακριτών πειραμάτων εμπλουτισμού του γράφου, τα οποία εξετάζουν αντίστοιχα την προσθήκη σημασιολογικών ακμών ομοιότητας, κόμβων ακαδημαϊκών ιδρυμάτων, κόμβων χώρας και κόμβων επιστημονικών περιοδικών.

Ο τρίτος άξονας διερευνά τη φύση του δομικού αποτυπώματος που αφήνει η ακαδημαϊκή απάτη στο δίκτυο και συγκεκριμένα αν αυτό εκδηλώνεται ως τοπικό φαινόμενο εντός πυκνών γειτονιών ή αν ενισχύεται από έναν μηχανισμό καθολικής, άμεσης ανταλλαγής πληροφορίας μεταξύ όλων των κόμβων-άρθρων του γράφου. Η υπόθεση αυτή ελέγχεται μέσω της ενσωμάτωσης

ενός εικονικού κόμβου στην τοπολογία του δικτύου.

Ο τέταρτος και τελευταίος άξονας αφορά τη δυνατότητα γενίκευσης του μοντέλου σε άρθρα τα οποία δεν συμμετείχαν καθόλου στη διαδικασία εκπαίδευσης και εφαρμόζεται επαγωγική μάθηση (inductive learning) του μοντέλου. Η αξιολόγηση αυτή προσομοιώνει ένα ρεαλιστικό σενάριο ελέγχου πριν την δημοσίευση ενός άρθρου και αποτελεί προϋπόθεση για την πρακτική εφαρμογή του συστήματος.

Στο τέλος παρουσιάζεται μια συγκεντρωτική συγκριτική ανάλυση όλων των πειραματικών αποτελεσμάτων, στα οποία τα επιμέρους ευρήματα συνδέονται με τους τέσσερις άξονες διερεύνησης, καθώς και με σχολιασμό των μεθοδολογικών περιορισμών της μελέτης.

6.2 Πειραματικό περιβάλλον και προετοιμασία δεδομένων

6.2.1 Υπολογιστικοί Πόροι και Περιβάλλον Εκτέλεσης

Η πειραματική διαδικασία υποστηρίχθηκε από υπολογιστικούς πόρους GPU (Graphics Processing Units) NVIDIA, συγκεκριμένα των μοντέλων NVIDIA T4 και NVIDIA L4, τα οποία παρέχονται από τις πλατφόρμες Google Colab και Kaggle αντίστοιχα. Η χρήση αυτών των επιταχυντών κρίθηκε απαραίτητη για την αποδοτική επεξεργασία του ετερογενούς γράφου και την επιτάχυνση της εκπαίδευσης του μοντέλου GraphSAGE μέσω της βιβλιοθήκης PyTorch Geometric και του πλαισίου CUDA. Η χρήση πολλαπλών περιβαλλόντων κρίθηκε επιβεβλημένη λόγω των περιορισμών στη διαθεσιμότητα των πόρων GPU (υπολογιστικά όρια) σε κάθε πλατφόρμα. Η δυνατότητα εκτέλεσης του κώδικα σε διαφορετικά περιβάλλοντα επιβεβαίωσε την ορθότητα της υλοποίησης και την ανεξαρτησία του λογισμικού από τις ιδιαιτερότητες του hardware, διασφαλίζοντας την αναπαραγωγιμότητα των αποτελεσμάτων.

6.2.2 Εξαγωγή σημασιολογικών χαρακτηριστικών κειμένου

Η κειμενική πληροφορία των άρθρων ενσωματώνεται στον γράφο ως αρχικά χαρακτηριστικά κόμβων (node features) μέσω του εξειδικευμένου γλωσσικού μοντέλου `allenai/specter2 base`. Η διαδικασία υλοποιήθηκε με τη χρήση της βιβλιοθήκης `sentence-transformers`, όπου για κάθε άρθρο ο τίτλος και η περίληψη (abstract) συνενώνονται σε ένα ενιαίο κείμενο με τη μεσολαβητική χρήση του ειδικού διαχωριστή `[SEP]` (title + `"[SEP]"` + abstract). Αυτή η μορφή καθοδηγεί την αρχιτεκτονική Transformer να αναγνωρίσει τη δομική και νοηματική διαφοροποίηση των δύο πεδίων, παράγοντας για κάθε επιστημονικό άρθρο ένα πυκνό διάνυσμα σταθερής διάστασης 768, το οποίο αποθηκεύεται ως PyTorch Tensor (`.pt`) για την άμεση τροφοδοσία και κανονικοποίηση του δικτύου.

Για την ενίσχυση της εκφραστικής ικανότητας των κόμβων-άρθρων, επιλέχθηκε το SPECTER 2, καθώς αποτελεί την εξέλιξη των μοντέλων αναπαράστασης επιστημονικών κειμένων. Σε αντίθεση με παραδοσιακά μοντέλα που βασίζονται αποκλειστικά στο κείμενο, το SPECTER 2 εκπαιδεύεται μέσω ενός προηγμένου πλαισίου αντιπαραθετικής μάθησης (contrastive learning), αξιοποιώντας την τοπολογία των αναφορών (citation graph) για να μάθει τη σημασιολογική εγγύτητα

μεταξύ άρθρων. Το contrastive learning είναι μια τεχνική κατά την οποία το μοντέλο διδάσκεται να ελαχιστοποιεί τη διανυσματική απόσταση μεταξύ άρθρων που συνδέονται μέσω βιβλιογραφικών αναφορών (θετικά ζεύγη) και να μεγιστοποιεί την απόσταση μεταξύ άρθρων που στερούνται τέτοιας σχέσης (αρνητικά ζεύγη). Η επιλογή αυτή είναι κρίσιμη για τον εντοπισμό ακαδημαϊκής απάτης, καθώς το μοντέλο παρουσιάζει υψηλή ευαισθησία στις νοηματικές ασυμβατότητες, επιτρέποντας στο GraphSAGE να απομονώνει ύποπτες ακμές χαρτογραφώντας σε μεγάλη διανυσματική απόσταση άρθρα που συνδέονται τεχνητά παρά το άσχετο γνωστικό τους αντικείμενο.

Παρά τον περιορισμό στην τροφοδοσία δεδομένων μόνο με τίτλο και abstract, το SPECTER 2 διατηρεί την αναλυτική του ισχύ, καθώς δεν επεξεργάζεται τα κείμενα ως απομονωμένες αλληλουχίες λέξεων, αλλά ως οντότητες εντός ενός επιστημονικού οικοσυστήματος. Κατά την επεξεργασία, το μοντέλο αποδίδει μια αναπαράσταση μέσω του ειδικού συμβόλου `[CLS]` token, το οποίο λειτουργεί ως ο σημασιολογικός "αντιπρόσωπος" ολόκληρου του κειμένου. Μέσω του μηχανισμού attention, το `[CLS]` token συγκεντρώνει πληροφορίες από όλες τις λέξεις του τίτλου και της περίληψης, συμπυκνώνοντας τη θεματολογία, το επιστημονικό πεδίο και τη συνεισφορά του άρθρου σε ένα διάνυσμα 768 διαστάσεων. Έτσι, το μοντέλο "συμπληρώνει τα κενά" της έλλειψης πλήρους κειμένου βασιζόμενο στην εμπειρία που απέκτησε κατά την εκπαίδευσή του, παρατηρώντας πώς τα abstracts των άρθρων που αναφέρονται το ένα στο άλλο ταίριαζαν μεταξύ τους.

6.2.3 Προετοιμασία και φόρτωση του ετερογενούς γράφου

Η δομή του ακαδημαϊκού δικτύου μετασχηματίζεται σε αντικείμενο HeteroData της βιβλιοθήκης PyTorch Geometric για την υποστήριξη των υπολογισμών του νευρωνικού δικτύου. Η υλοποίηση της ετερογένειας επιτυγχάνεται με τη μέθοδο to_hetero, η οποία επιτρέπει τη διαμοιρασμένη εκπαίδευση του GraphSAGE σε διαφορετικούς τύπους κόμβων και ακμών, εφαρμόζοντας ανεξάρτητα βάρη για κάθε σχέση του γράφου.

Για τη διαχείριση της υπολογιστικής πολυπλοκότητας κατά την επαγωγική εκπαίδευση, εφαρμόζεται η τεχνική NeighborLoader. Ο συγκεκριμένος φορτωτής δεδομένων διενεργεί δειγματοληψία της γειτονιάς (subgraph sampling) σε κάθε batch, επιτρέποντας στο μοντέλο να εκπαιδεύεται σε εκτεταμένα τμήματα του δικτύου χωρίς να απαιτείται η πλήρης φόρτωση του γράφου. Η διαδικασία αυτή διασφαλίζει ότι οι σημασιολογικές πληροφορίες (embeddings) και τα βιβλιομετρικά χαρακτηριστικά, μεταφέρονται ορθά μέσω του message passing στο μοντέλο, διατηρώντας τη δομική ακεραιότητα μεταξύ των βασικών άρθρων και των εξωτερικών κόμβων-γεφυρών.

6.3 Βασική αρχιτεκτονική και στρατηγική εκπαίδευσης

6.3.1 Αρχιτεκτονική μοντέλου Hetero-GraphSAGE

Η αρχιτεκτονική του δικτύου βασίζεται στον αλγόριθμο GraphSAGE (`SAGEConv`), ο οποίος είναι ιδανικός για επαγωγική μάθηση, καθώς δεν αποστηθίζει συγκεκριμένους κόμβους αλλά μαθαίνει συναρτήσεις συνάθροισης γειτονιάς. Λόγω της ετερογένειας των δεδομένων, το μοντέλο μετασχηματίζεται με τη χρήση της συνάρτησης `to_hetero` της PyG, η οποία δέχεται το ομογενές δίκτυο, τα μεταδεδομένα του γράφου και τη στρατηγική συνάθροισης `aggr='mean'`. Το δίκτυο αποτελείται από δύο επίπεδα συνέλιξης. Το πρώτο επίπεδο συνέλιξης δέχεται τα χαρακτηριστικά εισόδου και τα μετασχηματίζει σε έναν κρυφό χώρο 64 διαστάσεων. Η παράμετρος `(-1,-1)` επιτρέπει τον αυτόματο προσδιορισμό των διαστάσεων εισόδου κατά το πρώτο `forward pass`. Αμέσως μετά την πρώτη συνέλιξη, ακολουθεί η εφαρμογή του Batch Normalization (bn1), το οποίο εξομαλύνει τις ενεργοποιήσεις, και στη συνέχεια η συνάρτηση ενεργοποίησης ReLU. Για την αποτελεσματική αποτροπή της υπερεκπαίδευσης (overfitting), εφαρμόζεται ένα επίπεδο dropout (`torch.nn.Dropout(p=0.5)`) για τον έλεγχο μετά τη μη-γραμμική ενεργοποίηση. Το δεύτερο επίπεδο συνέλιξης (conv2) μειώνει τη διάσταση της πληροφορίας στις 2, εστιάζοντας στον τύπο κόμβου ”paper” (στόχος ταξινόμησης), παράγοντας τα `logits` για τις δύο κλάσεις (0 για έγκυρο,1 για ανακληθέν). Κατά το `forward pass`, η πληροφορία ρέει μέσω των ακμών και οι κρυφές καταστάσεις των κόμβων ενημερώνονται με βάση τον μέσο όρο (`mean`) των μηνυμάτων των γειτόνων τους, διατηρώντας τη σταθερότητα του σήματος μέσω της διαδοχικής εφαρμογής κανονικοποίησης και μη-γραμμικών μετασχηματισμών.

Σημειώνεται ότι η επιλογή του μέσου όρου (mean aggregator) ενέχει έναν θεωρητικό συμβιβασμό ως προς την εκφραστική ικανότητα (expressiveness) του δικτύου. Σύμφωνα με το τεστ ισομορφισμού γράφων 1-WL, η συνάθροιση μέσω αθροίσματος (sum aggregation) θεωρείται μαθηματικά πιο ισχυρή, καθώς ο μέσος όρος αδυνατεί να διακρίνει τοπολογικές γειτονιές που φέρουν τα ίδια χαρακτηριστικά αλλά διαφέρουν ως προς το πλήθος των κόμβων τους. Ωστόσο, στη συγκεκριμένη μελέτη η επιλογή του μέσου όρου κρίθηκε επιβεβλημένη για πρακτικούς λόγους βελτιστοποίησης. Στα δίκτυα ακαδημαϊκών αναφορών παρατηρούνται ακραίες διακυμάνσεις στον βαθμό των κόμβων (π.χ. άρθρα με 5 αναφορές έναντι άρθρων ανασκόπησης με 500 αναφορές). Η χρήση αθροίσματος σε ένα τέτοιο περιβάλλον θα οδηγούσε σε μαθηματική αστάθεια και εκρηκτικές κλίσεις (exploding gradients) κατά την εκπαίδευση. Αντίθετα, ο μέσος όρος λειτουργεί ως ένας φυσικός μηχανισμός κανονικοποίησης (normalization), εξασφαλίζοντας ομαλή και σταθερή σύγκλιση αλγορίθμου.

Η επιλογή μίας ”ρηχής” (shallow) αρχιτεκτονικής, αποτελούμενης από ακριβώς δύο επίπεδα συνέλιξης (2-hop neighborhood), αποτελεί μία βιβλιογραφικά τεκμηριωμένη σχεδιαστική απόφαση, καθώς στα νευρωνικά δίκτυα γράφων η ανεξέλεγκτη αύξηση του βάθους οδηγεί ταχύτατα στο φαινόμενο της υπερ-εξομάλυνσης (oversmoothing). Καθώς αυξάνονται τα επίπεδα, η επαναληπτική συνάθροιση μηνυμάτων από όλο και πιο απομακρυσμένους κόμβους έχει ως αποτέλεσμα οι αναπαραστάσεις (embeddings) των κόμβων να συγκλίνουν σε πανομοιότυπες τιμές, καταστρέφοντας την τοπική δομική πληροφορία. Τα δύο επίπεδα συνέλιξης εξασφαλίζουν ότι

κάθε άρθρο αντλεί πληροφορία από τους άμεσους γείτονες/αναφορές του, καθώς και από τους γείτονες δεύτερου βαθμού, επιτυγχάνοντας το βέλτιστο όριο μεταξύ επαρκούς αντίληψης του δικτύου και διατήρησης της διαχωριστικής ικανότητας των χαρακτηριστικών. Τέλος, το δεύτερο επίπεδο εξάγει απευθείας τις ακανονικοποίητες τιμές (logits) για τις δύο κλάσεις ταξινόμησης, οι οποίες τροφοδοτούνται στη συνάρτηση κόστους διασταυρούμενης εντροπίας για τον υπολογισμό του σφάλματος και την αναπροσαρμογή των βαρών του δικτύου μέσω οπισθοδιάδοσης.

Για τη διασφάλιση της αριθμητικής σταθερότητας και τη βελτιστοποίηση της διαδικασίας σύγκλισης, η εκπαίδευση του μοντέλου ενισχύθηκε με τρεις μηχανισμούς. Αρχικά, ενσωματώθηκε Batch Normalization (BatchNorm1d) μετά το πρώτο επίπεδο SAGEConv, μια πρακτική που εξομαλύνει τις ενεργοποιήσεις των νευρώνων καθώς λαμβάνει τις εξόδους του SAGEConv και τις "κανονικοποιεί" (rescaling), ώστε να έχουν μέση τιμή 0 και διακύμανση 1. Χωρίς αυτό, τα βάρη του μοντέλου θα έπρεπε να προσαρμόζονται συνεχώς σε συνεχώς μεταβαλλόμενες κλίμακες τιμών. Με την κανονικοποίηση, το δίκτυο "βλέπει" δεδομένα με συνεπή κλίμακα, γεγονός που επιτρέπει πολύ πιο γρήγορη και σταθερή σύγκλιση. Επιπροσθέτως, εφαρμόστηκε τεχνική gradient clipping (max norm=1.0) σε κάθε εποχή, λειτουργώντας ως μηχανισμός εξισορρόπησης που αποτρέπει την εκρηκτική αύξηση των κλίσεων (exploding gradients), η οποία συχνά παρατηρείται σε σύνθετα γραφικά δίκτυα λόγω της τοπολογικής ανομοιογένειας των κόμβων. Η gradient clipping ελέγχει το συνολικό μέγεθος (norm) των κλίσεων και αν υπερβαίνει το max norm=1.0, το "κόβει" (rescaling) ώστε να μην ξεπερνά αυτή την τιμή. Αν η κλίση γίνει τεράστια, το μοντέλο θα κάνει λάθος βήμα στη διόρθωση των βαρών, καταστρέφοντας όλη την πρόοδο που είχε κάνει μέχρι τότε. Το clipping είναι το "φρένο" που εξασφαλίζει ότι το μοντέλο θα κινείται πάντα με ασφαλή βήματα. Τέλος, χρησιμοποιήθηκε ο δυναμικός προγραμματιστής ReduceLROnPlateau (με patience=5 και factor=0.5), ο οποίος επιτηρεί το validation loss και προσαρμόζει προσαρμοστικά τον ρυθμό μάθησης. Η εν λόγω πρακτική επιτρέπει στο μοντέλο να πραγματοποιεί εκτενέστερα βήματα κατά την αρχική φάση της εκπαίδευσης και να περιορίζει τη διακύμανση του ρυθμού μάθησης κατά την προσέγγιση του βέλτιστου σημείου σύγκλισης, εξασφαλίζοντας υψηλότερη ακρίβεια και αποτροπή της ταλάντωσης γύρω από το ελάχιστο της συνάρτησης κόστους.

6.3.2 Στρατηγική εκπαίδευσης

Ο διαχωρισμός του dataset πραγματοποιείται με στρωματοποιημένο τρόπο (`stratified split`), διασφαλίζοντας ότι η αναλογία των έγκυρων και ανακληθέντων άρθρων παραμένει απόλυτα σταθερή (50-50) σε όλα τα υποσύνολα. Το dataset χωρίζεται σε 70% Εκπαίδευση (`Train`), 10% Επικύρωση (`Validation`) και 20% Έλεγχο (`Test`). Οι αντίστοιχοι δείκτες μετατρέπονται σε δυαδικές μάσκες (`train mask`, `val mask`, `test mask`) εντός του γράφου. Η εκπαίδευση εκτελείται για μέγιστο όριο 150 εποχών. Σε κάθε `epoch`, υπολογίζεται η συνάρτηση κόστους Cross-Entropy (`F.cross entropy`) αποκλειστικά πάνω στους κόμβους της μάσκας εκπαίδευσης. Ο αλγόριθμος `Adam` ανανεώνει τα βάρη του δικτύου με ρυθμό μάθησης `lr=0.01`. Στο τέλος κάθε epoch, το μοντέλο τίθεται σε κατάσταση αξιολόγησης (`model.eval()`) και υπολογίζεται το `validation loss`. Για την αποφυγή του overfitting, εφαρμόζεται ο μηχανισμός `Early Stopping` με παράμετρο `patience=20`. Αν το `validation loss` αποτύχει να βελτιωθεί για 20 συνεχόμενες εποχές, η

διαδικασία τερματίζεται αυτόματα.

6.3.3 Σταθερότητα/seeds

Το υπολογιστικό περιβάλλον αναπτύχθηκε σε python με χρήση βιβλιοθηκών PyTorch και PyTorch geometric (PyG), ενσωματώνοντας ρυθμίσεις για τη διασφάλιση της σταθερότητας και της επαναληψιμότητας των αποτελεσμάτων έναντι της εγγενούς στοχαστικότητας των νευρωνικών δικτύων. Συγκεκριμένα, για την εξάλειψη των μεταβολών που προκύπτουν από τυχαίες διαδικασίες όπως η αρχικοποίηση των βαρών και το dropout, καθορίστηκε ένας καθολικός ψευδοτυχαίος σπόρος (seed=123) που "κλειδώνει" τις γεννήτριες τυχαίων αριθμών του συστήματος, αφού έγιναν πρώτα δοκιμές με τρία seeds.

Η ανάλυση των τριών πειραματικών εκτελέσεων αποκαλύπτει μια σχεδόν σταθερή συμπεριφορά του μοντέλου GraphSAGE. Παρατηρείται ότι το F1-score παρουσιάζει χαμηλή διακύμανση (τυπική απόκλιση $\sigma = 0.0054$), γεγονός που επιβεβαιώνει ότι η αρχιτεκτονική δεν είναι ευαίσθητη στην τυχαία αρχικοποίηση των βαρών. Όσον αφορά τη συμπεριφορά του Precision και του Recall, ενώ παρατηρείται μια μικρή διακύμανση στις επιμέρους μετρικές (με μεγαλύτερη απόκλιση στο Precision, $\sigma = 0.0088$), το F1-score παραμένει σε υψηλά επίπεδα. Αυτό υποδεικνύει ότι το μοντέλο διατηρεί μια ισορροπημένη στρατηγική ταξινόμησης, με το Seed 7 να επιτυγχάνει την καλύτερη δυνατή σύγκλιση (F1-score 0.9104). Συνολικά, η επίτευξη μέσου F1-score 0.9068 επικυρώνει την ικανότητα του μοντέλου να γενικεύει αποτελεσματικά σε διαφορετικά τυχαία υποσύνολα δεδομένων του γράφου.

Πίνακας 6.1: Αποτελέσματα απόδοσης του μοντέλου GraphSAGE για διαφορετικά τυχαία seeds

Πείραμα (Seed)	**Accuracy**	**Precision**	**Recall**	**F1-Score**	**Early Stop**
Seed 123	0.9079	0.8939	0.9257	0.9095	115
Seed 42	0.8998	0.8947	0.9063	0.9005	118
Seed 7	0.9103	0.9097	0.9111	0.9104	106
Μέσος Όρος	0.9060	0.8994	0.9144	0.9068	113
Τυπική Απόκλιση	0.0054	0.0088	0.0101	0.0054	6.24

Για να διασφαλιστεί ότι η σύγκριση μεταξύ των μοντέλων είναι δίκαιη και ακριβής, όλα τα προσεχή πειράματα θα εκτελεστούν χρησιμοποιώντας τον ίδιο αρχικό τυχαίο σπόρο (seed 123). Η επιλογή αυτή καθιστά τις μετρήσεις άμεσα συγκρίσιμες, καθώς εξαλείφει την πιθανότητα οι διαφορές στις επιδόσεις να οφείλονται σε τυχαία αρχικοποίηση των βαρών. Με τον τρόπο αυτό, αποφεύγεται η επιλεκτική παρουσίαση ευνοϊκών αποτελεσμάτων και εξασφαλίζεται ότι οι επιδόσεις που καταγράφονται αντικατοπτρίζουν την σταθερότητα της αρχιτεκτονικής GraphSAGE.

6.4 Μελέτη ευαισθησίας και επιλογή υπερπαραμέτρων

6.4.1 Συγκριτικά αποτελέσματα δοκιμών για τις υπερπαραμέτρους

Στην μηχανική μάθηση, οι υπερπαράμετροι καθορίζουν τη ροή της εκπαίδευσης και τη δομική χωρητικότητα του μοντέλου, επηρεάζοντας άμεσα τη γενικευτική του ικανότητα. Οι βασικές παράμετροι που εξετάστηκαν στη μελέτη ευαισθησίας είναι οι εξής:

-Ρυθμός μάθησης (`learning rate`): Καθορίζει το μέγεθος του βήματος που πραγματοποιεί ο αλγόριθμος βελτιστοποίησης (`Adam`) προς τη κατεύθυνση ελαχιστοποίησης της συνάρτησης κόστους. Υψηλός ρυθμός μάθησης (π.χ. 0.01) επιταχύνει τη σύγκλιση αλλά ενέχει κίνδυνο αστάθειας ή της προσπέρασης του ολικού ελαχίστου, ενώ χαμηλός ρυθμό μάθησης (π.χ. 0.005) προσφέρει σταθερότητα αλλά μπορεί να εγκλωβίσει το μοντέλο σε τοπικά ελάχιστα ή να καθυστερήσει υπερβολικά την εκπαίδευση.

-Κρυφά κανάλια (`hidden channels`): Ορίζουν τη διάσταση των εσωτερικών επιπέδων αναπαράστασης της πληροφορίας στα επίπεδα συνέλιξης SAGEConv. Αντιπροσωπεύουν τη χωρητικότητα του δικτύου. Η αύξησή τους επιτρέπει στο μοντέλο να αποθηκεύει πιο σύνθετα και αφηρημένα τοπολογικά και σημασιολογικά μοτίβα, αλλά η υπερβολική αύξησή τους οδηγεί σε αποστήθιση (overfitting). Αντίθετα, η μείωσή τους προστατεύει από την υπερεκπαίδευση αλλά μπορεί να προκαλέσει υποεκπαίδευση (underfitting) λόγω έλλειψης εκφραστικής ισχύος.

-Ποσοστό απόρριψης (`dropout rate`): Αποτελεί τεχνική ομαλοποίησης (regularization) κατά την οποία, σε κάθε epoch, ένα τυχαίο ποσοστό νευρώνων απενεργοποιείται (τίθεται στο μηδέν). Η αύξησή του (π.χ. 0.5) αναγκάζει το δίκτυο να αναπτύξει πλεονασματικές διαδρομές μάθησης και εμποδίζει τους νευρώνες να αναπτύξουν συν-προσαρμογή (co-adaptation), μειώνοντας το overfitting. Η μείωσή του (π.χ. 0.3) επιτρέπει την απρόσκοπτη ροή πληροφορίας, αυξάνοντας όμως τον κίνδυνο αποστήθισης.

-Μέγιστες εποχές (`max epochs`): Ορίζουν το ανώτατο όριο των πλήρων επαναλήψεων εκπαίδευσης πάνω σε ολόκληρο το dataset.

- Υπομονή (`patience`): Καθορίζει για πόσες συνεχόμενες εποχές επιτρέπεται στο μοντέλο να εκπαιδεύεται χωρίς να παρουσιάζει βελτίωση (μείωση) στο validation loss, πριν ενεργοποιηθεί ο μηχανισμός `Early Stopping`. Μια υψηλή τιμή υπομονής επιτρέπει στο μοντέλο να ξεπεράσει μια προσωρινή στασιμότητα στη μείωση του σφάλματος, αλλά αν είναι υπερβολικά μεγάλη αφήνει το δίκτυο να συνεχίσει την εκπαίδευσή του παρόλο που έχει ήδη ξεκινήσει το φαινόμενο της υπερεκπαίδευσης.

Δοκιμάστηκαν δέκα πειραματικά σενάρια στο validation set με σκοπό την παρατήρηση της επίδρασης των αυξομειώσεων των παραμέτρων. Το validation set είναι κατάλληλο γιατί δεν συμμετέχει στην εκπαίδευση των βαρών του δικτύου. Αυτό σημαίνει ότι η απόδοση στο validation set αποτελεί ανεξάρτητη μέτρηση της ικανότητας γενίκευσης για κάθε διαφορετικό συνδυασμό υπερπαραμέτρων, επιτρέποντας έτσι αξιόπιστη σύγκριση μεταξύ τους.

Πίνακας 6.2: Συγκριτική αξιολόγηση 10 πειραματικών σεναρίων υπερπαραμέτρων βάσει του Validation F1-Score.

Πείραμα	**LR**	**Hidden**	**Drop.**	**Epochs**	**Pat.**	**Val F1**	**Val loss**	**Stop**
0 (Αρχικό)	0.01	64	0.5	150	20	0.9165	0.2398	115
1 (Μείωση lr)	0.001	64	0.5	150	20	0.9063	0.2767	113
2 (Αύξηση lr)	0.05	64	0.5	150	20	0.8882	0.2829	43
3 (Μείωση hid.)	0.01	32	0.5	150	20	0.9148	0.2413	137
4 (Αύξηση hid.)	0.01	128	0.5	150	20	0.9134	0.2435	96
5 (Μείωση drop.)	0.01	64	0.3	150	20	0.9035	0.2370	150
6 (Αύξηση drop.)	0.01	64	0.7	150	20	0.9122	0.2390	106
7 (Μείωση pat.)	0.01	64	0.5	150	10	0.8792	0.3788	39
8 (Αύξηση pat.)	0.01	64	0.5	150	35	0.9165	0.2398	130
9 (Μείωση epochs)	0.01	64	0.5	80	20	0.9049	0.2601	80

6.4.2 Ανάλυση αποτελεσμάτων επιλογής υπερπαραμέτρων και βέλτιστου μοντέλου

Η *αυξομείωση του ρυθμού μάθησης* αποδείχθηκε η πιο κρίσιμη υπερπαράμετρος. Η μείωση σε 0.001 (πείραμα 1) επιβράδυνε τη σύγκλιση - στο epoch 100 το Val Loss ήταν ακόμα στο 0.2837 έναντι του 0.2443 του αρχικού πειράματος - και τελικά σταμάτησε σε μεγαλύτερο τοπικό ελάχιστο (0.2767), με αποτέλεσμα την μείωση του Val F1 σε 0.9063. Αυτό αποδεικνύει ότι όταν έχει μικρότερο lr το μοντέλο, τα βάρη αλλάζουν λίγο σε κάθε βήμα και για να φτάσει ο optimizer σε καλό ελάχιστο χρειάζεται περισσότερα epochs. Αντίθετα, η αύξηση του lr σε 0.05 (πείραμα 2) οδήγησε σε πρόωρη σύγκλιση και το early stopping ενεργοποιήθηκε από epoch 43 με το μικρότερο Val F1 (0.8882) από όλα τα πειράματα επιλογής υπερπαραμέτρων. Συμβαίνει overshooting, όπου τα βήματα ενημέρωσης είναι τόσο μεγάλα που το μοντέλο προσπερνά το ελάχιστο της συνάρτησης απώλειας αντί να συγκλίνει ομαλά σε αυτό. Άρα το αρχικό πείραμα (lr=0.01) βρίσκεται κοντά στην βέλτιστη τιμή του lr.

Όσον αφορά τη *διάσταση του κρυφού επιπέδου (hidden channels)* (πειράματα 3,4), οι διαφορές είναι μικρές (Val F1 0.9148 για 32 hidden channels, Val F1 0.9134 για 128 hidden channels, έναντι Val F1 0.9165 αρχικού πειράματος στα 64 hidden channels), κάτι που δείχνει ότι στο μοντέλο δεν υπάρχει πληροφορία που να χάνεται λόγω μικρής χωρητικότητας ή στην περίπτωση των 128 διαστάσεων κρυφού επιπέδου, δεν υπάρχει επιπλέον πληροφορία να εκμεταλλευτεί η μεγαλύτερη χωρητικότητα. Εφόσον η κύρια πληροφορία προέρχεται από τα προεκπαιδευμένα embeddings,

το GraphSAGE συνδυάζει την τοπολογική πληροφορία πάνω σε σημασιολογικά χαρακτηριστικά, οπότε δεν χρειάζεται μεγάλη χωρητικότητα. Η διάσταση 64 (αρχικό πείραμα) πρακτικά προσφέρει την καλύτερη ισορροπία με Val loss 0.2398.

Σχετικά με το *dropout* (πειράματα 5,6), η μείωση σε 0.3 υποβάθμισε λίγο την απόδοση (0.9035) και έτρεξε ολόκληρα τα 150 epochs χωρίς να ενεργοποιηθεί early stopping. Αυτό αποτελεί ένδειξη παρουσίας overfitting, όπου με μικρότερο dropout το μοντέλο συνεχίζει να μειώνει το train loss αλλά το val loss ταλαντεύεται χωρίς σταθερή βελτίωση και χωρίς να μειωθεί αρκετά σε συνεχόμενα 20 epochs (patience) ώστε να ενεργοποιηθεί το early stopping. Η αύξηση σε 0.7 (πείραμα 6) έδωσε σχεδόν ίδιο αποτέλεσμα με το αρχικό (Val F1 0.9122), δείχνοντας ότι το μοντέλο παρά το υψηλό dropout δεν χάνει πληροφορία.

Η μείωση του patience (πειράματα 7,8) έδωσε το χειρότερο Val F1 (0.8792) μετά το πείραμα 2 με lr=0.05, σταματώντας στο epoch 39 πολύ νωρίς πριν προλάβει να εκμεταλλευτεί τη μείωση του lr από τον scheduler ReduceLROnPlateau με patience=5. Αυτός ο πρόωρος τερματισμός δεν συνεπάγεται καλύτερη γενίκευση αλλά υποδεικνύουν ότι τα 10 epochs υπομονής δεν επαρκούν για το μοντέλο που τα βήματα δείχνουν μια συνεχή εναλλαγή μεταξύ βελτίωσης και σταθερότητας. Αντίθετα, η αύξηση σε patience = 35 (πείραμα 8) έδωσε ίδιο Val F1 και Val loss με το αρχικό πείραμα (0.9165 και 0.2398) αλλά σταμάτησε αργότερα στην εποχή 130 αντί 115. Αυτό αποδεικνύει ότι το πραγματικό βέλτιστο σημείο είχε βρεθεί νωρίτερα και στα δύο πειράματα απλά η επιπλέον υπομονή ήταν απλώς αναμονή χωρίς περαιτέρω βελτίωση.

Το τελευταίο πείραμα με την μείωση των *epochs* (πείραμα 9) σταμάτησε την εκπαίδευση πριν φτάσει στο βέλτιστο σημείο, υποδεικνύοντας πως ο μέγιστος αριθμός εποχών είναι ανεπαρκής.

Επιλογή βέλτιστου μοντέλου: Τα πειράματα 0 και 8 έχουν ταυτόσημο Val F1 (0.9165) και Val loss (0.2398), καθώς εντόπισαν το ίδιο ακριβώς βέλτιστο σημείο. Η μόνη διαφορά είναι το patience (20 έναντι 35) και πόσα epochs περιμένει το μοντέλο μετά το βέλτιστο σημείο πριν σταματήσει. Επιλέγεται το αρχικό πείραμα γιατί έχει τα ίδια αποτελέσματα με το όγδοο πείραμα αλλά με λιγότερο υπολογιστικό κόστος -σταματάει στην εποχή 115 χωρίς απώλεια ακρίβειας. Επιλέγοντας το 8ο πείραμα θα έδινε την εντύπωση ότι η αλλαγή της υπερπαραμέτρου patience συνέβαλε σε καλύτερο αποτέλεσμα ενώ στην πραγματικότητα είναι στατιστικά πανομοιότυπο με το αρχικό. Συμπερασματικά, ο πίνακας δείχνει ότι το αρχικό πείραμα υπερπαραμέτρων (lr=0.01, hidden=64, dropout=0.5, patience=20) είναι το βέλτιστο, καθώς καμία μεταβολή δεν το ξεπέρασε, ενώ άλλες το επιδείνωσαν.

6.5 Απόδοση του μοντέλου σε επίπεδο βασικής τοπολογίας

Το μοντέλο εκπαιδεύεται ώστε να εντοπίσει κακόβουλες πρακτικές μέσω της ανάλυσης του ετερογενούς γράφου. Πρακτικά, το σύστημα επεξεργάζεται τον όγκο των ακαδημαϊκών δεδομένων, συνδυάζοντας σημασιολογικά χαρακτηριστικά κειμένου (embeddings) και στατιστικά στοιχεία των αναφορών των άρθρων με την τοπολογική δομή των βιβλιογραφικών παραπομπών και των συνεργασιών των συγγραφέων. Κατά την εκπαίδευση, το μοντέλο εφαρμόζει εφαρμόζει μηχανισμούς νευρωνικής μάθησης (Hetero-GraphSAGE) για να αναγνωρίσει διακριτά πρότυπα που διαχωρίζουν τα έγκυρα άρθρα από τα ανακληθέντα.

Πίνακας 6.3: Αποτελέσματα βασικού μοντέλου Hetero-GraphSAGE στο test set.

Epoch	**Train Loss**	**Val Loss**	**Μετρική**	**Τιμή**
10	0.4197	0.6045	Accuracy	0.9079
20	0.3009	0.4972	Precision	0.8939
30	0.2326	0.3807	Recall	0.9257
40	0.1899	0.3996	F1 Score	0.9095
50	0.1711	0.3307	ROC AUC	0.9688
60	0.1597	0.2966	Avg. Precision	0.9677
70	0.1463	0.2731		
80	0.1336	0.2601		
90	0.1189	0.2466		
100	0.1069	0.2443		
110	0.0958	0.2456		
Early stopping: epoch 115		*Best epoch: 95*	*Val Loss: 0.2398*	*Val F1: 0.9165*

Κατά την διάρκεια της εκπαίδευσης, το μοντέλο παρουσίασε σταθερή μείωση τόσο στο train loss όσο και στο val loss, γεγονός που υποδεικνύει ομαλή σύγκλιση. Συγκεκριμένα, το train loss μειώθηκε από 0.4197 στο epoch 10 σε 0.0958 στο epoch 110, ενώ η val loss από 0.6045 σε 0.2456 αντίστοιχα. Βέβαια το val loss είχε μια παροδική αύξηση στο epoch 40 (0.3996 έναντι 0.3807 του epoch 30), η οποία αποδίδεται σε προσωρινή αστάθεια κατά την προσαρμογή του learning rate από τον scheduler. Το early stopping ενεργοποιήθηκε στην εποχή 115, με βέλτιστο σημείο στην εποχή 95.

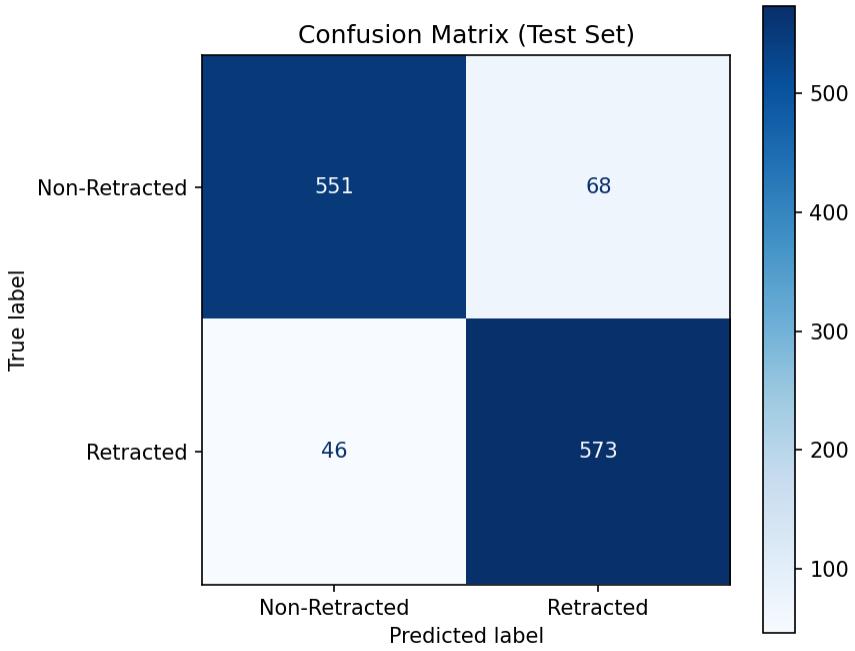
Το βέλτιστο σημείο αξιολογήθηκε στο test set, επιτυγχάνοντας ορθότητα (accuracy) 90.79%, precision 89.39%, recall 92.57% και F1-score 90.95%. Το υψηλό recall έναντι precision υποδεικνύει ότι το μοντέλο είναι πιο συντηρητικό ως προς τα false negatives -δηλαδή θα χαρακτηρίσει ένα άρθρο ως ανακληθέν παρά να το αφήσει χωρίς ετικέτα, χαρακτηριστικό που βοηθάει στον εντοπισμό ακαδημαϊκής απάτης όπου θα κόστιζε παραπάνω η διαφυγή ενός ανακληθέντος άρθρου από ότι ένα false positive.

Πίνακας 6.4: Στατιστικά ετερογενούς γράφου βασικού μοντέλου.

Κατηγορία	**Τύπος**	**Πλήθος**
Κόμβοι	paper (dataset)	6.190
	paper (+ leaf references)	325.115
	author	26.690
Ακμές	author → writes → paper	31.065
	paper → written_by → author	31.065
	paper → cites → paper	357.977
	paper → cited_by → paper	357.977
	author → collaborates → author	243.310
	paper → shares_refs → paper	12.592
	paper → shared_refs_by → paper	12.592
Μέσος βαθμός	paper	129,77
	author	11,44

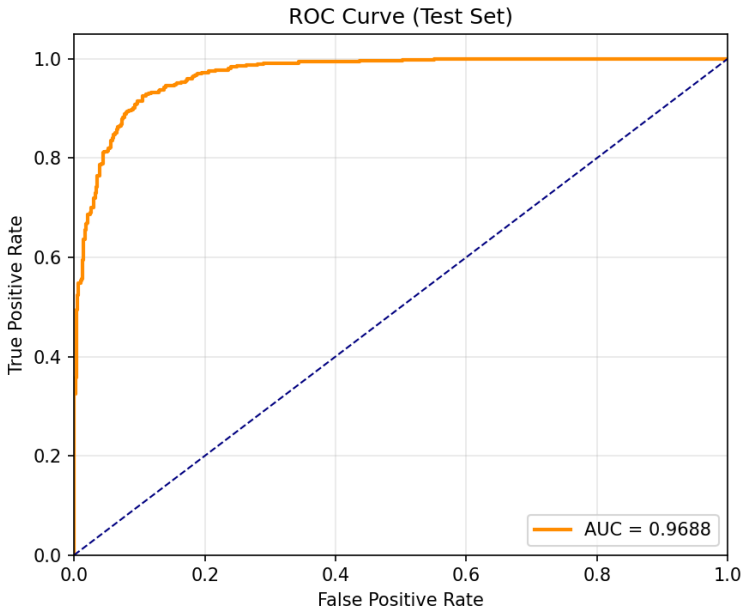
Ανάλυση Confusion Matrix

Σχήμα 6.1: Πίνακας σύγχυσης (confusion matrix) βασικού μοντέλου



Ο πίνακας σύγχυσης αποκαλύπτει 551 ορθώς ταξινομημένα έγκυρα άρθρα (TN) και 573 ορθώς ταξινομημένα ανακληθέντα (TP), με 68 false positives και 46 false negatives. Το μοντέλο κάνει περισσότερα λάθη στην κατηγορία των έγκυρων άρθρων (68 FP) από ότι στα ανακληθέντα (46), γεγονός που εξηγεί την υπεροχή του recall (0.9257) έναντι της precision (0.8939).

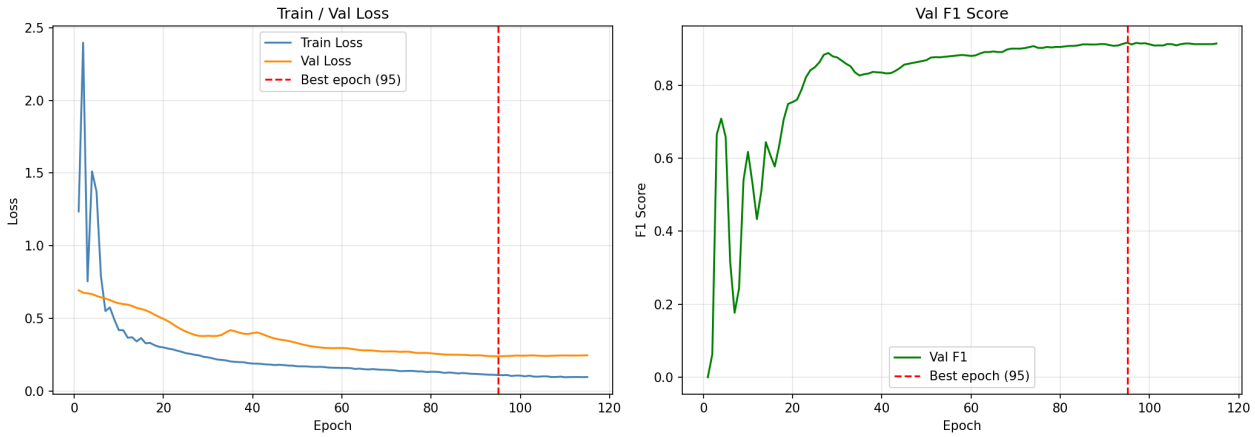
Ανάλυση Καμπυλών ROC



Σχήμα 6.2: Roc curve main

Η καμπύλη ROC (Receiver Operating Characteristic) με AUC (Area Under the Curve) ίσο με 0.9688 υποδεικνύει μια σημαντική διαχωριστική ικανότητα του μοντέλου μεταξύ των δύο κλάσεων. Η καμπύλη ανεβαίνει απότομα προς την πάνω αριστερά γωνία ήδη από πολύ χαμηλές τιμές false positive, κάτι που σημαίνει πως το μοντέλο επιτυγχάνει υψηλό true positive rate με ελάχιστα false positives. Η υψηλή τιμή ROC AUC (0.9688) σε συνδυασμό με το Average Precision 0.9677 υποδεικνύουν ότι η διαχωριστική ικανότητα του μοντέλου είναι ανεξάρτητη από το επιλεγμένο κατώφλι απόφασης — δηλαδή το μοντέλο δεν ταξινομεί τυχαία σωστά σε ένα συγκεκριμένο κατώφλι, αλλά διαθέτει πραγματική ικανότητα γενίκευσης.

Ανάλυση καμπυλών σύγκλισης train/val

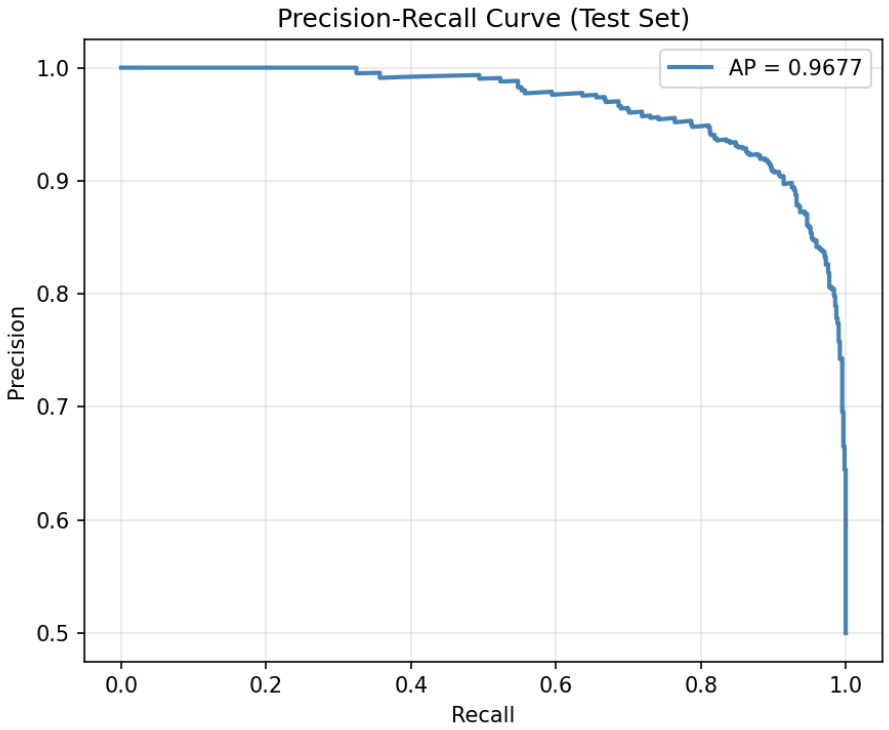


Σχήμα 6.3: Καμπύλες σύγκλισης train/val loss και val F1.

Κατά τις πρώτες εποχές εκπαίδευσης, παρατηρείται ένα έντονο spike στο train loss (epoch 2-2.5), το οποίο αποδίδεται στη δυναμική προσαρμογή των βαρών του GraphSAGE κατά τη διαδικασία του message passing, καθώς το μοντέλο σταδιακά εξισορροπεί τη σημασιολογική πληροφορία των SPECTER 2 embeddings με την τοπολογική δομή γράφου. Μετά το spike, το train loss μειώνεται σταθερά, ενώ το val loss ξεκινάει να μειώνεται, στην εποχή 38 παρουσιάζει μια αύξηση, και από εκεί και πέρα μειώνεται σταθερά μέχρι την εποχή 95 που σταθεροποιείται στο βέλτιστο σημείο. Η συνεχής μείωση του train loss μετά το epoch 95 παράλληλα με την στασιμότητα του val loss αποτελεί ένδειξη ήπιας υπερπροσαρμογής την οποία το early stopping αντιμετώπισε αποτελεσματικά.

Ανάλυση Precision-Recall curve

Η καμπύλη Val F1 παρουσιάζει έντονες διακυμάνσεις κατά τις πρώτες 25 εποχές, με τιμές που κυμαίνονται μεταξύ 0.0 και 0.8, αντανακλώντας την αστάθεια της αρχικής φάσης εκπαίδευσης όπου το μοντέλο δεν έχει ακόμα συγκλίνει σε σταθερές αναπαραστάσεις. Από το epoch 20 και έπειτα, το Val F1 αυξάνεται σταδιακά και σταθεροποιείται, φτάνοντας στο βέλτιστο 0.9165 στο epoch 95. Μετά το best epoch το Val F1 παραμένει σχεδόν σταθερό, επιβεβαιώνοντας ότι το early stopping σταμάτησε την εκπαίδευση σε ένα σημείο που δεν έχασε επιπλέον απόδοση.



Σχήμα 6.4: Precision Recall curve main

Η καμπύλη Precision-Recall με μέσο όρο precision 0.9677 επιδεικνύει την απόδοση του μοντέλου, με την precision να παραμένει σταθερά στο 1 για τιμές recall έως 0.35, υποδεικνύοντας ότι σε συντηρητικά κατώφλια απόφασης το μοντέλο δεν παράγει σχεδόν κανένα false positive. Από το recall 0.35 έως 0.85 η precision μειώνεται σταδιακά παραμένοντας πάνω από 0.90 ενώ η πτώση

επιταχύνεται μόνο για recall άνω του 0.90, όπου το μοντέλο ”αναγκάζεται” να αποδεχτεί περισσότερα false positives. Συνολικά, η καμπύλη υποδεικνύει ότι το μοντέλο διατηρεί υψηλή ακρίβεια σε ένα πλατύ εύρος κατωφλίων.

6.6 Πειραματική αξιολόγηση εμπλουτισμού γράφου

Παρά την αποτελεσματικότητα του βασικού μοντέλου στην αξιοποίηση της δομικής πληροφορίας, η φύση της επιστημονικής απάτης συχνά περιλαμβάνει στρατηγικές που στοχεύουν στην απόκρυψη συνδέσεων, όπως η δημιουργία τεχνητών βιβλιογραφικών παραπομπών. Για την ενίσχυση της διακριτικής ικανότητας του δικτύου έναντι τέτοιων τακτικών, ο ετερογενής γράφος εμπλουτίζεται με πρόσθετα επίπεδα σημασιολογικής και τοπολογικής πληροφορίας. Ο στόχος είναι το μοντέλο GraphSAGE να βρει εναλλακτικές διαδρομές επικοινωνίας (message passing) για καλύτερο και πιο αξιόπιστο τρόπο ανίχνευσης των άρθρων που πρέπει να ανακληθούν.

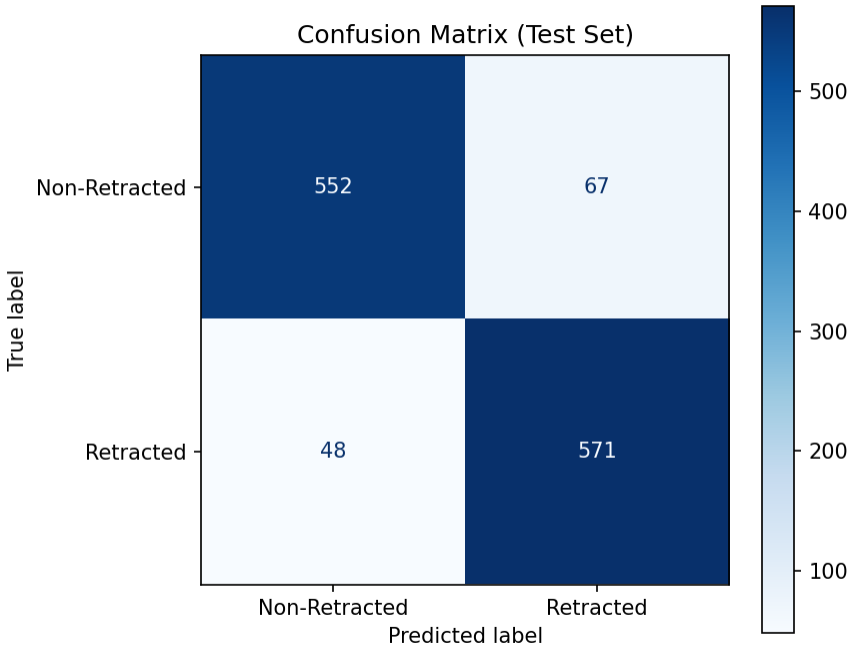
6.6.1 Πείραμα 1: Ενσωμάτωση σημασιολογικών ακμών (cosine similarity)

Στο πλαίσιο του πρώτου πειράματος, η τοπολογία του βασικού ετερογενούς γράφου εμπλουτίζεται μέσω της ενσωμάτωσης σημασιολογικών ακμών, με σκοπό την αντιμετώπιση των τακτικών απόκρυψης που εφαρμόζουν τα οργανωμένα δίκτυα εκδοτικής απάτης. Η σύνδεση των paper mills με βάση τη νοηματική ομοιότητα παρέχει στο GraphSAGE εναλλακτικές δομικές διαδρομές εντοπισμού. Προγραμματιστικά, εφαρμόστηκε L_2 κανονικοποίηση στα διανύσματα SPECTER 2, η οποία προβάλλει κάθε διάνυσμα σε μια τυποποιημένη κλίμακα μήκους μονάδας. Με τον τρόπο αυτό, η σημασιολογική ομοιότητα εξαρτάται αποκλειστικά από την κατεύθυνση των διανυσμάτων στον χώρο, επιτρέποντας στο μοντέλο να εξάγει την ομοιότητα συνημίτονου μέσω πράξεων πολλαπλασιασμού πινάκων. Η διαδικασία αυτή καθιστά τον συγκριτικό έλεγχο μεταξύ εκατοντάδων χιλιάδων άρθρων αποδοτικό, απομονώνοντας την ουσιαστική θεματική συγγένεια από τις διαφορές στην κλίμακα των δεδομένων. Μέσω της συνάρτησης `torch.mm`, υπολογίστηκε ο πίνακας εσωτερικών γινομένων για την εξαγωγή της ομοιότητας συνημίτονου (cosine similarity) μεταξύ όλων των άρθρων. Αφού μηδενίστηκε η κύρια διαγώνιος για την αποφυγή των ακμών self-loops (ακμή από ένα άρθρο στον εαυτό του), χρησιμοποιήθηκε η συνάρτηση `torch.topk` ώστε να επιλεγούν οι 5 κορυφαίοι γείτονες για κάθε κόμβο, υπό τον περιορισμό ότι η ομοιότητά τους υπερβαίνει το κατώφλι του 0.75 (εμπειρική δοκιμή). Αυτό έγινε για να μην δημιουργηθεί ένας υπερβολικά πυκνός γράφος ο οποίος θα υποβάθμιζε την διαχωριστική ικανότητα του μοντέλου λόγω υπερ-εξομάλυνσης (oversmoothing). Η διαδικασία αυτή εισήγαγε δυναμικά 30.950 νέες ακμές `('paper', 'similar to', 'paper')`, διευρύνοντας σημαντικά τον ιστό ανταλλαγής μηνυμάτων (message passing) του δικτύου.

Πίνακας 6.5: Αποτελέσματα πειράματος Cosine Similarity στο test set.

Epoch	Train Loss	Val Loss	Μετρική	Τιμή
10	0.4343	0.6268	Accuracy	0.9071
20	0.3086	0.4972	Precision	0.8950
30	0.2399	0.3603	Recall	0.9225
40	0.1865	0.3607	F1 Score	0.9085
50	0.1704	0.3312	ROC AUC	0.9671
60	0.1504	0.2882	Avg. Precision	0.9647
70	0.1367	0.2779		
80	0.1235	0.2678		
90	0.1102	0.2567		
100	0.0964	0.2566		
110	0.0896	0.2593		
Early stopping: epoch 115		*Best epoch: 95*	*Val Loss: 0.2545*	*Val F1: 0.9146*

Ανάλυση Confusion Matrix



Σχήμα 6.5: Confusion matrix cosine similarity

Ο πίνακας σύγχυσης εμφανίζει 552 True Negatives, 571 True Positives, 67 False Positives και 48 False Negatives. Σε σύγκριση με τον βασικό κώδικα (551 TN, 573 TP, 68 FP, 46 FN), οι διαφορές είναι ελάχιστες — ένα επιπλέον σωστά ταξινομημένο non-retracted και δύο λιγότερα σωστά ταξινομημένα retracted. Ο λόγος recall/precision παραμένει παρόμοιος, με recall (0.9225) ελαφρώς χαμηλότερο από αυτό του βασικού κώδικα (0.9257). Παρά την προσθήκη 30.950 ακμών σημασιολογικής ομοιότητας, το μοντέλο δεν παρουσίασε βελτίωση σε καμία μετρική — το F1 μειώθηκε

οριακά από 0.9095 σε 0.9085, το AUC από 0.9688 σε 0.9671 και το AP από 0.9677 σε 0.9647. Αυτό υποδεικνύει ότι η σημασιολογική πληροφορία που εκφράζουν οι cosine similarity ακμές εμπεριέχεται ήδη στα embeddings που χρησιμοποιούνται ως node features.

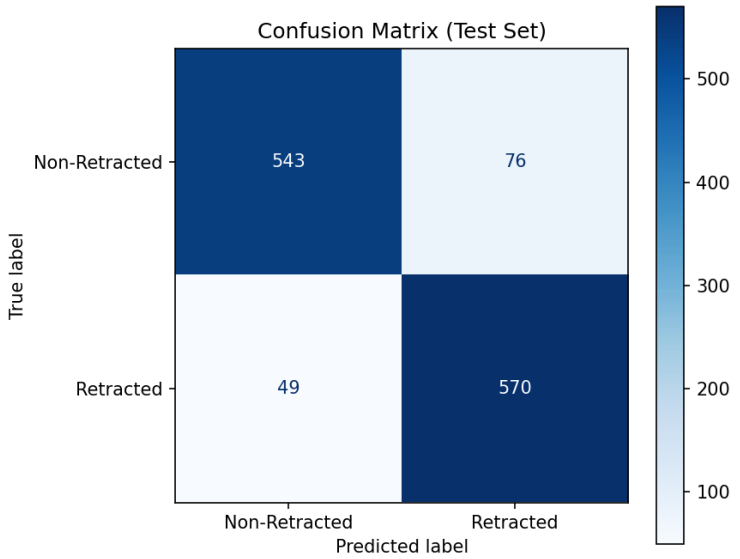
6.6.2 Πείραμα 2: Ενσωμάτωση κόμβων-πανεπιστημίου

Η δεύτερη πειραματική επέκταση επικεντρώνεται στην εισαγωγή κόμβων των ακαδημαϊκών ιδρυμάτων (university nodes) στον ετερογενή γράφο, με σκοπό τη μοντελοποίηση μακρο-δομικών κοινοτήτων (macro-hubs). Στο πλαίσιο της εκδοτικής απάτης, τα οργανωμένα δίκτυα (paper mills) συχνά συγκεντρώνουν τη δραστηριότητά τους ή δημιουργούν εικονικούς συγγραφείς σε συγκεκριμένα ιδρύματα, καθιστώντας την ιδρυματική συνεκτικότητα κρίσιμο παράγοντα ανίχνευσης. Προγραμματιστικά, χρησιμοποιήθηκε μια κανονική έκφραση (`regex`) για την εξαγωγή του ονόματος του πανεπιστημίου από το πεδίο των συγγραφέων και μέσω ενός μηχανισμού αντιστοίχισης (uni mapping) εντοπίστηκαν 5.767 διακριτά πανεπιστήμια. Καθώς αυτοί οι κόμβοι δεν έχουν ουσιαστικά χαρακτηριστικά, εφαρμόστηκε η προσέγγιση των σταθερών χαρακτηριστικών (dummy features), αρχικοποιώντας τον πίνακα `uni_features_tensor`) με την μονάδα (`torch.ones`). Η τεχνική αυτή αναγκάζει τον αλγόριθμο GraphSAGE να μάθει τις αναπαραστάσεις των πανεπιστημίων αποκλειστικά από την τοπολογία τους, μέσω της δημιουργίας αμφίδρομων ακμών (`('affiliated with', 'has author')` μεταξύ συγγραφέων και ιδρυμάτων. Με τη δομή αυτή, η πληροφορία ρέει από τον εκάστοτε συγγραφέα προς το πανεπιστήμιο και διαχέεται μέσω του message passing στους υπόλοιπους ερευνητές του ίδιου ιδρύματος.

Πίνακας 6.6: Αποτελέσματα πειράματος University Nodes στο test set.

Epoch	**Train Loss**	**Val Loss**	**Μετρική**	**Τιμή**
10	0.4302	0.6150	Accuracy	0.8990
20	0.2930	0.5103	Precision	0.8824
30	0.2204	0.3623	Recall	0.9208
40	0.1748	0.3813	F1 Score	0.9012
50	0.1527	0.3143	ROC AUC	0.9678
60	0.1376	0.2615	Avg. Precision	0.9670
70	0.1263	0.2431		
80	0.1129	0.2378		
90	0.0985	0.2376		
100	0.0961	0.2385		
Early stopping: epoch 103		*Best epoch: 83*	*Val Loss: 0.2345*	*Val F1: 0.9306*

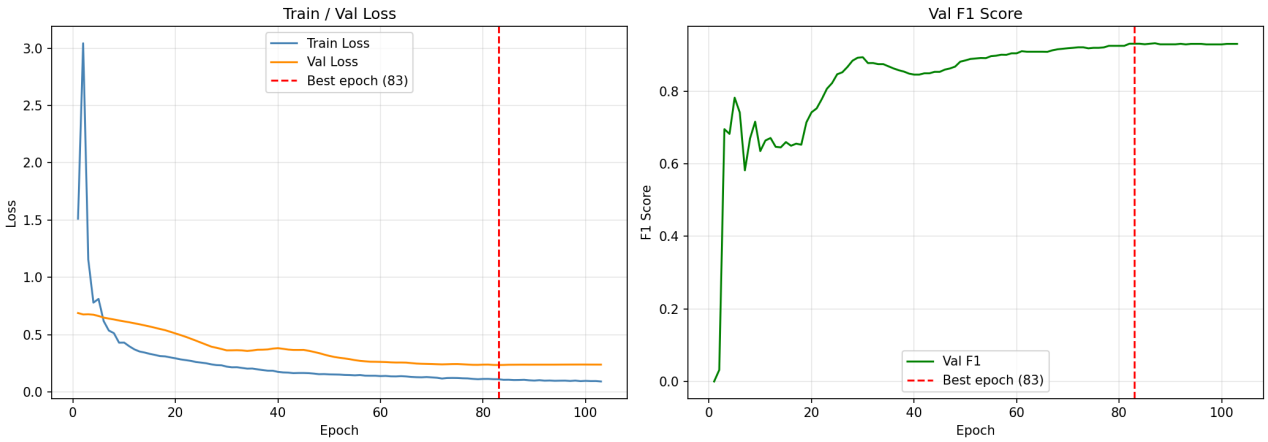
Ανάλυση Confusion Matrix



Σχήμα 6.6: Confusion matrix uni nodes

Ο πίνακας σύγχυσης αποκαλύπτει 543 True Negatives, 570 True Positives, 76 False Positives και 49 False Negatives. Σε σύγκριση με τον βασικό κώδικα, τα false positives αυξήθηκαν κατά 8, δηλαδή το μοντέλο χαρακτηρίζει περισσότερα μη ανακληθέντα άρθρα ως ανακληθέντα — για αυτόν τον λόγο μειώθηκε η precision (0.8824 έναντι 0.8939).

Ανάλυση loss curve



Σχήμα 6.7: Loss curve uni nodes

Η καμπύλη παρουσιάζει το ίδιο αρχικό spike στο train loss με τον βασικό κώδικα, ακολουθούμενο από ομαλή σύγκλιση. Το best epoch εντοπίζεται στο epoch 83, νωρίτερα από το best epoch

του βασικού κώδικα, υποδεικνύοντας ότι οι κόμβοι-πανεπιστήμια επιταχύνουν την σύγκλιση παρέχοντας επιπλέον τοπολογική πληροφορία μέσω των ακμών affiliated_with. Ωστόσο, η val loss στο βέλτιστο σημείο (0.2345) είναι ελαφρώς χαμηλότερη από αυτή του βασικού κώδικα (0.2398), γεγονός που εξηγεί το υψηλότερο Val F1 (0.9306), η βελτίωση αυτή όμως δεν είχε αντίστοιχη βελτίωση στο test set, υποδεικνύοντας ότι η πληροφορίας των uni nodes ευνοεί το validation set χωρίς να γενικεύεται εξίσου. Παρά τη βελτίωση του Val F1 (0.9306 έναντι 0.9165 του βασικού κώδικα), όλες οι μετρικές στο test set μειώθηκαν ελάχιστα.

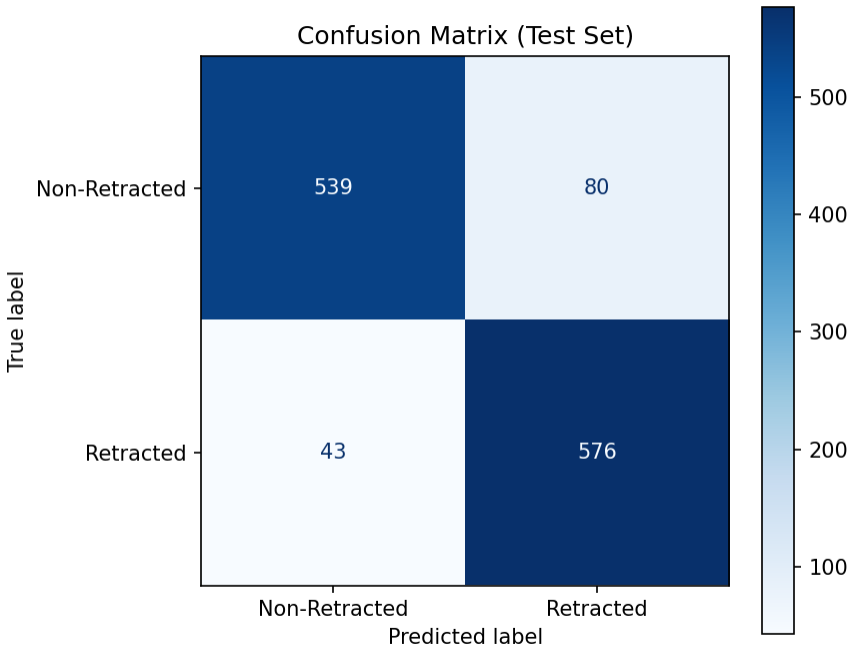
6.6.3 Πείραμα 3: Ενσωμάτωση κόμβων-χώρας

Η τρίτη πειραματική επέκταση επικεντρώνεται στη μοντελοποίηση γεωγραφικών μακροκοινοτήτων, μέσω της εισαγωγής κόμβων χώρας (country nodes). Στη βιβλιογραφία της εκδοτικής απάτης, τα οργανωμένα δίκτυα (paper mills) συχνά παρουσιάζουν ισχυρή γεωγραφική συγκέντρωση, εκμεταλλευόμενα συγκεκριμένα εθνικά συστήματα αξιολόγησης ή ελλιπείς ελεγκτικούς μηχανισμούς. Προγραμματιστικά, αξιοποιήθηκε μια κανονική έκφραση (`regex`) για την εξαγωγή της τοποθεσίας από το πεδίο των συγγραφέων, εντοπίζοντας συνολικά 236 μοναδικές χώρες. Καθώς πρόκειται για γεωγραφικές οντότητες χωρίς δικά τους δεδομένα, εφαρμόστηκε και εδώ η στρατηγική σταθερών χαρακτηριστικών (dummy features), αρχικοποιώντας τον πίνακα των 236 κόμβων με την μονάδα (`torch.ones`). Με τη δημιουργία 30.723 αμφίδρομων ακμών μεταξύ συγγραφέων και χωρών (`'located in', 'has author'`), οι χώρες μετατρέπονται σε γεωγραφικούς υπερ-κόμβους (super-hubs) (έχουν πολύ μεγαλύτερο βαθμό συνδεσιμότητας (degree) από έναν κόμβο-πανεπιστήμιο) επιτρέποντας στη δομική πληροφορία να διαδοθεί σε όλους τους ερευνητές μιας χώρας, ανεξαρτήτως του ιδρύματος στο οποίο ανήκουν.

Πίνακας 6.7: Αποτελέσματα πειράματος Country Nodes στο test set.

Epoch	**Train Loss**	**Val Loss**	**Μετρική**	**Τιμή**
10	0.3708	0.6391	Accuracy	0.9006
20	0.2648	0.5208	Precision	0.8780
30	0.2070	0.3634	Recall	0.9305
40	0.1556	0.4372	F1 Score	0.9035
50	0.1369	0.3152	ROC AUC	0.9680
60	0.1248	0.2676	Avg. Precision	0.9667
70	0.1121	0.2498		
80	0.1024	0.2517		
90	0.0946	0.2504		
Early stopping: epoch 93		*Best epoch: 73*	*Val Loss: 0.2456*	*Val F1: 0.9097*

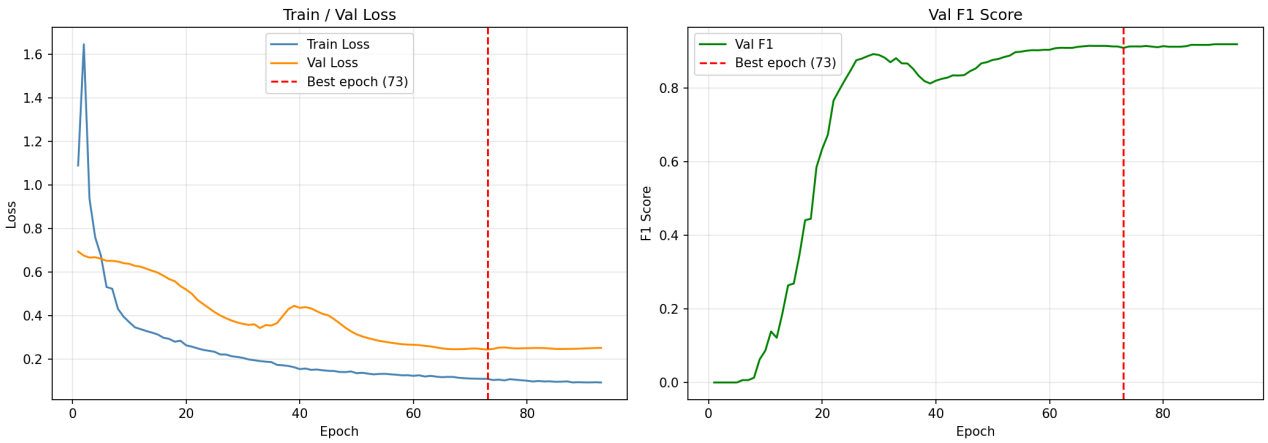
Ανάλυση confusion matrix



Σχήμα 6.8: Confusion matrix country nodes

Τα True Positive αυξήθηκαν (576) και τα False Negative μειώθηκαν (43), δηλαδή υπήρξε καλύτερη κάλυψη των ανακληθέντων άρθρων αλλά με κόστος στα False Positive (80 vs 68). Το αποτέλεσμα αυτό ερμηνεύεται από τον υψηλό μέσο βαθμό των country κόμβων (416.65): κάθε χώρα συνδέεται με εκατοντάδες συγγραφείς, εισάγοντας υπερβολικά γενική πληροφορία που «αναμιγνύει» άρθρα διαφορετικών κατηγοριών μέσω του message passing.

Ανάλυση loss curve



Σχήμα 6.9: Loss curve country nodes

Το Val F1 ξεκινάει σχεδόν από το 0 στα πρώτα 10 epochs (0.0867) - πολύ αργότερα από τον βασικό κώδικα - λόγω του θορύβου που εισάγουν οι κόμβοι-χώρες με τον μέσο βαθμό άρθρων-κόμβων να είναι 416.65. Η Val loss έχει έντονη αύξηση μέχρι το epoch 40 (από 0.36 στο 0.44), μια αστάθεια που δεν παρατηρείται στον βασικό κώδικα και αντικατοπτρίζει την επίδραση των country nodes στο message passing.

Το πείραμα Country Nodes παρουσιάζει παρόμοιο μοτίβο με το πείραμα University Nodes: το Val F1 στο βέλτιστο σημείο (0.9097) είναι χαμηλότερο από το αντίστοιχο του πειράματος University Nodes (0.9306) αλλά συγκρίσιμο με αυτό του βασικού κώδικα (0.9165), ενώ το Test F1 (0.9035) έχει μειωθεί ελάχιστα σε σχέση με αυτό του βασικού κώδικα (0.9095). Το recall βελτιώθηκε (0.9305 vs 0.9257), αλλά μειώθηκε η μετρική precision (0.8780 vs 0.8939) — το μοντέλο γίνεται πιο «επιθετικό» στον χαρακτηρισμό άρθρων ως retracted, αυξάνοντας τα False Positive σε 80 από 68 του βασικού κώδικα. Όλες οι μετρικές υποχώρησαν σε σχέση με τον βασικό κώδικα εκτός από την μετρική recall που αυξήθηκε στο 0.9305 (συνέπεια της μείωσης της μετρικής precision), και έτσι το μοντέλο χαρακτηρίζει περισσότερα άρθρα ως retracted (80 False Positive αντί 68).

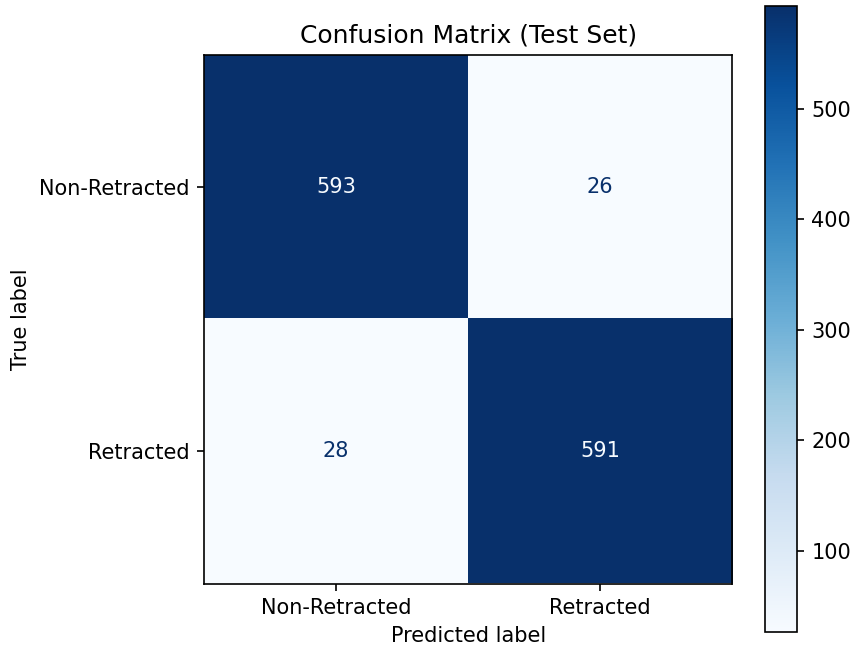
6.6.4 Πείραμα 4: Ενσωμάτωση κόμβων-επιστημονικών περιοδικών

Η τέταρτη πειραματική επέκταση στοχεύει στη μοντελοποίηση του εκδοτικού περιβάλλοντος μέσω εισαγωγής κόμβων επιστημονικών περιοδικών (journal nodes). Στο ευρύτερο ερευνητικό πεδίο της εκδοτικής απάτης, τα οργανωμένα δίκτυα (paper mills) συχνά παρακάμπτουν τις παραδοσιακές διαδικασίες αξιολόγησης στοχεύοντας μαζικά συγκεκριμένα κακόβουλα περιοδικά (predatory journals) ή αλλοιωμένα ειδικά τεύχη (hijacked special issues). Προγραμματιστικά, το όνομα κάθε περιοδικού εξήχθη απευθείας από το αντίστοιχο πεδίο του dataset, εντοπίζοντας 558 εκδοτικές οντότητες. Καθώς δεν υπήρχαν διαθέσιμα κειμενικά χαρακτηριστικά για τα επιστημονικά περιοδικά, εφαρμόστηκε η τεχνική των σταθερών χαρακτηριστικών (dummy features), αρχικοποιώντας τους 558 κόμβους με τη μονάδα (`torch.ones`). Στη συνέχεια, δημιουργήθηκαν αμφίδρομες τοπολογικές ακμές (`published in, has paper`) μεταξύ των άρθρων και των περιοδικών δημοσίευσής τους. Μέσω αυτής της δομής, το περιοδικό λειτουργεί ως ένας στοχευμένος μακρο-κόμβος (macro-hub), καθώς εάν το GraphSAGE εντοπίσει συσσώρευση κακόβουλων άρθρων σε έναν συγκεκριμένο εκδοτικό χώρο, το σήμα της απάτης διαχέεται μέσω του message passing σε όλες τις υπόλοιπες δημοσιεύσεις του ίδιου περιοδικού, αποκαλύπτοντας άρθρα που στερούνταν ύποπτων δοκιμών αναφορών.

Πίνακας 6.8: Αποτελέσματα πειράματος Journal Nodes στο test set.

Epoch	Train Loss	Val Loss	Μετρική	Τιμή
10	0.4802	0.6141	Accuracy	0.9564
20	0.2388	0.4642	Precision	0.9579
30	0.1589	0.5039	Recall	0.9548
40	0.1282	0.3853	F1 Score	0.9563
50	0.1202	0.2129	ROC AUC	0.9914
60	0.1126	0.1672	Avg. Precision	0.9923
70	0.1013	0.1547		
80	0.0936	0.1507		
90	0.0895	0.1384		
100	0.0832	0.1370		
110	0.0852	0.1337		
120	0.0781	0.1336		
130	0.0812	0.1325		
140	0.0759	0.1329		
Early stopping: epoch 149	*Best epoch: 129*	*Val Loss: 0.1325*	*Val F1: 0.9496*	

Ανάλυση confusion matrix

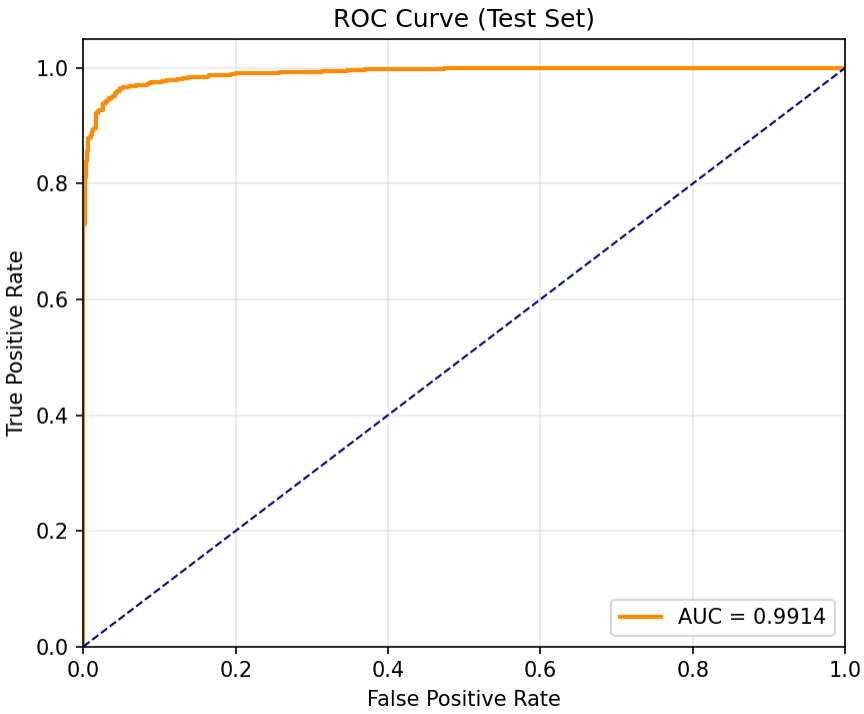


Σχήμα 6.10: Confusion matrix journal nodes

Ο πίνακας σύγχυσης αποτελεί την πιο άμεση απόδειξη της βελτίωσης που εισάγουν οι κόμβοι-επιστημονικά περιοδικά. Το μοντέλο ταξινόμησε ορθά 593 έγκυρα άρθρα (True Negative) και 591 ανακληθέντα (True Positive), με μόλις 26 ψευδώς θετικά (FP) και 28 ψευδώς αρνητικά (FN).

Η ισορροπία μεταξύ False Positive Και False Negative υποδηλώνει ότι το μοντέλο δεν εκδηλώνει κάποια προκατάληψη ως προς μία από τις δύο κλάσεις.

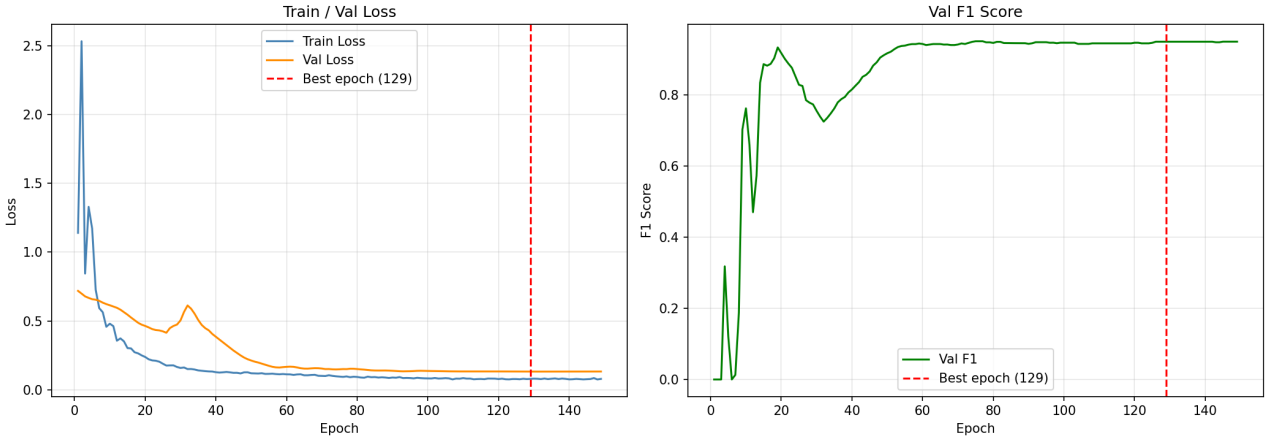
Ανάλυση roc curve



Σχήμα 6.11: ROC curve journal nodes

Η καμπύλη επιδεικνύει υψηλή διαχωριστική ικανότητα με AUC=0.9914, το υψηλότερο από όλα τα πειράματα. Η καμπύλη ανεβαίνει απότομα προς την αριστερή γωνία, φτάνοντας True Positive Rate πάνω από 0.95 για False Positive Rate μόλις 0.05, γεγονός που σημαίνει ότι το μοντέλο επιτυγχάνει υψηλή ανίχνευση ανακληθέντων με ελάχιστες λανθασμένες κατηγοριοποιήσεις.

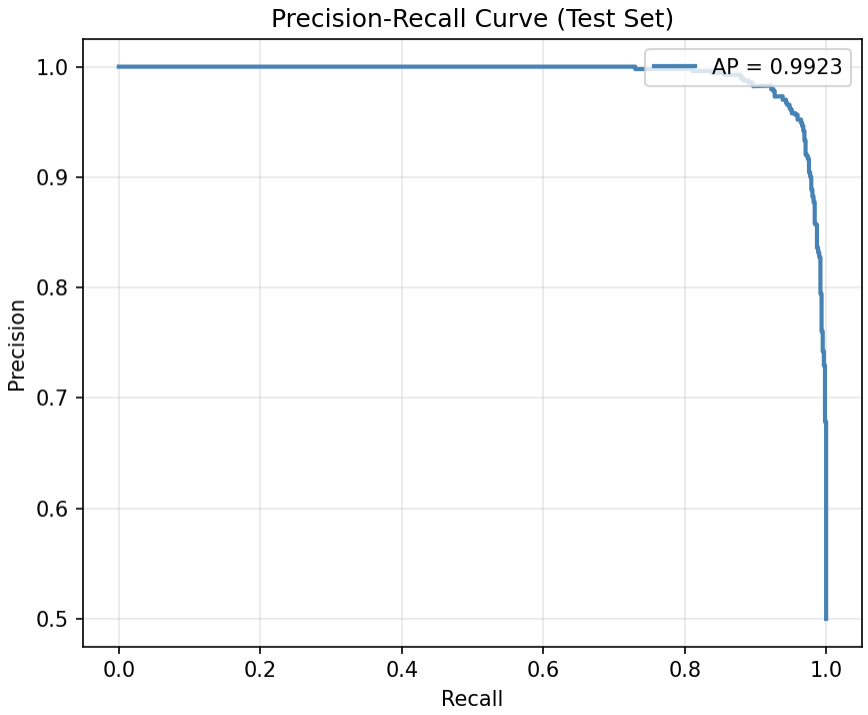
Ανάλυση loss curve



Σχήμα 6.12: Loss curve journal nodes

Η καμπύλη εκπαίδευσης δείχνει μια περίοδο αστάθειας στις πρώτες 40 εποχές,το train loss έχει spikes στις πρώτες 10 εποχές, το Val loss ξεκινάει από 0.63 στην εποχή 10 και το Val F1 κυμαίνεται μεταξύ 0 και 0.92, με δύο μεγάλες πτώσεις στις εποχές 10 και 30. Η αστάθεια αυτή οφείλεται στην ανάγκη του μοντέλου να αρχικοποιήσει ταυτόχρονα embeddings για τους νέους κόμβους επιστημονικών περιοδικών (dummy features), ενώ συντονίζει τις υπάρχουσες. Από την εποχή 50 και μετά, υπάρχει σταθερή σύγκλιση με το Val loss να μειώνεται σταθερά έως το 0.135 στην εποχή 129 και το μοντέλο συνεχίζει να βελτιώνεται με best epoch την εποχή 129, γεγονός που υποδηλώνει ότι η προσθήκη των journal nodes απαιτεί περισσότερες επαναλήψεις για να ενσωματωθεί πλήρως.

Ανάλυση precision/recall curve



Σχήμα 6.13: Precision/recall curve journal nodes

Η καμπύλη Precision-Recall παραμένει σχεδόν οριζόντια στο 1.0 για recall έως 0.75, υποδεικνύοντας ότι το μοντέλο μπορεί να εντοπίσει τα περισσότερα ανακληθέντα άρθρα χωρίς να εισάγει κανένα ψευδώς θετικό. Η πτώση εμφανίζεται μόνο για recall άνω του 0.90, όπου το μοντέλο αναγκάζεται να μειώσει το κατώφλι απόφασης προκειμένου να εντοπίσει τα «δυσκολότερα περιστατικά». Το Average Precision = 0.9923 επιβεβαιώνει ότι η ενσωμάτωση του εκδοτικού πλαισίου ενισχύει σημαντικά τη συνολική ακρίβεια ταξινόμησης.

Τα αποτελέσματα αυτού του πειράματος χρήζουν μιας σημαντικής *επισήμανσης*. Το dataset κατασκευάστηκε με τρόπο ώστε για κάθε ανακληθέν άρθρο να υπάρχει ένα αντίστοιχο έγκυρο από το ίδιο επιστημονικό περιοδικό. Η επιλογή αυτή δημιουργεί μια ειδική συνθήκη για το συγκεκριμένο πείραμα: κάθε κόμβος-επιστημονικό περιοδικό συνδέεται με άρθρα και των δύο κλάσεων, πράγμα που σημαίνει ότι το μοντέλο δεν μπορεί να μάθει ότι κάποια περιοδικά έχουν περισσότερες ανακλήσεις από άλλα. Η βελτίωση στις μετρικές πιθανώς να οφείλεται στο ότι οι κόμβοι-επιστημονικά περιοδικά επιτρέπουν στο μοντέλο να συγκρίνει άρθρα που δημοσιεύτηκαν στον ίδιο εκδοτικό χώρο και να εντοπίζει διαφορές μεταξύ τους. Το κατά πόσο αυτή η βελτίωση θα διατηρηθεί σε πραγματικά δεδομένα, όπου η αναλογία ανακλήσεων ανά περιοδικό δεν είναι τεχνητά ισορροπημένη, παραμένει άγνωστο.

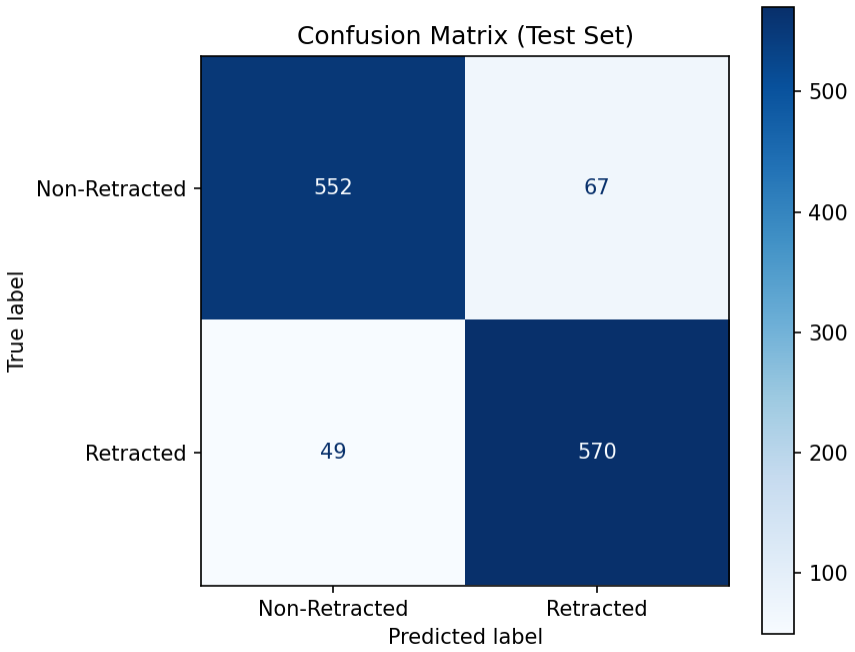
6.6.5 Πείραμα 5: Ενσωμάτωση εικονικού κόμβου

Η πέμπτη πειραματική επέκταση αξιολογεί την προσθήκη ενός εικονικού κόμβου (virtual node) επί της βασικής τοπολογίας του δικτύου. Στη βιβλιογραφία της Μηχανικής Μάθησης Γράφων, ο εικονικός κόμβος εισάγεται ως ένας παγκόσμιος μακρο-κόμβος ο οποίος συνδέεται αμφίδρομα με τους κόμβους-άρθρα του γράφου. Ο στόχος αυτής της τεχνικής είναι η αντιμετώπιση του προβλήματος των μεγάλων αποστάσεων καθώς μειώνει τη μέγιστη τοπολογική απόσταση μεταξύ οποιωνδήποτε δύο κόμβων σε μόλις δύο βήματα (hop distance). Προγραμματιστικά, δημιουργήθηκε ένας μοναδικός κόμβος (id:0) στον οποίο εκχωρήθηκε ένα σταθερό διάνυσμα χαρακτηριστικών και στη συνέχεια κατασκευάστηκαν 12.380 κατευθυνόμενες ακμές (`broadcasts to, sends to`), συνδέοντας τον άμεσα με το σύνολο των 6.190 άρθρων του συνόλου δεδομένων. Σε αντίθεση με το βασικό μοντέλο, όπου η μάθηση περιορίζεται στην άμεση γειτονιά κάθε κόμβου, ο εικονικός κόμβος επιτρέπει στο σύστημα να αποκτήσει μια σφαιρική επίγνωση της τοπολογίας του γράφου. Με αυτόν τον τρόπο, το μοντέλο δύναται να συσχετίσει "ύποπτα" άρθρα που βρίσκονται σε απομακρυσμένες περιοχές του δικτύου, αναγνωρίζοντας μοτίβα χειραγώγησης, που εξαιτίας της μεγάλης τοπολογικής απόστασης, θα παρέμεναν αόρατα. Μέσω αυτού του παγκόσμιου διαύλου, το GraphSAGE καλείται να συμπυκνώσει τη συνολική δομική κατάσταση του δικτύου σε ένα ενιαίο διάνυσμα και να το αναμεταδώσει πίσω σε κάθε άρθρο κατά τη διαδικασία του message passing.

Πίνακας 6.9: Αποτελέσματα πειράματος Virtual Node στο test set.

Epoch	**Train Loss**	**Val Loss**	**Μετρική**	**Τιμή**
10	0.4906	0.4509	Accuracy	0.9063
20	0.3506	0.3568	Precision	0.8948
30	0.2893	0.3391	Recall	0.9208
40	0.2503	0.3039	F1 Score	0.9076
50	0.2021	0.3080	ROC AUC	0.9634
60	0.1836	0.2823	Avg. Precision	0.9604
70	0.1505	0.2825		
Early stopping: epoch 73		*Best epoch: 53*	*Val Loss: 0.2799*	*Val F1: 0.8956*

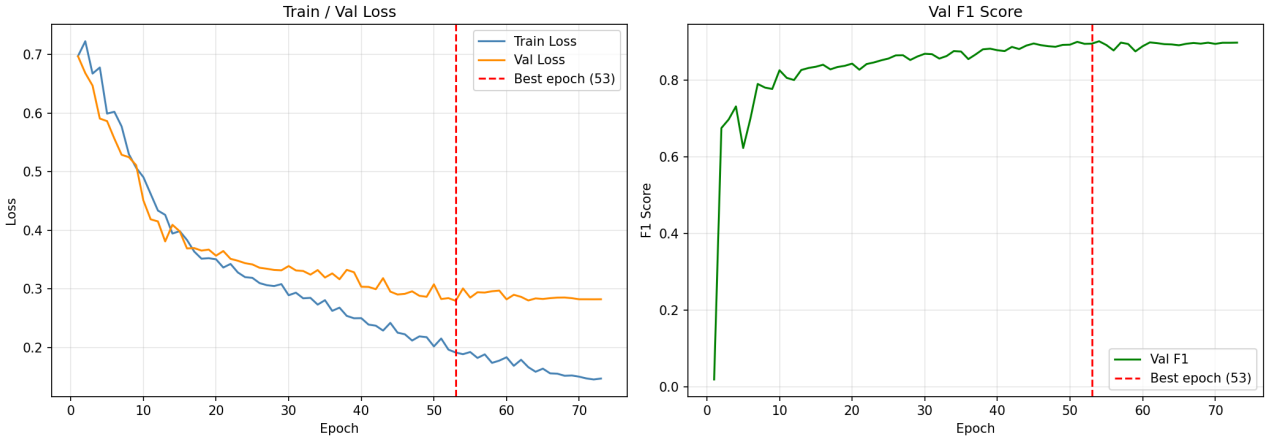
Ανάλυση confusion matrix virtual node



Σχήμα 6.14: Confusion matrix virtual node

Ο πίνακας σύγχυσης του πειράματος Virtual Node καταγράφει 552 True Negative, 570 True Positive, 67 False Positive και 49 False Negative, αποτελέσματα σχεδόν ταυτόσημα με τον βασικό κώδικα. Η μόνη διαφορά είναι η οριακή αύξηση των False Negative (49 έναντι 46), δηλαδή λίγα περισσότερα ανακληθέντα άρθρα που ταξινομήθηκαν λανθασμένα ως έγκυρα. Αυτό υποδηλώνει ότι ο virtual node αντί να ενισχύσει την ανίχνευση των retracted articles, το εμποδίζει ελαφρώς. Ο κόμβος συγκεντρώνει όλη τη πληροφορία από όλα τα άρθρα μαζί και την επιστρέφει σε κάθε ένα από αυτά με αποτέλεσμα κάθε άρθρο να λαμβάνει έναν «μέσο όρο» του γράφου και να διαφοροποιεί τα χαρακτηριστικά της άμεσης γειτονιάς του.

Ανάλυση train/val loss virtual node



Σχήμα 6.15: Train/val loss virtual node

Η καμπύλη εκπαίδευσης με την προσθήκη εικονικού κόμβου αποτελεί ένδειξη της μείωσης της απόδοσης του μοντέλου. Έως την εποχή 40, οι καμπύλες train loss Και val loss συγκλίνουν παράλληλα με αρκετά spikes βέβαια, ενώ το Val F1 αυξάνεται σταθερά πάνω από 0.87. Από την εποχή 50 και μετά, το train loss συνεχίζει να μειώνεται από 0.20 σε 0.15 ενώ το val loss είναι σταθερό γύρω στο 0.28-0.20, δημιουργώντας ένα αυξανόμενο χάσμα που αποτελεί σημάδι ένδειξης υπερπροσαρμογής. Το early stopping στην εποχή 73 με best epoch 53 επιβεβαιώνει ότι το μοντέλο σταματάει να γενικεύει νωρίς. Ο εικονικός κόμβος συνδεόμενος αμφίδρομα με όλα τα 6.190 άρθρα λειτουργεί ως αθροιστής που κατά την εκπαίδευση απομνημονεύει χαρακτηριστικά του train set, χωρίς αυτά να μεταφέρονται αποτελεσματικά στο validation set.

6.7 Αξιολόγηση της γενικευτικής ικανότητας του μοντέλου

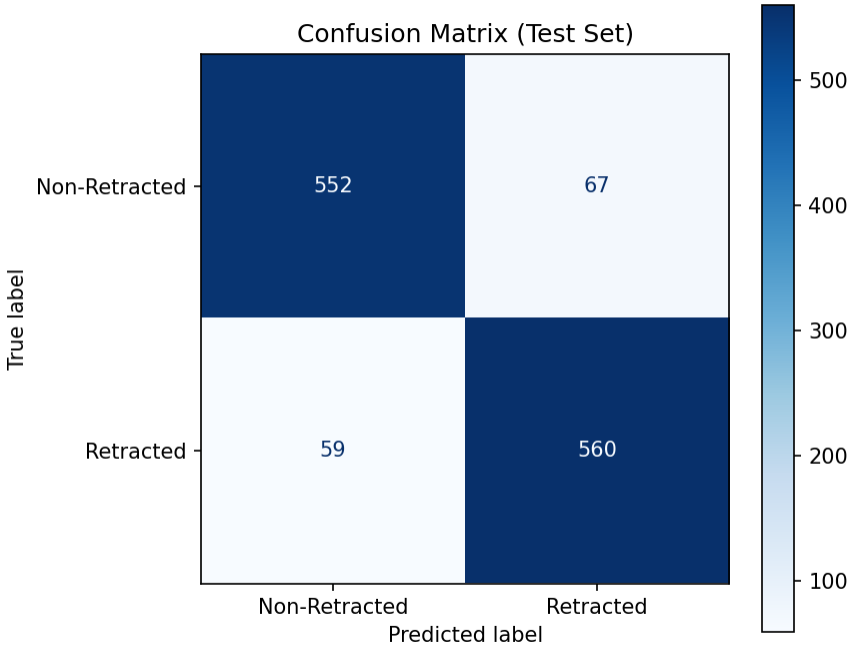
Το τελικό στάδιο της πειραματικής διαδικασίας αποσκοπεί στην αξιολόγηση της γενικευτικής ικανότητας του μοντέλου υπό συνθήκες επαγωγικής μάθησης (inductive learning). Σε αντίθεση με τη μεταγωγική (transductive) προσέγγιση, όπου η πλήρης τοπολογία του γράφου είναι διαθέσιμη, εδώ προσομοιώθηκε ένα ρεαλιστικό σενάριο: το μοντέλο εκπαιδεύτηκε αποκλειστικά σε ένα υπογράφημα από 4.333 κόμβους και κλήθηκε να ταξινομήσει άρθρα (test set) των οποίων η δομική θέση ήταν ”αόρατη” κατά τη φάση της εκπαίδευσης. Για τη διασφάλιση της μεθοδολογικής εγκυρότητας και την αποφυγή διαρροής δεδομένων (data leakage) εφαρμόστηκαν τρεις αυστηρές δικλίδες ασφαλείας. Αρχικά, εφαρμόστηκε η απομόνωση τοπολογίας με τη κλάση NeighborLoader, η οποία χρησιμοποιείται ώστε ο αλγόριθμος να κατασκευάζει τοπικά υπογραφήματα με μοναδική αφετηρία (root nodes) τα άρθρα εκπαίδευσης, αποκρύπτοντας πλήρως κάθε πληροφορία (ακμές/δομή) από το σύνολο επικύρωσης και ελέγχου. Δεύτερον, έγινε εξαίρεση των συγγραφέων που εμφανίζονται ταυτόχρονα στα σύνολα εκπαίδευσης και αξιολόγησης, αποτρέποντας τη δομική διαρροή μέσω κοινών συγγραφέων. Τέλος, όσον αφορά το bibliographic coupling, το μοντέλο διανυσματοποίησης (CountVectorizer) εκπαιδεύτηκε αποκλειστικά στο σύνολο εκπαίδευσης. Έτσι, το λεξιλόγιο και η συχνότητα των παραπομπών καθορίζονται αυστηρά από τα δεδομένα εκπαίδευσης, εμποδίζοντας την ”πρόωρη γνώση” των προτύπων παραπομπών του test set.

Είναι απαραίτητο να διευκρινιστεί η φύση του inductive πλαισίου αξιολόγησης: ενώ κατά το training το μοντέλο περιορίζεται αυστηρά στο υπογράφημα εκπαίδευσης, κατά το στάδιο των validation και testing, μέσω του NeighborLoader, έχει πρόσβαση στην τοπολογική γειτονιά των άρθρων του test set. Ωστόσο, οι κόμβοι αυτοί παραμένουν μεθοδολογικά ”αόρατοι” ως προς τα labels τους, καθώς το μοντέλο δεν έχει ενσωματώσει καμία πληροφορία από τη δομή τους κατά τη διαδικασία βελτιστοποίησης των βαρών. Η ταξινόμηση βασίζεται αποκλειστικά στη γενικευτική ικανότητα των συναρτήσεων συνάθροισης, γεγονός που προσδίδει υψηλή εγκυρότητα στα αποτελέσματα.

Πίνακας 6.10: Αποτελέσματα πειράματος Inductive Learning στο test set.

Epoch	**Train Loss**	**Val Loss**	**Μετρική**	**Τιμή**
10	0.1307	0.2768	Accuracy	0.8982
20	0.0733	0.2993	Precision	0.8931
30	0.0526	0.2944	Recall	0.9047
			F1 Score	0.8989
			ROC AUC	0.9614
			Average Precision	0.9574
Early stopping: epoch 33		*Best epoch: 13*	*Val Loss: 0.2641*	*Val F1: 0.8983*

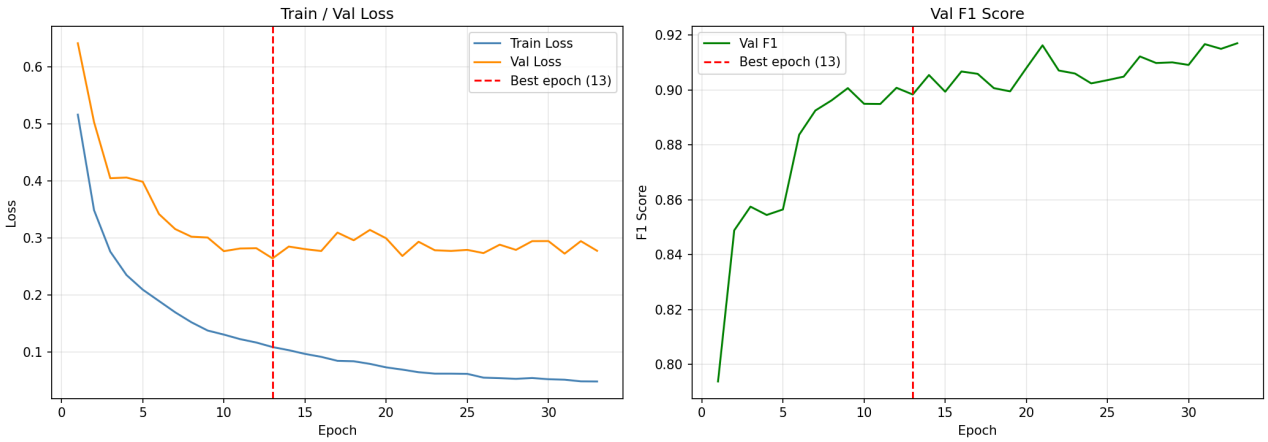
Ανάλυση confusion matrix inductive learning



Σχήμα 6.16: Confusion matrix inductive learning

Ο πίνακας σύγχυσης της επαγωγικής εκπαίδευσης καταγράφει 1.238 κόμβους στο test μετά από deduplication (αφαίρεση διπλότυπων που εισάγει ο NeighborLoader λόγω επικαλυπτόμενων γειτονιών). Το μοντέλο ταξινομεί σωστά 552 έγκυρα και 560 ανακληθέντα άρθρα, με 67 False Positive και 59 False Negative. Η κατανομή σφαλμάτων είναι σχεδόν συμμετρική (67 και 59) γεγονός που υποδηλώνει ότι το μοντέλο δεν προτιμάει συστηματικά κάποια κλάση, και αυτο επιβεβαιώνεται από την ισορροπία μεταξύ precision (0.8931) και recall (0.9047).

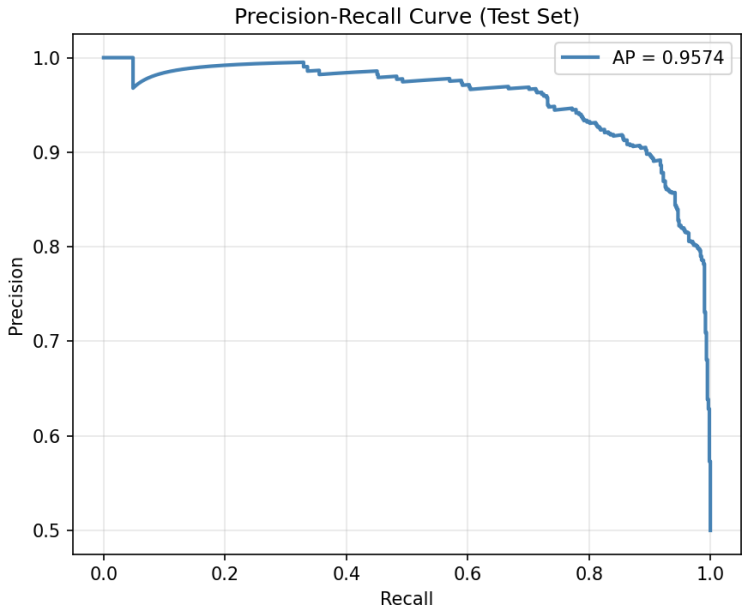
Ανάλυση train/val loss inductive learning



Σχήμα 6.17: Train/val loss inductive learning

Από το διάγραμμα train/val loss δεν παρατηρείται spike όπως στα προηγούμενα πειράματα και αυτό οφείλεται στη χρήση mini-batch training μέσω NeighborLoader, όπου το Train Loss κάθε epoch αντιπροσωπεύει τον μέσο όρο πολλών batches, εξομαλύνοντας τις διακυμάνσεις που παρατηρούνται στα transductive πειράματα full-graph εκπαίδευσης. Το train loss μειώνεται ομαλά σε όλη τη διάρκεια της εκπαίδευσης, ενώ το val loss σταθεροποιείται στο 0.28 γρήγορα στην εποχή 10 και παραμένει σχεδόν αμετάβλητο έως το τέλος. Το early stopping επιλέγει την εποχή 13 (val loss 0.2641) ως βέλτιστη, ωστόσο το Val F1 συνεχίζει να βελτιώνεται μέχρι την epoch 30. (0.9091), ξεπερνώντας το Val F1 της best epoch (0.8983). Αυτή η απόκλιση υποδηλώνει ότι η χρήση του Val loss ως κριτήριο early stopping δεν συμπίπτει πάντα με την βέλτιστη F1. Η ελαφρά ανοδική τάση του validation loss ενώ το train loss συνεχίζει να μειώνεται υποδηλώνει ήπια υπερπροσαρμογή (overfitting), καθώς το μοντέλο αρχίζει να απομνημονεύει τα τοπικά χαρακτηριστικά του υπογραφήματος εκπαίδευσης εις βάρος της γενίκευσης σε άγνωστους κόμβους. Ωστόσο, η έγκαιρη ενεργοποίηση του early stopping αποτρέπει την περαιτέρω απόκλιση, διατηρώντας υψηλές και σταθερές τις μετρικές απόδοσης στο test set.

Ανάλυση precision/recall curve inductive learning



Σχήμα 6.18: Precision/recall curve inductive learning

Η καμπύλη Precision-Recall παραμένει σε υψηλά επίπεδα για μεγάλο εύρος τιμών Recall (Precision > 0.95 έως Recall ≈ 0.70), πριν αρχίσει να πέφτει απότομα κοντά στο Recall = 1.0. Το Average Precision (AP = 0.9574) επιβεβαιώνει την ικανότητα του μοντέλου να ανακτά ανακληθέντα άρθρα με υψηλή ακρίβεια, ακόμα και σε inductive ρύθμιση. Η πτώση στα τελευταία σημεία της καμπύλης είναι αναμενόμενη: για να επιτευχθεί Recall = 1.0 το μοντέλο αναγκάζεται να χαμηλώσει το κατώφλι απόφασης, αυξάνοντας τα False Positives.

6.8 Συνολική σύγκριση αποδόσεων

Πίνακας 6.11: Συγκεντρωτικά αποτελέσματα πειραματικής αξιολόγησης και σύγκριση αρχιτεκτονικών

Μοντέλο	**Αρχιτεκτονική**	**Acc.**	**Prec.**	**Rec.**	**F1**
Main training	Βασικό Μοντέλο	90.79%	89.39%	92.57%	90.95%
Πείραμα 1	Σημασιολογικές ακμές	90.71%	89.50%	92.25%	90.85%
Πείραμα 2	Κόμβοι-πανεπιστήμια	89.90%	88.24%	92.08%	90.12%
Πείραμα 3	Κόμβοι-χώρες	90.06%	87.80%	93.05%	90.35%
Πείραμα 4	Κόμβοι-περιοδικά	**95.64%**	**95.79%**	**95.48%**	**95.63%**
Πείραμα 5	Εικονικός κόμβος	90.63%	89.48%	92.08%	90.76%
Πείραμα 6	Inductive learning	89.82%	89.31%	90.47%	89.89%

Τα αποτελέσματα της συγκεντρωτικής αξιολόγησης αναδεικνύουν σαφείς διαφορές μεταξύ των αρχιτεκτονικών που εξετάστηκαν. Το βασικό μοντέλο επιτυγχάνει F1=90.95%, θέτοντας ένα ισχυρό σημείο αναφοράς που τα περισσότερα πειράματα δυσκολεύονται να ξεπεράσουν. Τα πειράματα 1 έως 3 (σημασιολογικές ακμές, κόμβοι-πανεπιστήμια, κόμβοι-χώρες) έχουν παρόμοια αποτελέσματα (F1: 90.85%, 90.12%, 90.35%), υποδηλώνοντας ότι η προσθήκη σημασιολογικών ακμών και ετερογενών οντοτήτων δεν προσφέρει σημαντικό πλεονέκτημα έναντι της βασικής αρχιτεκτονικής. Εξαίρεση αποτελεί το πείραμα 4 με κόμβους-επιστημονικά περιοδικά, το οποίο επιτυγχάνει την υψηλότερη απόδοση (F1=95.63%), ωστόσο η ερμηνεία αυτού του αποτελέσματος απαιτεί προσοχή λόγω δομής dataset. Το πείραμα 5 με τον εικονικό κόμβο δεν βελτιώνει το βασικό μοντέλο (F1=90.76%) λόγω oversmoothing από τον κόμβο υψηλής συνδεσιμότητας. Τέλος, το πείραμα 6 (inductive learning) παρουσιάζει τη χαμηλότερη F1 (89.89%) , κάτι που είναι αναμενόμενο δεδομένου ότι το μοντέλο εκπαιδεύεται σε υπογράφο και αξιολογείται σε κόμβους άγνωστους σε αυτό, είναι δηλαδή ένα δυσκολότερο σενάριο από ότι τα transductive learning μοντέλα.

Κεφάλαιο 7

Συμπεράσματα

Η εκπόνηση της παρούσας διπλωματικής εργασίας είχε ως κύριο στόχο τη διερεύνηση και την αλγοριθμική ανίχνευση της εκδοτικής απάτης, επικεντρώνοντας στη συστηματική χειραγώγηση των επιστημονικών μετρικών μέσω οργανωμένων δικτύων (paper mills) και καρτέλ αναφορών. Η μεθοδολογική προσέγγιση απομακρύνθηκε από την παραδοσιακή ανάλυση κειμένου προτείνοντας τη μοντελοποίηση του ακαδημαϊκού περιβάλλοντος ως έναν ετερογενή γράφο. Μέσω της εφαρμογής Νευρωνικών Δικτύων Γράφων (GNNs) και ειδικότερα της αρχιτεκτονικήςGraphSAGE κατέστη δυνατή η συνδυαστική αξιολόγηση σημασιολογικών χαρακτηριστικών (SPECTER 2 - embeddings) και τοπολογικών μοτίβων (δίκτυα αναφορών και συνεργασιών). Η σταδιακή αρχιτεκτονική επέκταση του δικτύου μέσα από μια σειρά στοχευμένων πειραμάτων προσέφερε γνώση για τους μηχανισμούς της ακαδημαϊκής διαφθοράς, οδηγώντας στα ακόλουθα επιμέρους συμπεράσματα.

7.1 Η τοπολογία ως αυτόνομος δείκτης αξιοπιστίας (βασικό μοντέλο)

Το βασικό μοντέλο αποτέλεσε την απόδειξη ορθότητας της κεντρικής ερευνητικής υπόθεσης, επιτυγχάνοντας F1-score 90.95%, Precision 89.39% και Recall 92.57%. Η υψηλή τιμή Recall υποδηλώνει ότι το μοντέλο εντοπίζει την πλειοψηφία των ανακληθέντων άρθρων, αποδεικνύοντας ότι οι κακόβουλες δημοσιεύσεις δεν αποτελούν απομονωμένες στατιστικές αστοχίες, αλλά είναι μέρος ενός πυκνού δικτύου σχέσεων. Η δομή των παραπομπών, οι σχέσεις άρθρου-συγγραφέων, οι συνεργασίες των συγγραφέων και η βιβλιογραφική σύζευξη λειτουργούν ως τοπολογικό αποτύπωμα που διαχωρίζει με σαφήνεια την επιστημονική δραστηριότητα από τις βιομηχανοποιημένες πρακτικές των paper mills. Το βασικό μοντέλο παραμένει το ισχυρότερο transductive μοντέλο πέρα από το πείραμα 4, επιβεβαιώνοντας ότι η δομή αναφορών και συν-συγγραφής αρκεί για ένα αξιόπιστο βασικό έλεγχο.

7.2 Η σημασία της πρόσθετης σημασιολογικής ομοιότητας (πείραμα 1)

Η προσθήκη ακμών βάσει ομοιότητας συνημιτόνου επί των SPECTER2 διανυσμάτων οδήγησε σε οριακή μείωση απόδοσης (F1: 90.85%). Παρόλο που η μετρική Precision αυξήθηκε λίγο (89.50%), η Recall μειώθηκε (92.25%), με αποτέλεσμα χαμηλότερο F1-score. Αυτό υποδηλώνει ότι οι σημασιολογικές ακμές εισάγουν θόρυβο στην συνάθροιση γειτονιών, καθώς άρθρα με παρόμοιο θεματικό περιεχόμενο δεν είναι απαραίτητα συνδεδεμένα με δίκτυα απάτης, με αποτέλεσμα το μοντέλο να γίνεται πιο ”συντηρητικό” χωρίς να αυξάνεται η διακριτική του ικανότητα. Το συμπέρασμα είναι ότι η προσθήκη σημασιολογικής ομοιότητας κειμένου δεν βελτίωσε την ανίχνευση της ακαδημαϊκής απάτης.

7.3 Η συνεισφορά των θεσμικών μεταδεδομένων (πειράματα 2, 3)

Η ενσωμάτωση κόμβων-πανεπιστημίων (πείραμα 2) και κόμβων-χωρών (πείραμα 3) απέδωσε F1-score 90.12% και 90.35% αντίστοιχα -και τα δύο χαμηλότερα από το βασικό μοντέλο. Παρά την μείωση αυτή, η προσθήκη κόμβων-χωρών πέτυχε το υψηλότερο Recall μεταξύ όλων των transductive πειραμάτων (93.05%), υποδηλώνοντας ότι η γεωγραφική πληροφορία ενισχύει την ευαισθησία του μοντέλου, δηλαδή εντοπίζει περισσότερα ανακληθέντα άρθρα, όμως μειώνει την μετρική Precision (87.80%). Αντίθετα, οι κόμβοι-πανεπιστήμια διατήρησαν ισορροπημένη κατανομή σφαλμάτων (Precision 88.24% και Recall 92.08%), υποδεικνύοντας ότι το ακαδημαϊκό ίδρυμα αποτελεί μία πιο στοχευμένη οντότητα στον γράφο από ότι η χώρα. Συμπερασματικά, και τα δύο πειράματα επιβεβαιώνουν ότι τα θεσμικά μεταδεδομένα εμπλουτίζουν τον γράφο με νέες σχέσεις αλλά δεν βελτιώνουν την τελική απόδοση, πιθανώς λόγω αυξημένη ετερογένειας που εισάγουν στις γειτονιές των κόμβων-άρθρων.

7.4 Το εκδοτικό περιβάλλον ως ισχυρός δείκτης απάτης (πείραμα 4)

Το σημαντικότερο εύρημα της εργασίας προέκυψε κατά την εισαγωγή των επιστημονικών περιοδικών (journals) ως διακριτών δομικών κόμβων. Το μοντέλο κατέγραψε τη μέγιστη απόδοσή του, φτάνοντας Accuracy 95.64%, F1-score 95.63% και Recall 95.48% -ξεπερνώντας κατά περίπου 5 μονάδες όλα τα υπόλοιπα πειράματα. Επίσης υπάρχει ισορροπία μεταξύ Precision και Recall, γεγονός που υποδηλώνει ότι ο κόμβος-επιστημονικό περιοδικό προσφέρει κρίσιμη πληροφορία στο δίκτυο. Αυτό επιβεβαιώνει ότι τα οργανωμένα δίκτυα απάτης στοχεύουν συστηματικά συγκεκριμένα επιστημονικά περιοδικά, αφήνοντας διακριτό τοπολογικό αποτύπωμα. Το εύρημα αυτό συνάδει με προγενέστερη έρευνα: το CIDRE [28] εντοπίζει πάνω από το 50% των επιστημονικών περιοδικών που ανακλήθηκαν από το Journal Citation Reports (JCR) λόγω ύπο-

πτης συμπεριφοράς αναφορών, ενισχύοντας την υπόθεση ότι το εκδοτικό περιβάλλον αποτελεί έναν ισχυρό δείκτη οργανωμένης χειραγώγησης. Ωστόσο, η ερμηνεία αυτού του αποτελέσματος απαιτεί προσοχή καθώς ο σχεδιασμός του dataset περιελάμβανε έγκυρα άρθρα επιλεγμένα από τα ίδια περιοδικά με τα ανακληθέντα, γεγονός που μπορεί να επηρεάζει θετικά την διακριτική ικανότητα του μοντέλου.

7.5 Η τοπικότητα των κακόβουλων μοτίβων (πείραμα 5)

Ο εικονικός κόμβος (virtual node), ο οποίος συνδέεται με όλα τα άρθρα του γράφου, πέτυχε F1-score 90.76%, ποσοστό ελαφρά χαμηλότερο από το βασικό μοντέλο. Η διαφορά αυτή, αν και μικρή, έχει ερμηνευτική σημασία: ο κόμβος με βαθμός συνδεσιμότητας 12.380 ακμών λειτουργεί ως μηχανισμός παγκόσμιας συνάθροισης, αδρανοποιώντας τοπικές δομές που αποτελούν το κύριο σημείο εντοπισμού ακαδημαϊκής απάτης. Παρουσιάζονται σημάδια oversmoothing όταν η Precision μειώνεται (89.48%) όσο μειώνεται και η Recall (92.08%). Το συμπέρασμα είναι ότι η ακαδημαϊκή απάτη είναι φαινόμενο τοπικής τοπολογίας, εμφανίζεται σε πυκνές, κλειστές κοινότητες και δεν εκφράζεται σε παγκόσμια δομικά μοτίβα που θα εντοπίζονταν με την προσθήκη του virtual node.

7.6 Δυνατότητα γενίκευσης σε πραγματικές συνθήκες (πείραμα 6)

Η μετάβαση σε περιβάλλον επαγωγικής μάθησης (inductive learning) πιστοποίησε την πρακτική αξία του συστήματος. Το μοντέλο ταξινόμησε κόμβους των οποίων η τοπολογική θέση ήταν παντελώς αόρατη κατά την εκπαίδευση και παρουσίασε Ακρίβεια (Precision) 89.31% και συνολικό F1-score 89.89%. Η μείωση μόλις μίας μονάδας στο F1-score σε σχέση με το βασικό transductive μοντέλο (90.95%) αποδεικνύει ότι το δίκτυο δεν απομνημόνευσε τη συγκεκριμένη γεωμετρία του γράφου, αλλά αφομοίωσε θεμελιώδη δομικά μοτίβα που γενικεύονται σε νέους κόμβους. Υπάρχει ισορροπία μεταξύ Precision και Recall η οποία υποδηλώνει ότι το μοντέλο δεν αναπτύσσει μεροληψία κατά την αξιολόγηση άγνωστων κόμβων. Το AUC (0.9614%) και το Average Precision (0.9574) επιβεβαιώνουν την διαχωριστική ικανότητα του μοντέλου, η οποία μπορεί να εφαρμοστεί και σε πραγματικές συνθήκες.

7.7 Περιορισμοί της μελέτης

Η εξαγωγή ασφαλών συμπερασμάτων προϋποθέτει την αναγνώριση των περιορισμών του τρέχοντος πειραματικού σχεδιασμού. Αρχικά, η κλίμακα του συνόλου δεδομένων (6.190 άρθρα), αν και επαρκής για την απόδειξη της μεθοδολογίας, αντιπροσωπεύει ένα μικρό κλάσμα της παγκόσμιας επιστημονικής παραγωγής. Ακόμα το dataset περιορίζεται σε άρθρα με πλήρη κάλυψη DOI και OpenAlex, εισάγοντας μια μεροληψία (bias) υπέρ συγκεκριμένων επιστημονικών πεδίων,

αφήνοντας εκτός συστήματος δημοσιεύσεις σε τοπικά περιοδικά ή άλλες γλώσσες. Επιπλέον, το σύνολο δεδομένων κατασκευάστηκε τεχνητά με αναλογία 50-50 μεταξύ έγκυρων και ανακληθέντων άρθρων για τις ανάγκες εκπαίδευσης. Στο πραγματικό ακαδημαϊκό σύστημα, τα άρθρα που συνδέονται με οργανωμένη απάτη (paper mills) αποτελούν λιγότερο από το 1% του συνόλου, γεγονός που αυξάνει τη δυσκολία εντοπισμού τους σε πραγματικές συνθήκες. Όσον αφορά τα εξωτερικά άρθρα που δεν άνηκαν στο αρχικό dataset, αυτά ενσωματώθηκαν με μηδενικά διανύσματα χαρακτηριστικών, αφαιρώντας έτσι σημασιολογική πληροφορία από τις γειτονιές δεύτερου βαθμού. Επίσης, το χαρακτηριστικό των συγγραφέων (orcid) κωδικοποιήθηκε απλά ως δυαδική τιμή για απόδειξη εγκυρότητας των συγγραφέων. Ο ορισμός του "ανακληθέντος" (retracted) βασίστηκε αποκλειστικά στα labels του Retraction Watch. Η έλλειψη διάκρισης μεταξύ χειραγώγησης και ειλικρινούς σφάλματος ενδέχεται να θολώνει το εκπαιδευτικό σήμα, καθώς ο μηχανισμός εντοπισμού απάτης καλείται να διακρίνει φαινόμενα που τοπολογικά μπορεί να διαφέρουν σημαντικά. Τέλος, η αρχιτεκτονική του μοντέλου περιορίστηκε σε δύο επίπεδα για την αποφυγή της υπερεξομάλυνσης, αφήνοντας ανοιχτό το ερώτημα αν πιο βαθιές αρχιτεκτονικές με κατάλληλους μηχανισμούς θα αποδώσουν βέλτιστα.

7.8 Γενικό συμπέρασμα

Στην αρχή της παρούσας εργασίας διατυπώθηκε το ερευνητικό κενό σχετικά με την ανάγκη μετάβασης από την αμιγώς γλωσσική ανάλυση στην τοπολογική μελέτη των επιστημονικών δικτύων. Η αναγκαιότητα αυτή καλύφθηκε, επιβεβαιώνοντας ότι η συστηματική αλλοίωση των βιβλιομετρικών δεδομένων αφήνει σαφές και ανιχνεύσιμο δομικό αποτύπωμα στον γράφο. Από τη συγκριτική ανάλυση των πειραμάτων αναδύονται τρία κεντρικά ευρήματα. Πρώτον, η τοπολογία των αναφορών και της συν-συγγραφής αποτελεί αυτόνομο και ισχυρό σήμα ανίχνευσης: το βασικό μοντέλο είχε την καλύτερη απόδοση πέρα από το πείραμα 4. Δεύτερον, η πληροφορία του περιοδικού δημοσίευσης αποδείχθηκε ο ισχυρότερος ενιαίος δείκτης απάτης, επιβεβαιώνοντας ότι τα paper mills λειτουργούν στοχευμένα εντός συγκεκριμένων εκδοτικών περιβαλλόντων. Τρίτον, η επαγωγική γενίκευση αποδεικνύει ότι το μοντέλο μαθαίνει δομικά μοτίβα και όχι απλώς τοπολογικές συντεταγμένες, καθιστώντας το κατάλληλο για ανάπτυξη σε πραγματικά δίκτυα. Συνοψίζοντας, η παρούσα εργασία παρέχει μία λύση στο πεδίο της βιβλιομετρίας, καταδεικνύοντας ότι τα Νευρωνικά Δίκτυα Γράφων και η ενσωμάτωση ετερογενούς βιβλιομετρικής πληροφορίας επιτρέπουν τον εντοπισμό κακόβουλων πρακτικών με ακρίβεια. Η προτεινόμενη αρχιτεκτονική είναι κλιμακώσιμη και μπορεί να λειτουργήσει ως εργαλείο προληπτικού ελέγχου, μετατρέποντας την ακαδημαϊκή βιβλιομετρία από εργαλείο στατικής ανάλυσης σε δυναμική πλατφόρμα διασφάλισης της επιστημονικής ακεραιότητας.

Κεφάλαιο 8

Μελλοντική εργασία

8.1 Κλιμάκωση και εμπλουτισμός του συνόλου δεδομένων

Η άμεση ερευνητική προοπτική αφορά την κλιμάκωση της βάσης δεδομένων πέρα από το τρέχον δείγμα των 6.190 άρθρων, ενσωματώνοντας μια ευρύτερη ποικιλία επιστημονικών πεδίων μέσω ανοιχτών API όπως το OpenAlex. Η επέκταση αυτή θα επιτρέψει τη δημιουργία ενός «ζωντανού» οικοσυστήματος δεδομένων, ικανού να αντιπροσωπεύει την παγκόσμια ερευνητική δραστηριότητα. Ωστόσο, η διαχείριση της ανισορροπίας κλάσεων (class imbalance) αποτελεί κρίσιμη πρόκληση, καθώς το πραγματικό ποσοστό απάτης παραμένει μικρότερο του 1%. Προς αυτή την κατεύθυνση, προτείνεται η διερεύνηση τεχνικών Graph Oversampling (π.χ. SMOTE-NC) ή η εφαρμογή Weighted Cross-Entropy απωλειών, ώστε το μοντέλο να μην εγκλωβίζεται σε ένα υψηλό Accuracy που οφείλεται αποκλειστικά στην αναγνώριση των νόμιμων άρθρων, αλλά να αναπτύξει υψηλή ευαισθησία (Recall) στα σπάνια περιστατικά απάτης.

8.2 Εμπλουτισμός τοπολογίας και ετερογένειας

Ο ετερογενής γράφος μπορεί να αποκτήσει σημαντικά μεγαλύτερη εκφραστικότητα μέσω μιας βαθύτερης μοντελοποίησης των ακμών. Πέρα από τη δυαδική σύνδεση cites, προτείνεται η εισαγωγή χαρακτηριστικών όπως η «θέση της αναφοράς» στο κείμενο και το citation sentiment, τα οποία διακρίνουν μια ουδέτερη παραπομπή από μια εσκεμμένη προσπάθεια χειραγώγησης των δεικτών (citation manipulation). Επιπροσθέτως, η επέκταση του δικτύου με κόμβους ερευνητικών υποδομών ή εργαστηρίων θα αποκαλύψει και οργανωτικές εξαρτήσεις, οι οποίες συχνά υποκρύπτουν τη «βιομηχανοποιημένη» φύση των paper mills. Με αυτόν τον τρόπο, το μοντέλο θα μετακινηθεί από την ανάλυση μεμονωμένων άρθρων στην αναγνώριση «μοτίβων δράσης» ολόκληρων κυκλωμάτων.

8.3 Εξέλιξη της αρχιτεκτονικής GNN

Η επιτυχία του GraphSAGE επιβεβαιώνει την αξία της επαγωγικής μάθησης, ωστόσο η αρχιτεκτονική του περιορίζεται από την ισότιμη μεταχείριση των γειτόνων κατά τη συνάθροιση

(aggregation). Το επόμενο βήμα περιλαμβάνει την αξιολόγηση Graph Attention Networks (GAT) ή Heterogeneous Graph Transformer (HGT) αρχιτεκτονικών, που επιτρέπουν στο μοντέλο να αποδίδει δυναμική βαρύτητα σε κρίσιμους γείτονες (π.χ. predatory journals). Παράλληλα, για την αποφυγή φαινομένων oversmoothing που παρατηρήθηκαν κατά το Πείραμα 5, μελλοντικές αρχιτεκτονικές πρέπει να ενσωματώνουν Skip Connections και τεχνικές Graph Normalization, επιτρέποντας τη δημιουργία βαθύτερων δικτύων χωρίς απώλεια της τοπικής διακριτότητας. Επιπλέον, η αξιοποίηση των Graph Masked Autoencoders (GMAE) μέσω self-supervised learning θα επιτρέψει την εκπαίδευση σε τεράστια σύνολα δεδομένων χωρίς ανάγκη για ετικέτες, αποκαλύπτοντας κρυμμένες δομικές ασυνέπειες που δεν είναι άμεσα ορατές με επιβλεπόμενη μάθηση.

8.4 Επεξηγηματικότητα και διαφάνεια

Η υιοθέτηση του συστήματος από μεγάλους εκδοτικούς οίκους απαιτεί την ενσωμάτωση μηχανισμών Explainable AI (XAI). Η χρήση εργαλείων όπως το GNNExplainer ή το Integrated Gradients θα επιτρέπει στους επιμελητές να εντοπίζουν το ακριβές «υπογράφημα της απάτης» (π.χ. γιατί ένα άρθρο χαρακτηρίστηκε ύποπτο – λόγω αναφορών, συγγραφέων ή περιοδικού;). Η δυνατότητα αυτή καθιστά το μοντέλο ένα αξιόπιστο εργαλείο υποστήριξης αποφάσεων (Decision Support System), αυξάνοντας τη διαφάνεια και την εμπιστοσύνη των ειδικών στις αυτοματοποιημένες προτάσεις του συστήματος.

8.5 Μοντελοποίηση δυναμικών γράφων (TGNs)

Η πιο υποσχόμενη επέκταση είναι η μετάβαση σε Temporal Graph Networks (TGNs). Δεδομένου ότι η απάτη εκδηλώνεται συχνά μέσω «εκρηκτικών» μοτίβων (bursty citation patterns), η μοντελοποίηση του χρόνου ως εγγενές χαρακτηριστικό θα επιτρέψει στο σύστημα να αντιλαμβάνεται τη χρονική αλληλουχία των γεγονότων. Μια τέτοια προσέγγιση μετατρέπει το μοντέλο από ένα στατικό εργαλείο μετα-ανάλυσης σε μια δυναμική πλατφόρμα pre-publication screening, ικανή να αξιολογεί την ακεραιότητα ενός χειρογράφου τη στιγμή της υποβολής του. Έτσι, προλαμβάνεται η διασπορά της ακαδημαϊκής απάτης πριν αυτή εισέλθει στην επίσημη επιστημονική βιβλιογραφία, προστατεύοντας την εγκυρότητα του επιστημονικού λόγου.

Βιβλιογραφία

[1] I. Fister, I. Fister, and M. Perc, "Toward the discovery of citation cartels in citation networks," *Frontiers in Physics*, vol. 4, 12 2016.

[2] E. A. Fong and A. W. Wilhite, "Authorship and citation manipulation in academic research," *PLoS ONE*, vol. 12, 12 2017.

[3] M. L. Grieneisen and M. Zhang, "A comprehensive survey of retracted articles from the scholarly literature," *PLoS ONE*, vol. 7, 10 2012.

[4] E. Wager and P. Williams, "Why and how do journals retract articles? an analysis of medline retractions 1988-2008," *Journal of Medical Ethics*, vol. 37, pp. 567–570, 2011.

[5] S. Y. Hwang, D. K. Yon, S. W. Lee, M. S. Kim, J. Y. Kim, L. Smith, A. Koyanagi, M. Solmi, A. F. Carvalho, E. Kim, E. Kim, J. I. Shin, and J. P. Ioannidis, "Causes for retraction in the biomedical literature: A systematic review of studies of retraction notices," *Journal of Korean Medical Science*, vol. 38, pp. 1–18, 2023.

[6] P. E. van der Vet and H. Nijveen, "Propagation of errors in citation networks: a study involving the entire citation network of a widely cited paper published in, and later retracted from, the journal nature," *Research Integrity and Peer Review*, vol. 1, 5 2016.

[7] J. Bar-Ilan and G. Halevi, "Post retraction citations in context: a case study.," *Scientometrics*, vol. 113, pp. 547–565, 2017.

[8] T.-K. Hsiao and J. Schneider, "Continued use of retracted papers: Temporal trends in citations and (lack of) awareness of retractions shown in citation contexts in biomedicine.," *Quantitative science studies*, vol. 2, pp. 1144–1169, 2 2022.

[9] I. Heibi and S. Peroni, "A qualitative and quantitative analysis of open citations to retracted articles: the wakefield 1998 et al.'s case," *Scientometrics*, vol. 126, pp. 8433–8470, 10 2021.

[10] I. Heibi and S. Peroni, "A quantitative and qualitative open citation analysis of retracted articles in the humanities," *Quantitative Science Studies*, vol. 3, pp. 953–975, 12 2022.

[11] C. Candal-Pedreira, C. Guerra-Tort, A. Ruano-Ravina, F. Freijedo-Farinas, J. Rey-Brandariz, J. S. Ross, and M. Pérez-Ríos, "Retracted papers originating from paper mills: A cross-sectional analysis of references and citations," *Journal of Clinical Epidemiology*, vol. 172, p. 111397, 2024.

[12] J. Zhang, J. Liu, E. Haihong, T. Hu, X. Qiao, and Z. C. Tang, "A paper mill detection model based on citation manipulation paradigm," *Journal of Data and Information Science*, vol. 10, pp. 167–187, 2 2025.

[13] J. A. Byrne, Y. Park, R. A. Richardson, P. Pathmendra, M. Sun, and T. Stoeger, "Protection of the human gene research literature from contract cheating organizations known as research paper mills," *Nucleic Acids Research*, vol. 50, pp. 12058–12070, 11 2022.

[14] J. Wittau and R. Seifert, "How to fight fake papers: a review on important information sources and steps towards solution of the problem," 12 2024.

[15] H. Ibrahim, F. Liu, Y. Zaki, and T. Rahwan, "Google scholar is manipulatable," 2 2024.

[16] L. Besançon, G. Cabanac, C. Labbé, and A. Magazinov, "Sneaked references: Fabricated reference metadata distort citation counts," *Journal of the Association for Information Science and Technology*, vol. 75, pp. 1368–1379, 12 2024.

[17] J. A. Byrne, A. Abalkina, O. Akinduro-Aje, J. Christopher, S. E. Eaton, N. Joshi, U. Scheffler, N. H. Wise, and J. Wright, "A call for research to address the threat of paper mills," *PLoS Biology*, vol. 22, 11 2024.

[18] H. Ibrahim, F. Liu, Y. Zaki, and T. Rahwan, "Citation manipulation through citation mills and pre-print servers," *Scientific Reports*, vol. 15, 12 2025.

[19] M. Mehregan, "Scientific journals must be alert to potential manipulation in citations and referencing," *Research Ethics*, vol. 18, pp. 163–168, 4 2022.

[20] S. J. Porter and L. D. McIntosh, "Identifying fabricated networks within authorship-for-sale enterprises," *Scientific Reports*, vol. 14, 12 2024.

[21] B. Scancar, J. A. Byrne, D. Causeur, and A. G. Barnett, "Machine learning based screening of potential paper mill publications in cancer research: methodological and cross sectional study," *British Medical Journal (BMJ)*, vol. 392, 2026.

[22] C. Bless, A. Waldis, A. Parfenova, M. A. Rodriguez, and A. Marfurt, "Analyzing the evolution of scientific misconduct based on the language of retracted papers," in *Proceedings of the Fifth Workshop on Scholarly Document Processing (SDP 2025)*, 2025.

[23] A. Sarkar, R. Das, M. Nandan, and A. B. Chowdhury, "BERTRetrax: A transformer-augmented pipeline for retraction detection in scholarly articles," 2024.

[24] M. Fire and C. Guestrin, "Over-optimization of academic publishing metrics: observing goodhart's law in action," *GigaScience*, vol. 8, no. 6, p. giz053, 2019.

[25] L. Chen, S. Fu, G. E. Freedman, C. Zor, G. Martin, J. Kinross, U. Vaghela, O. Şerban, and F. Toni, "Pub-Guard-LLM: Detecting retracted biomedical articles with reliable explanations," *arXiv preprint arXiv:2502.15429*, 2025.

[26] V. Plevris, "Quantifying unethical self-citation practices in academic research," *Journal of Academic Ethics*, 2025.

[27] R. Avros, M. B. Haim, A. Madar, E. Ravve, and Z. Volkovich, "Spotting suspicious academic citations using self-learning graph transformers," *MDPI Mathematics*, 2024.

[28] S. Kojaku, G. Livan, and N. Masuda, "Detecting anomalous citation groups in journal networks," vol. 11, 9 2021.

[29] J. Liu, F. Xia, X. Feng, J. Ren, and H. Liu, "Deep graph learning for anomalous citation detection," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 33, no. 6, pp. 2543–2557, 2022.

[30] P. W. Battaglia, J. B. Hamrick, V. Bapst, A. Sanchez-Gonzalez, V. Zambaldi, M. Malinowski, A. Tacchetti, D. Raposo, A. Santoro, R. Faulkner, *et al.*, "Relational inductive biases, deep learning, and graph networks," *arXiv preprint arXiv:1806.01261*, 2018.

[31] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *International Conference on Learning Representations (ICLR)*, 2017.

[32] W. L. Hamilton, "Graph representation learning," tech. rep., 2020.

[33] P. Veličkovick, G. Cucurull, A. Casanova, A. Romero, P. Liò, and Y. Bengio, "Graph attention networks," in *International Conference on Learning Representations (ICLR)*, 2018.

[34] M. Schlichtkrull, T. N. Kipf, P. Bloem, R. Ritscht, M. Seitzer, and M. Welling, "Modeling relational data with graph convolutional networks," *arXiv preprint arXiv:1703.06103*, 2017.

[35] A. H. A. Fletcher and M. Stevenson, "Predicting retracted research: a dataset and machine learning approaches," *Research Integrity and Peer Review*, 6.

[36] Crossref, "Retraction watch data repository." `https://gitlab.com/crossref/retraction-watch-data`, 2023.

[37] Y. Zhou, J. Zhang, M. Wang, and L. Yu, "Bmdetect: A novel dataset for biomedical misconduct detection," *Journal of Biomedical Informatics*, 2025.

[38] A. Fletcher and B. Stevenson, "Matching methodologies for predicting scientific retractions," *Journal of Data and Information Science*, vol. 10, no. 1, pp. 1–22, 2025.

[39] S. Rao, H. Liu, Z. Zhang, K. Saha, and D. Yang, "Withdrarxiv: A large-scale dataset for analyzing retractions in preprint archives," 2024.

[40] E. Sabir, S. Nandi, W. AbdAlmageed, and P. Natarajan, "Biofors: A benchmark dataset for biomedical image forensics," 2021.

[41] Mathurinache, "Citation network dataset." `https://www.kaggle.com/datasets/mathurinache/citation-network-dataset`, 2021.